《人工智能通识》（科技素养）

第5讲 强化学习

主讲：丛润民





章节知识点概览



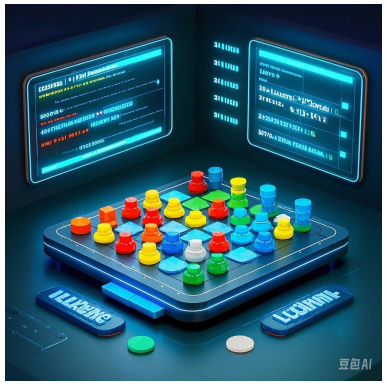
知识点1：马尔可夫决策过程——以井字棋游戏为例

知识点2：解密贝尔曼方程

知识点3：当深度学习遇到强化学习

知识点4：智能机器人与强化学习

知识点1：
马尔可夫决策过程 — 以井字棋为例

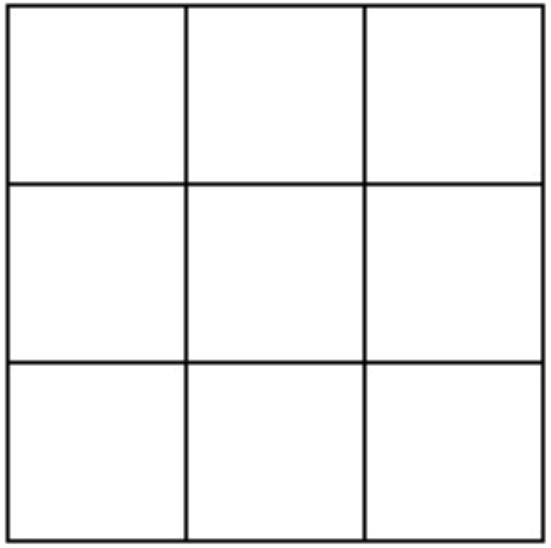


01 马尔可夫性质

02 马尔可夫决策过程

一起来玩井字棋！

井字棋，英文名为 Tic-Tac-Toe，是一种在 3×3 格子上进行的两人对弈游戏。游戏双方轮流在空格中放置自己的棋子。先手玩家先放置“X”，后手玩家放置“O”。率先将自己的三个棋子连成一条直线的玩家获胜。如果棋盘被填满后，双方都没有达成三子连线，则游戏为平局。

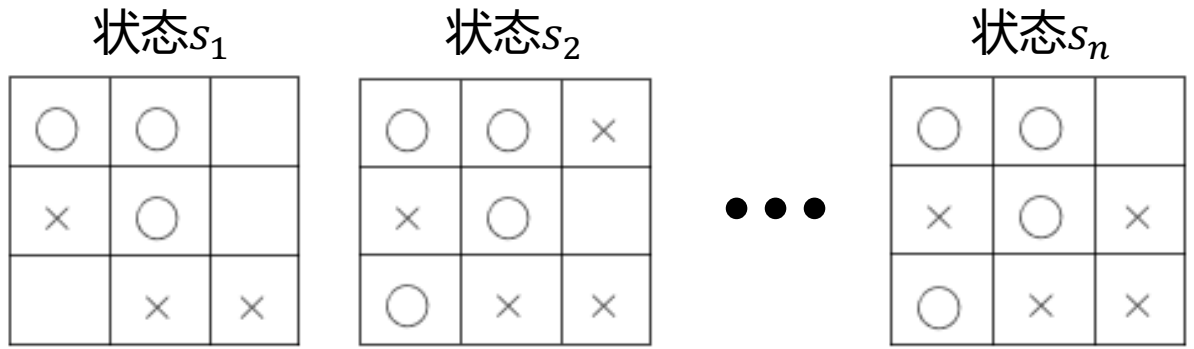


- 每个格子有三种选择，分别为：X、O和空，每个选择都会对结果产生影响
- **只需要关注当前棋盘上棋子的分布状态**，而不需要考虑之前是如何走到这个状态的


今天很不错👍
五
完
晚
t
y
u
i
d
f
g
h
j
k
l
x
c
v
b
n
m
确认
选定
你有没有纳闷过

马尔可夫决策过程

在井字棋游戏中，我们可以作如下定义：

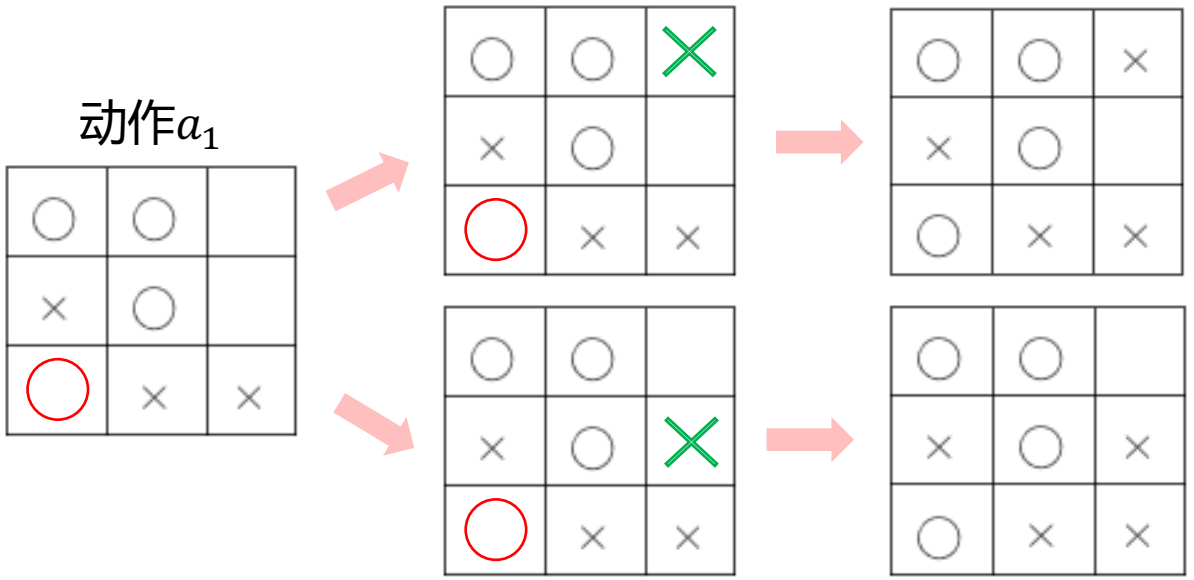


状态空间（State Space，S）：

所有落子之前的棋盘分布

动作空间（Action Space，A）：

棋手落子的9个位置



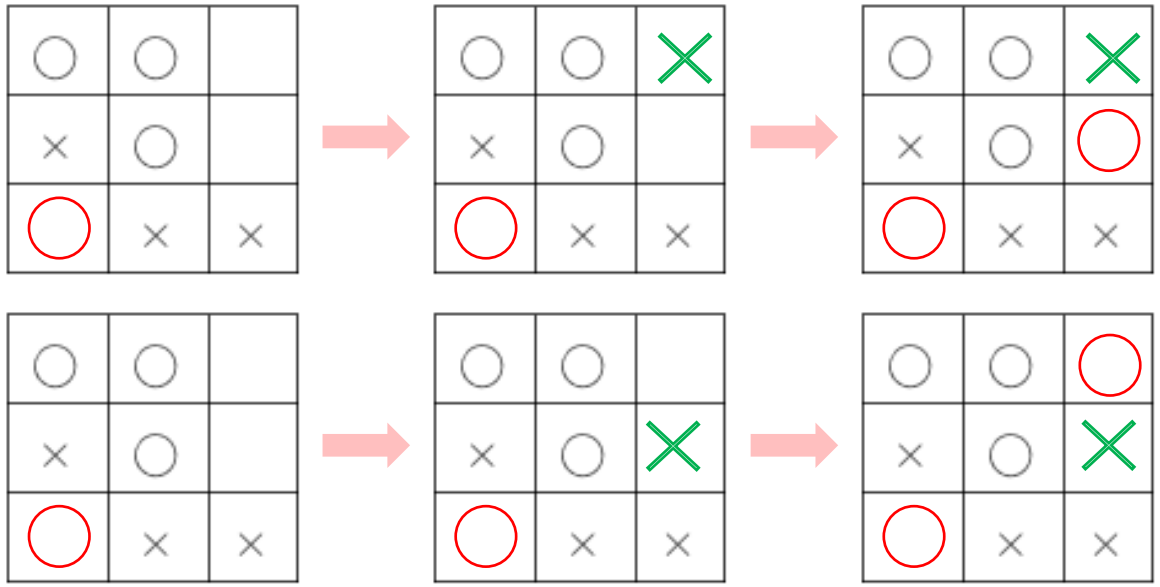
状态转移概率

（Transition Probability，P）：

棋手○落子后，棋手×落子位置使棋盘变为新的状态的可能性

马尔可夫决策过程

为了增加游戏的趣味性，我们还可以设置奖励和惩罚机制：

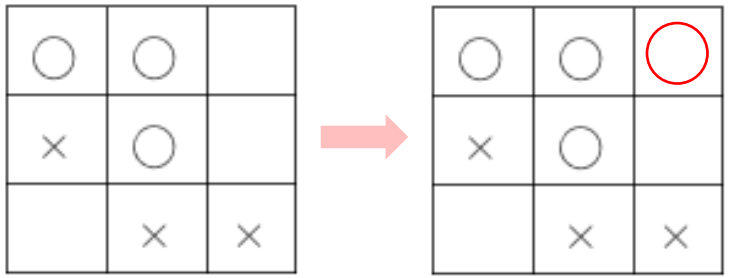


平局：奖励（Reward）$R=0$

获胜：奖励$R=+100$ $R=0.9^4\times100$

失败：奖励$R=-100$

事实上，我们还可以有更快的获胜方式：

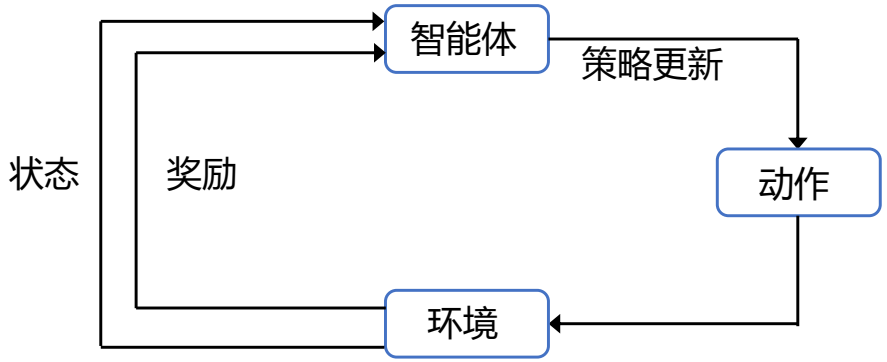


衰减因子γ：步数越少，奖励越高 $R=0.9^3\times100$

以最大化游戏奖励为目标，以最小回合数获胜的方式，被称为策略（Policy）

马尔可夫决策过程

通过井字棋，我们可以定义一个马尔可夫决策过程的5个关键组成部分：



1) **状态空间S**：所有环境状态的集合，$s_t \in S$表示t时刻智能体所处的状态。

2) **动作空间A**：智能体可执行动作的集合，$a_t \in A$表示t时刻智能体所执行的动作。

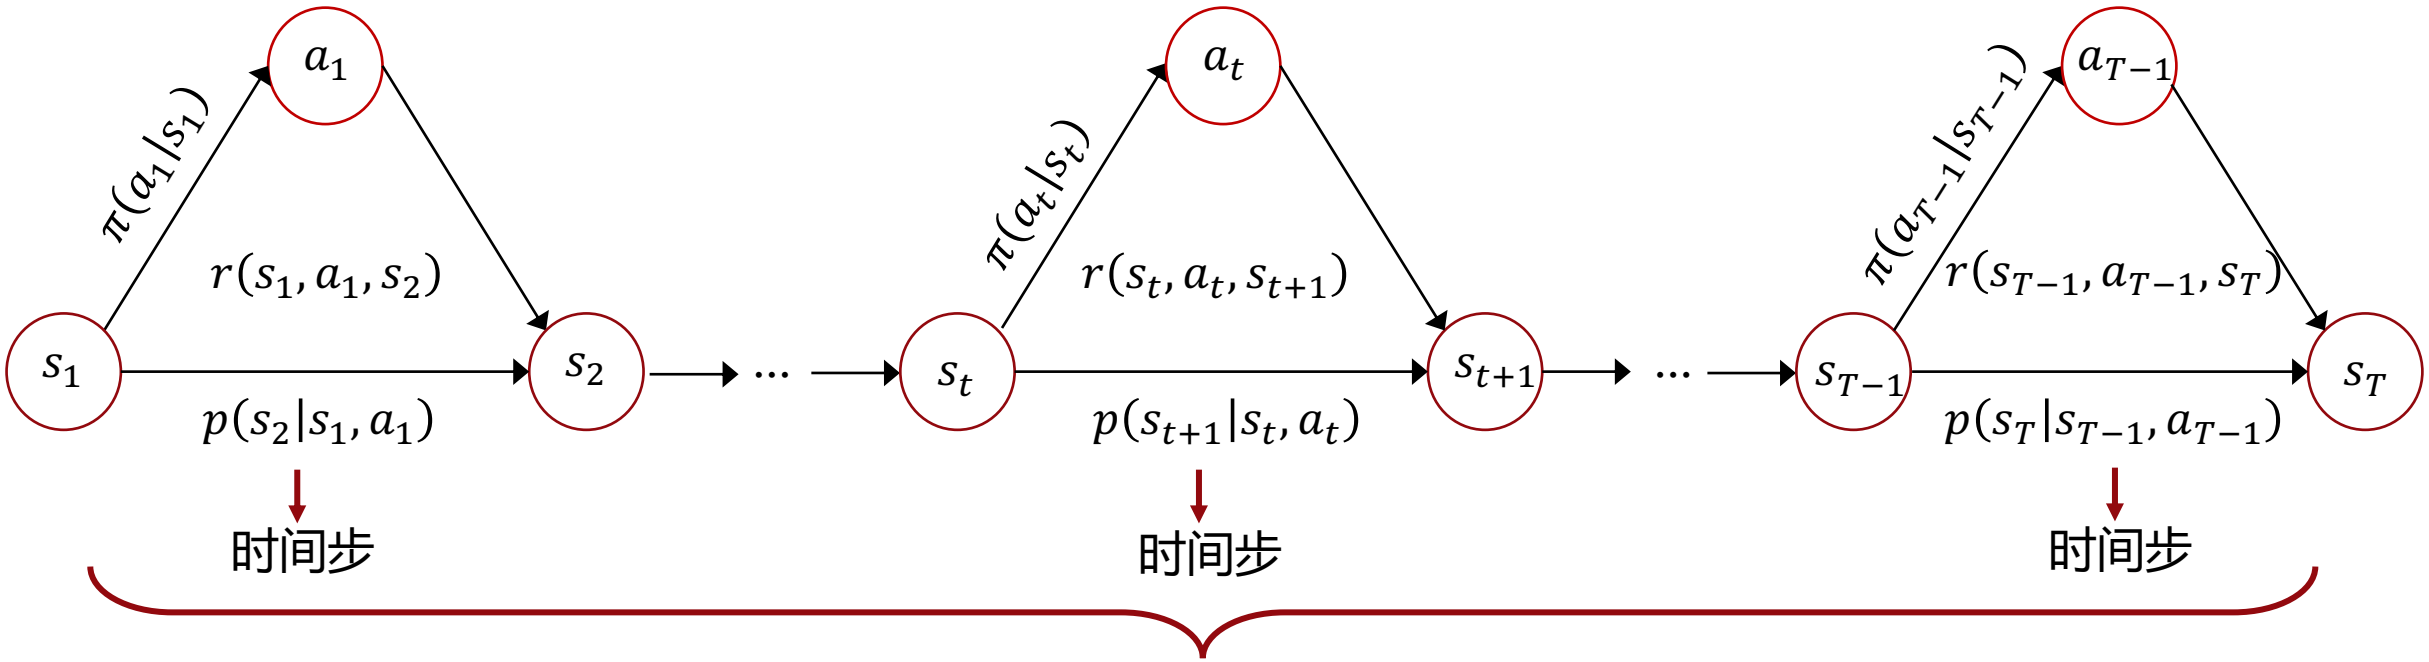
3) **转移概率P**：表示在执行某个动作后，从当前状态转移到另一个状态的概率。$p(s_{t+1}|s_t, a_t)$为状态转移概率，表示智能体在状态s_t执行动作a_t后转移到下一个状态s_{t+1}的概率。

4) **奖励函数R**：智能体在某个状态下执行某个动作后获得的即时奖励，用$r(s_t, a_t, s_{t+1})$表示。

5) **策略π**：它是一个从状态空间到行动空间的映射，定义了在每个状态s下应该采取哪个行动a。

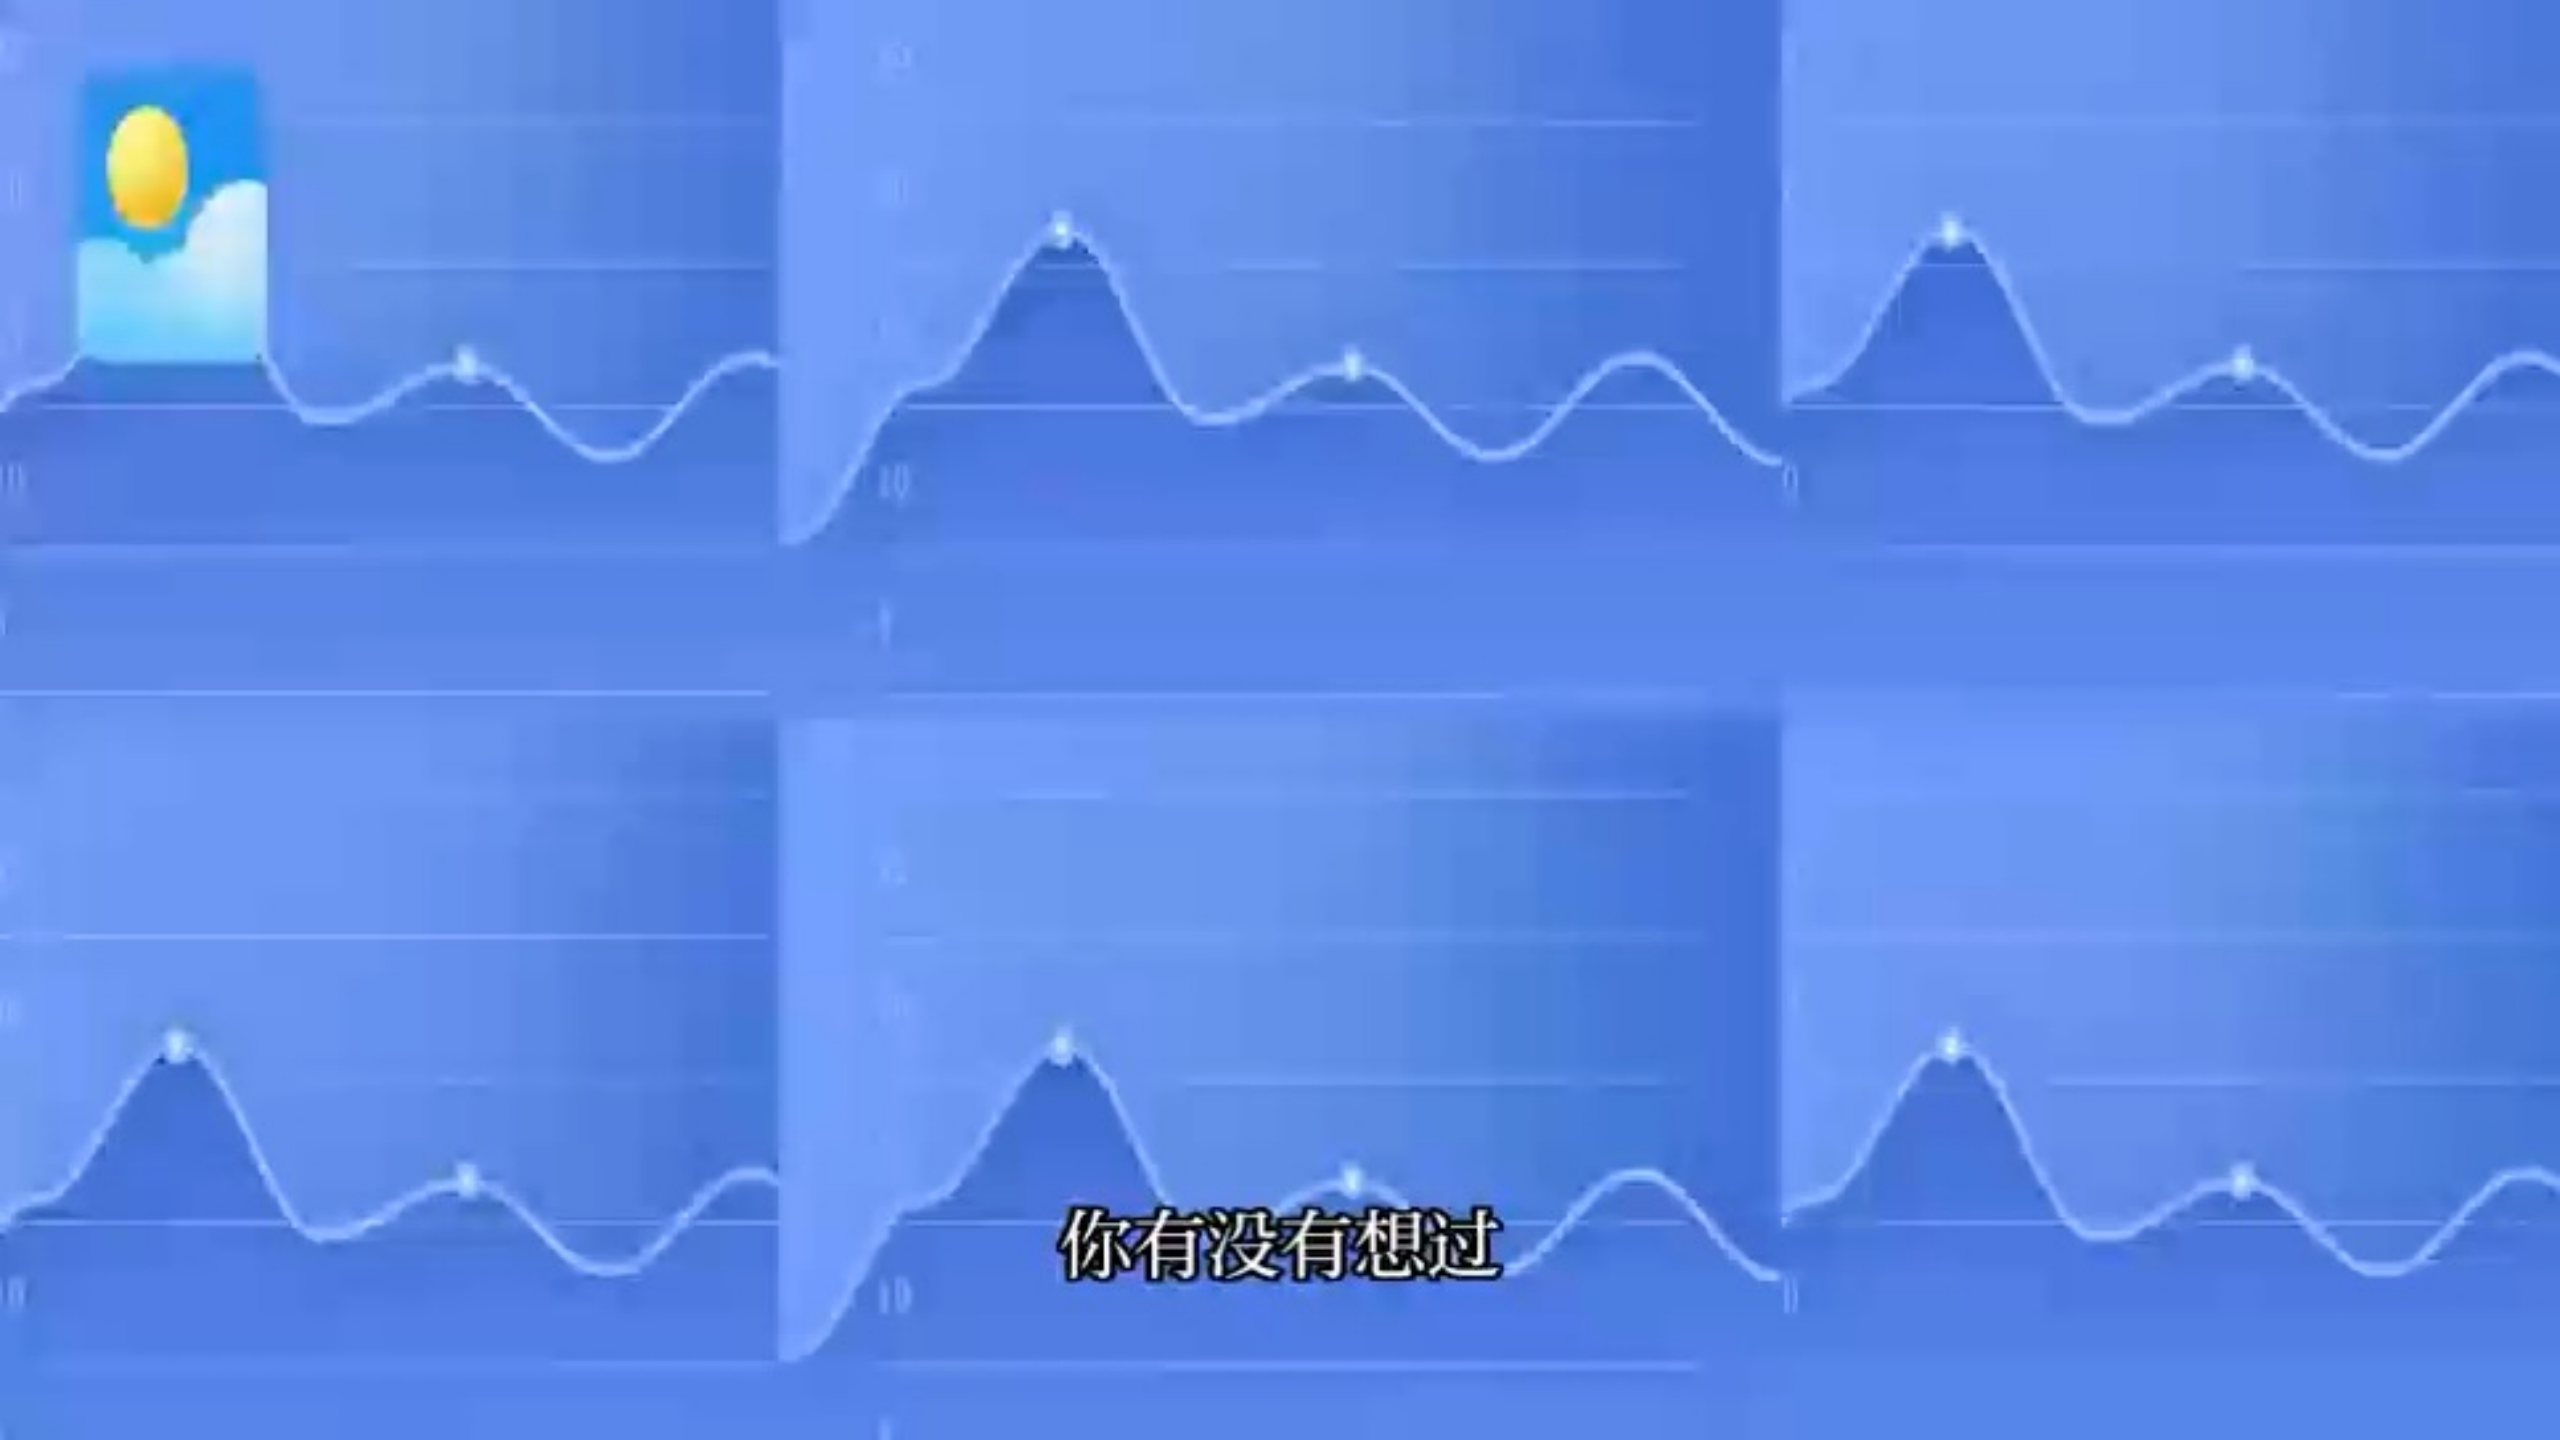
马尔可夫决策过程

智能体从起始状态s_1开始，根据策略π执行动作a_1，获得奖励r_1，并将状态转移到s_2，循环往复，直至到达终止状态（或满足某种终止条件）。

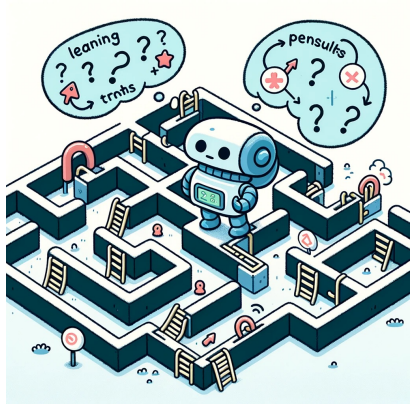


进行一次完整的交互过程称之为回合。

在这些时间步中，智能体会根据当前状态选择动作，执行动作后收到环境的反馈（即时奖励和下一个状态），直到回合结束。


你有没有想过

知识点2：解密贝尔曼方程



01 状态价值与动作价值

02 贝尔曼方程

从迷宫游戏看状态价值与动作价值

我们定义一个 3×3 迷宫游戏，包括起点（Start）、终点（End）、障碍物（#）与可通行区域（1）。游戏的任务是通过上下左右移动，从当前的某一位置最快到达终点。

Start		
#		
	End	

状态空间S：所有可能的位置。我们用坐标表示状态：起点$(1,1)$、终点$(3,2)$

动作空间A：智能体在当前状态可能执行的所有动作（如上、下、左、右）

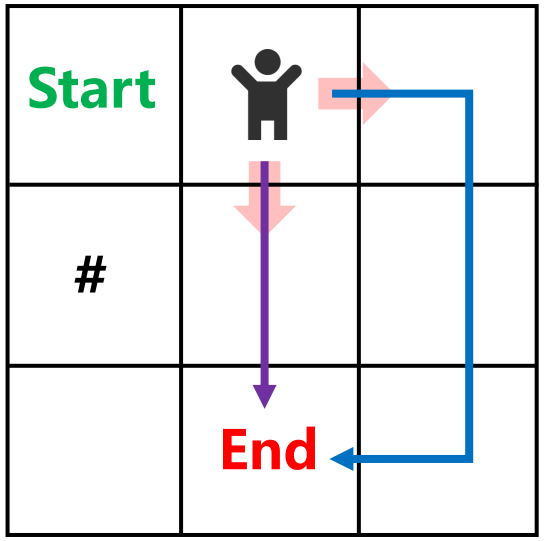
转移概率P：智能体从当前状态，通过动作a（如前进、后退、左转、右转）转移到下一状态的概率

奖励函数R：遇到障碍物奖励为-100，每移动到相邻格子奖励为-1，到达出口奖励为10，完成任务

策略π：以最大化奖励的方式，最快到达出口路径

核心目标是找到一个策略 $\pi(a|s)$，使得该策略能够最大化奖励，完成任务。

从迷宫游戏看状态价值与动作价值



以状态 (1,2) 为例，它可以向右 (1,3) 和向下 (2,2) 移动。

若向右移动，至少需要4步才能到达终点。则在这种情况下的最大奖励为：

$$10 + (-1)\times 4 = 6$$

若向下移动，需要至少2步才能到达终点。则在这种情况下的最大奖励为：

$$10 + (-1)\times 2 = 8$$

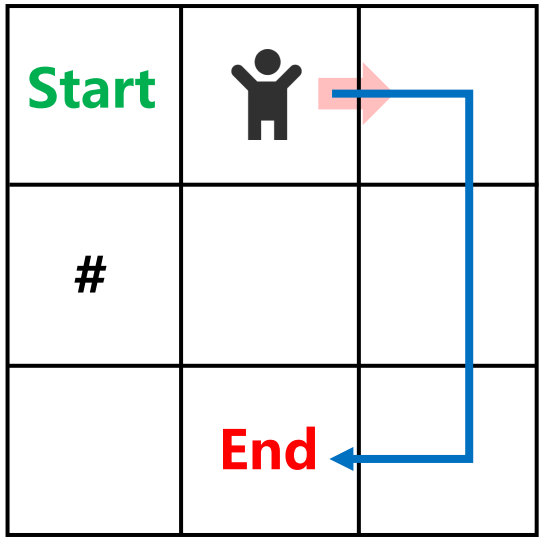
选择较大值 8 作为从状态 (1,2) 出发按照最优策略行动的期望奖励：

$$V(1,2) = 8$$



状态价值函数（State Value Function）它表示在给定一个状态下，按照某个策略行动所能获得的预期奖励。换句话说，状态价值函数衡量了在某个状态下，遵循某个策略时，能够从该状态开始所获得的期望累计奖励。

从迷宫游戏看状态价值与动作价值



以状态$(1,2)$为例，如果采取“向右”的动作，我们还可以计算：

- 即时奖励$R(1,2)$：右移一步-1，到达$V(1,3)$
- $V(1,3)$状态价值为$10+(-1)\times 3 = 7$

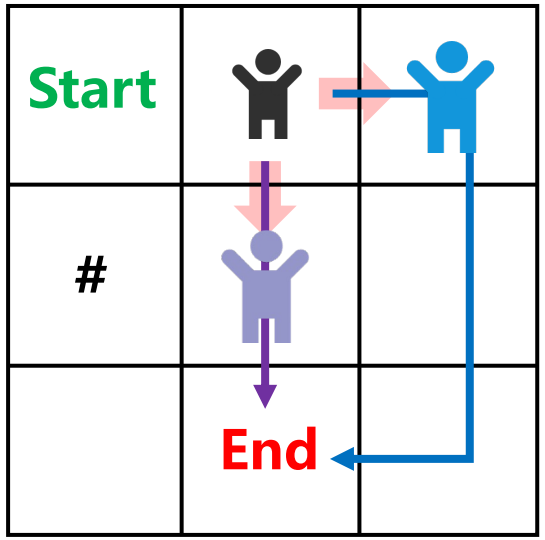
于是，我们采取“向右”动作的价值为：

$$Q(1,2) = R(1,2) + \gamma V(1,3) = -1 + 0.9\times 7 = 5.3$$



动作价值函数（Action Value Function）表示在当前状态下，执行某个动作后，按照最优策略继续行动所获得的期望累积奖励。

贝尔曼状态方程



以状态$(1,2)$为例，有“向右”和“向下”两个可行动作

- 采取“向右”动作，到达状态$(1,3)$，转移概率$P((1,3)|(1,2),右)=1$，
- $V(1,3)$状态价值为$10+(-1)\times 3=7$

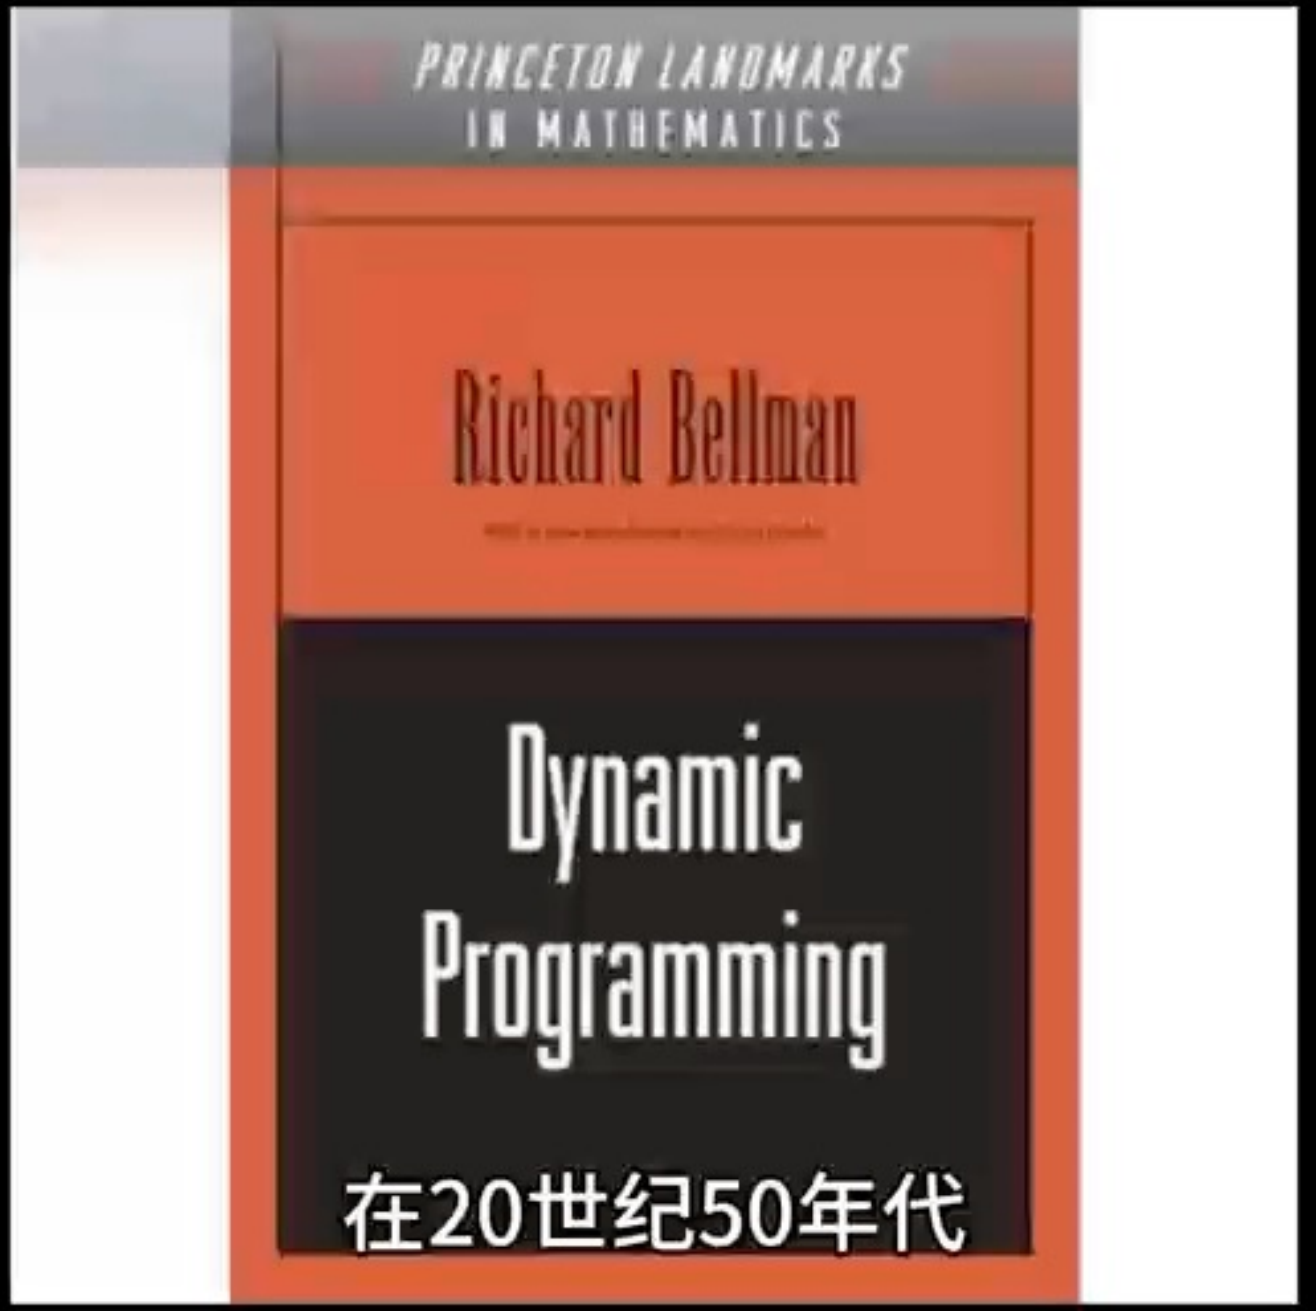
动作价值： $R(1,2)+\gamma P((1,3)|(1,2),右)\ V(1,3)=-1+0.9\times 1\times 7=5.3$

- 采取“向下”动作，到达状态$(2,2)$，转移概率$P((2,2)|(1,2),下)=1$，
- $V(2,2)$ 状态价值为$10+(-1)\times 1=9$

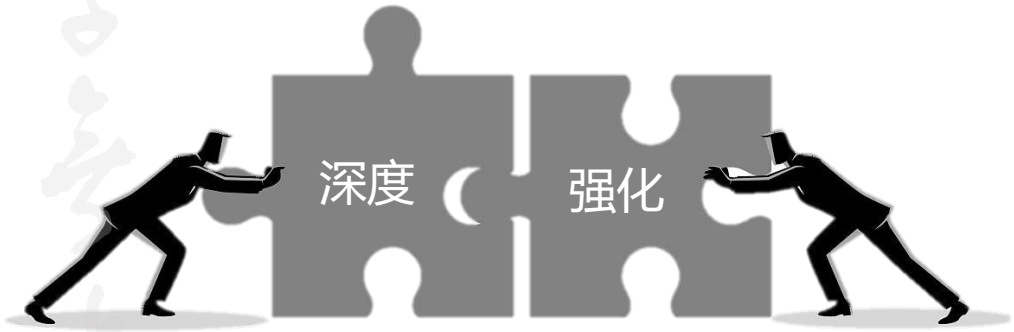
动作价值： $R(1,2)+\gamma P((2,2)\,|\,(1,2),下)\ V(2,2)=-1+0.9\times 1\times 9=7.1$

⋮

控制初学者 bilibili



知识点3：当深度学习遇到强化学习

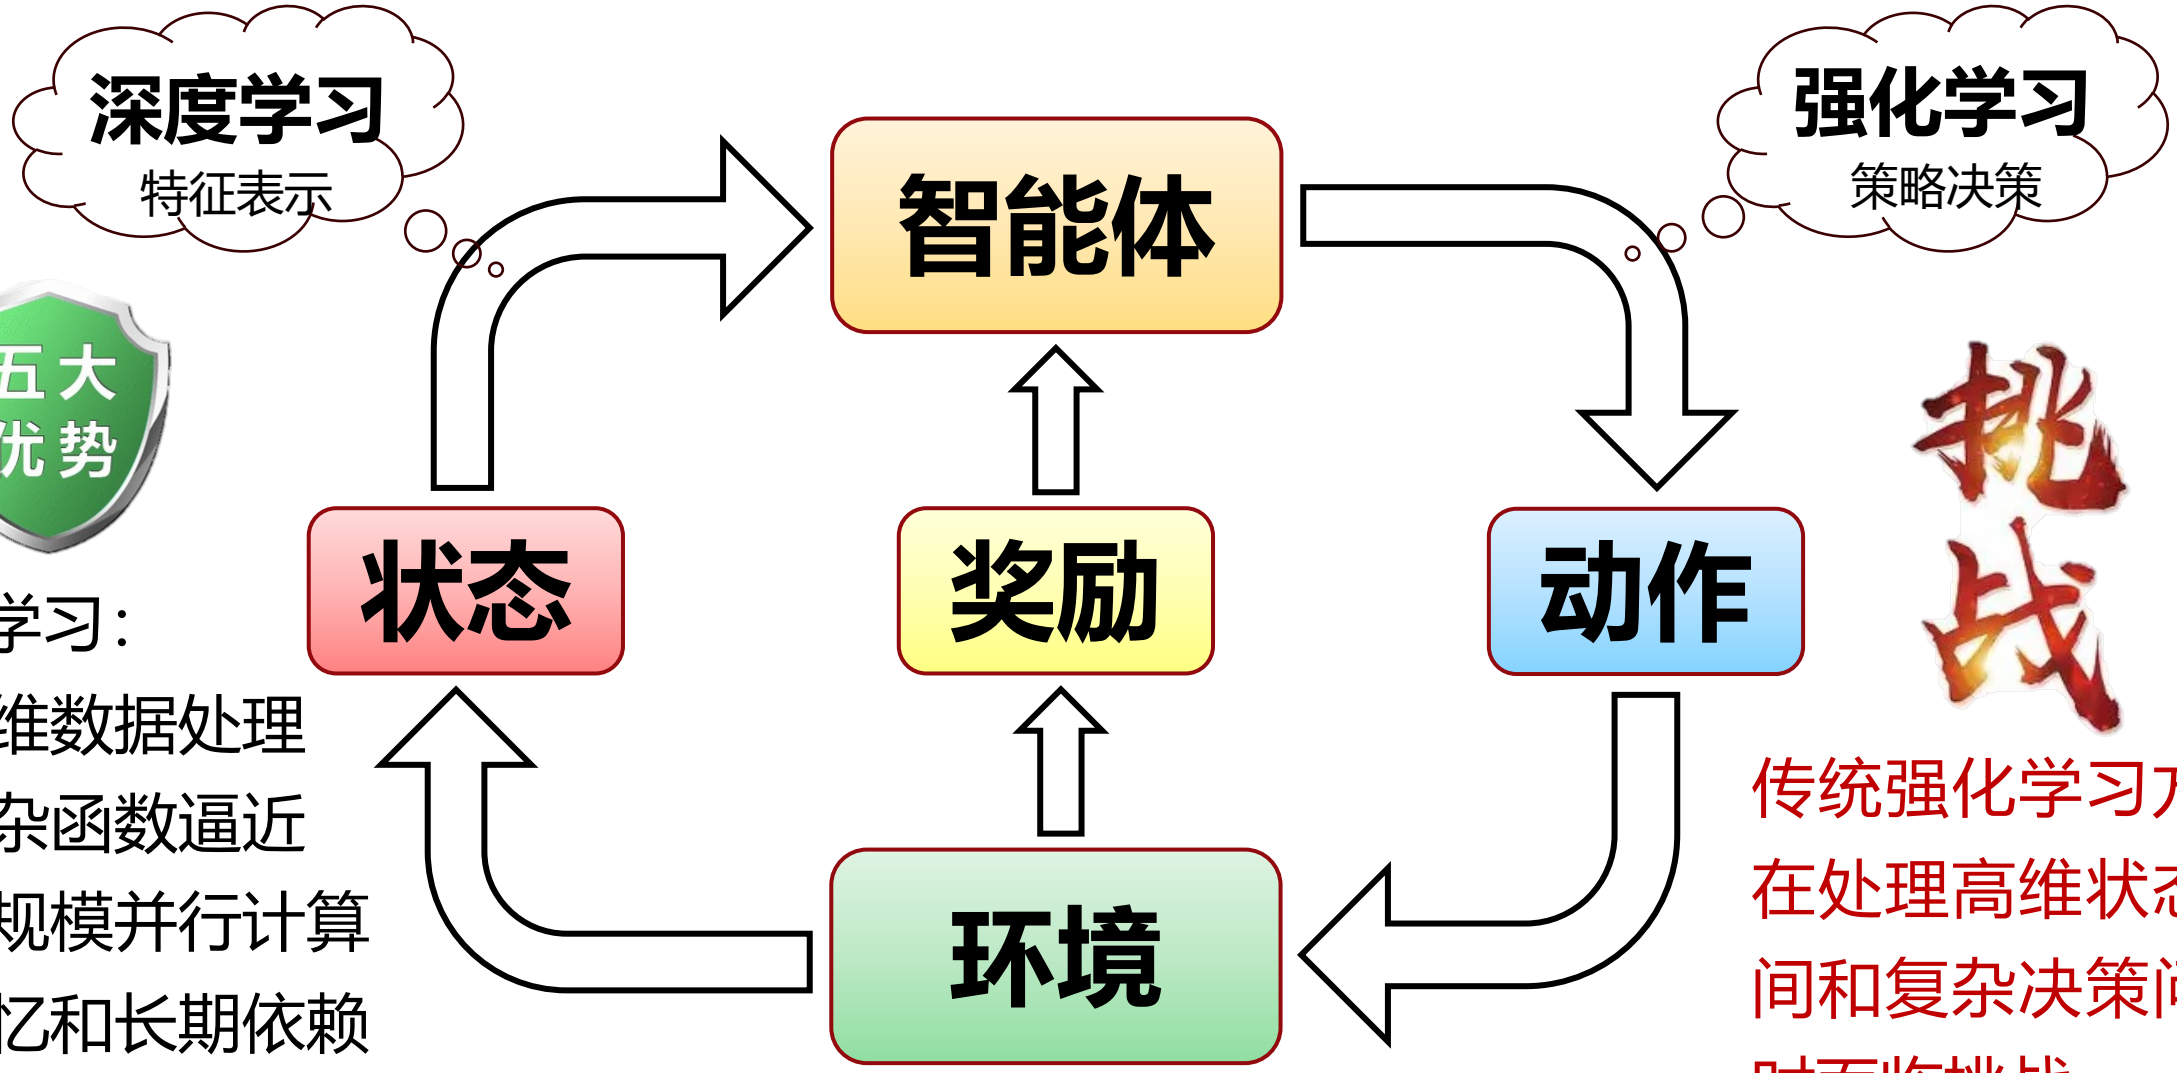


01 深度强化学习概念

02 深度强化学习方法


C:/FILE 26.06.1998
MY VLOGGING LIFE

什么是深度强化学习



五大优势

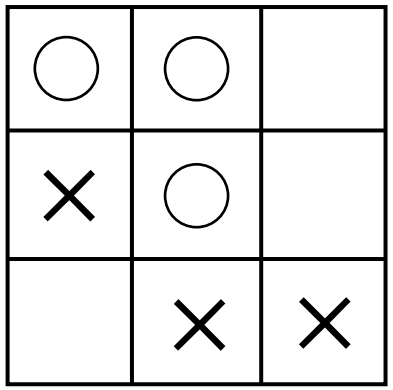
深度学习：

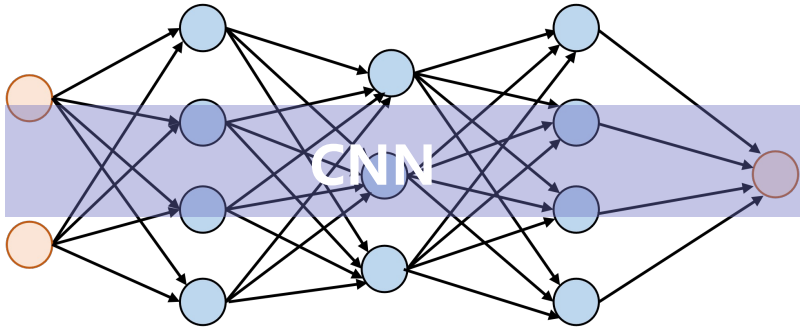
- ✓ 高维数据处理
- ✓ 复杂函数逼近
- ✓ 大规模并行计算
- ✓ 记忆和长期依赖
- ✓ 泛化能力

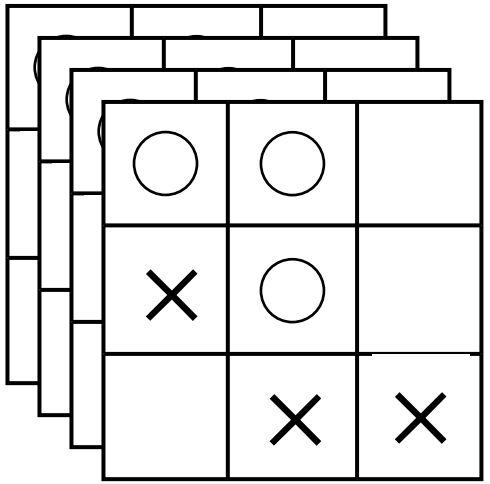
挑战

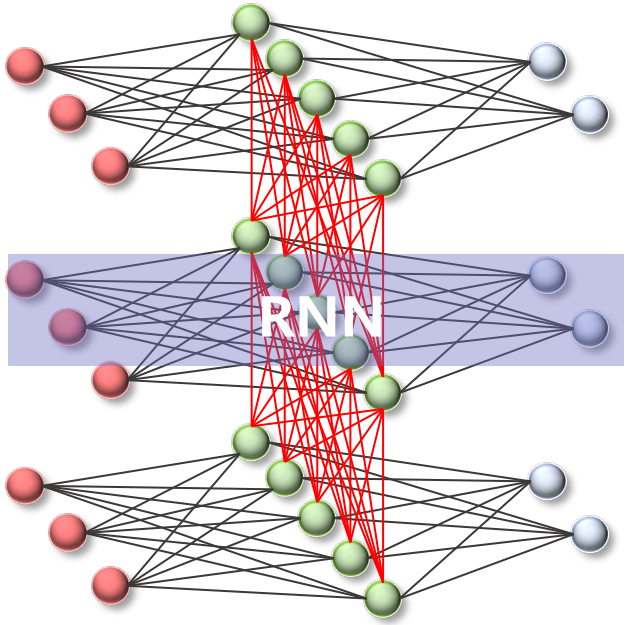
传统强化学习方法在处理高维状态空间和复杂决策问题时面临挑战。

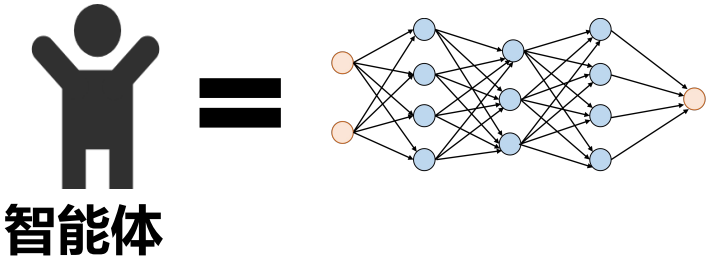
使用神经网络构建强化学习主体的方法被称为深度强化学习

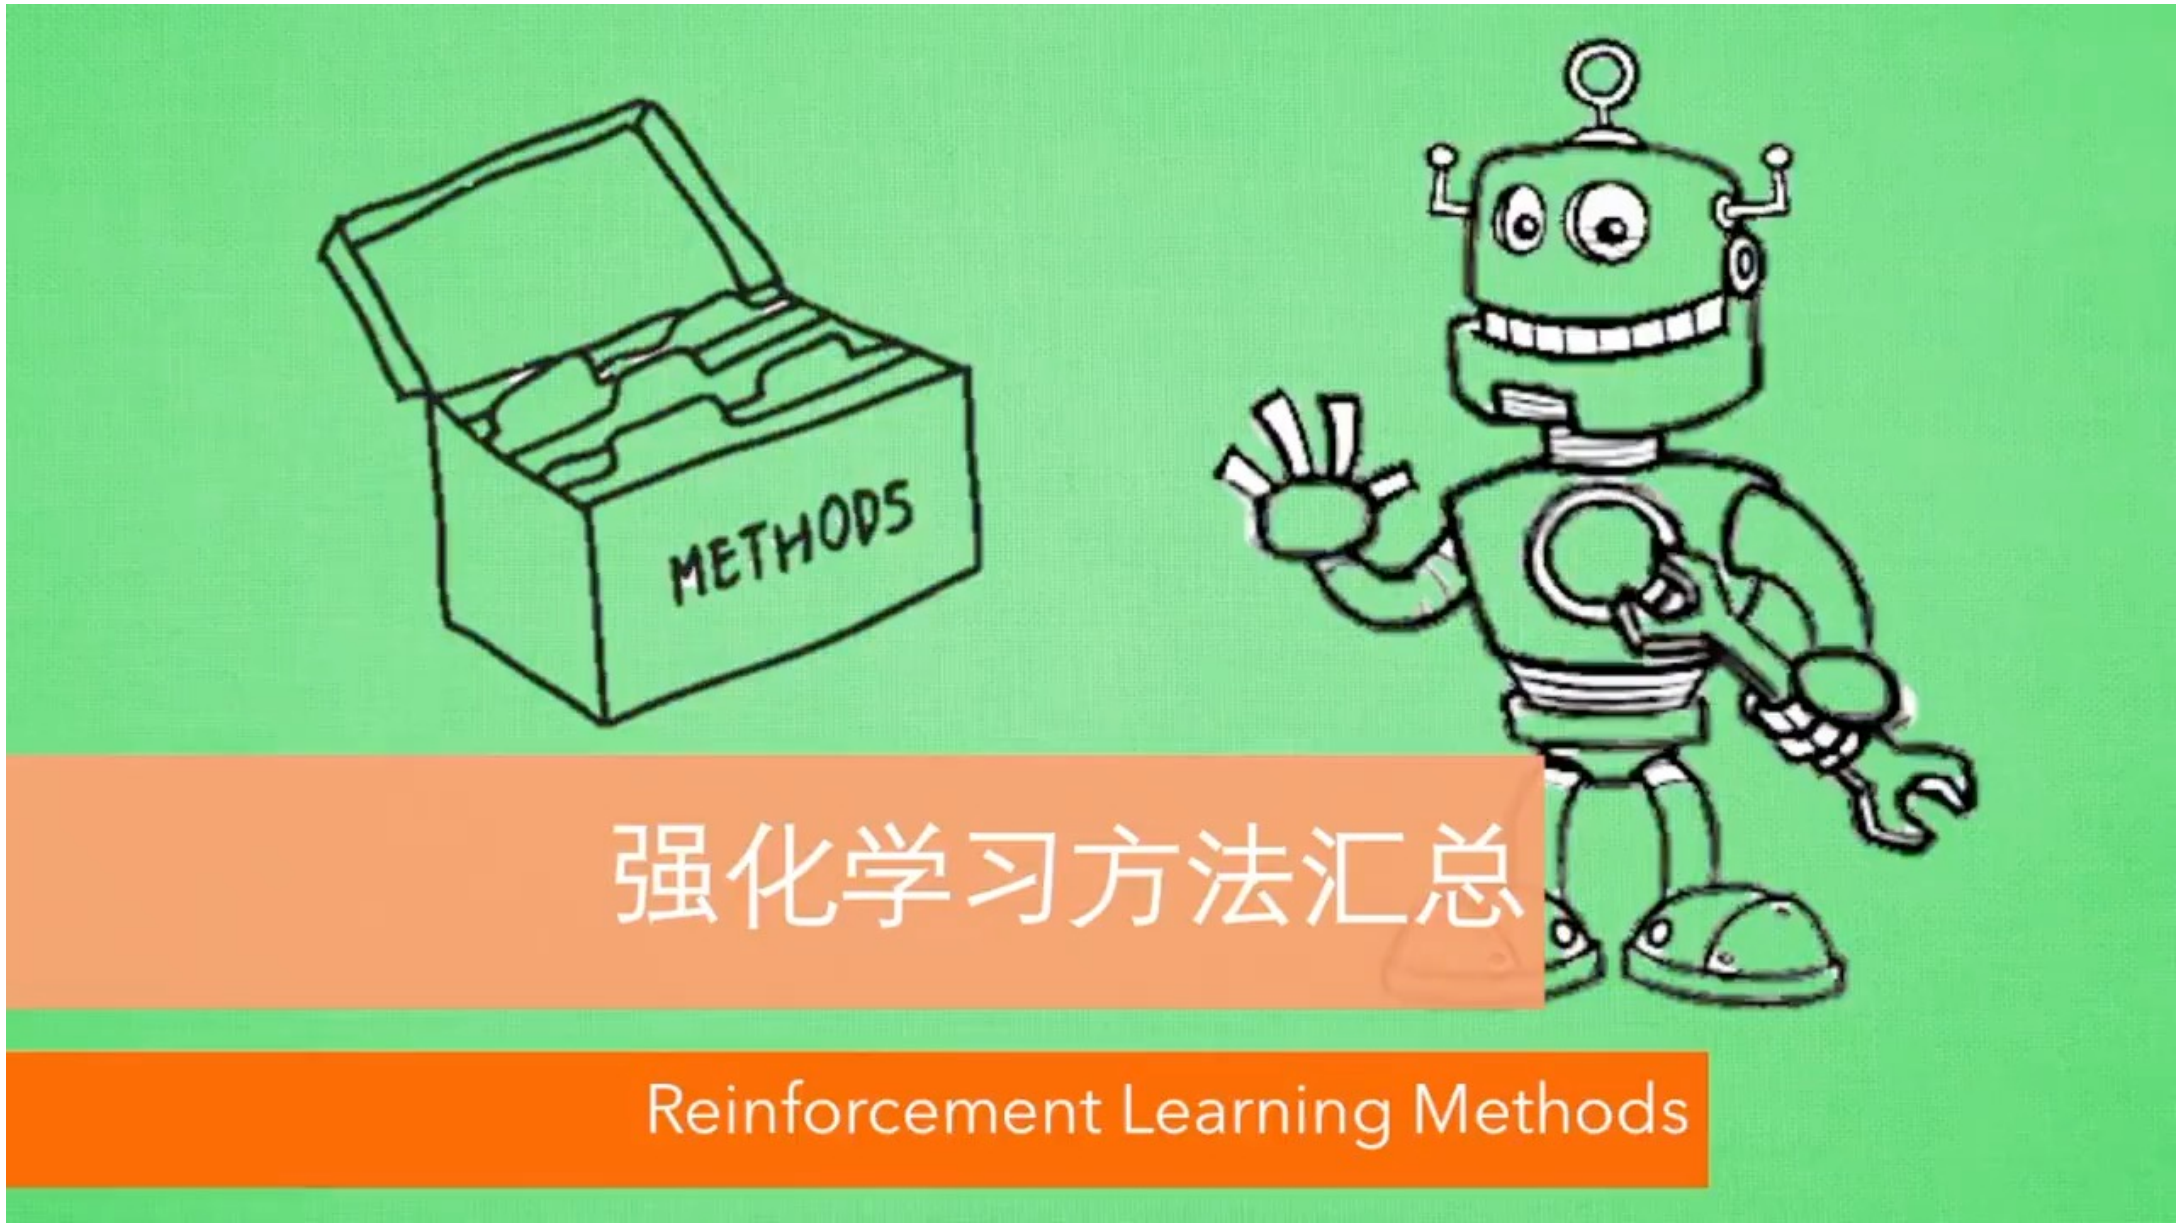











METHODS
强化学习方法汇总
Reinforcement Learning Methods

■ 基于价值的方法

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$



DQN方法

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$

=

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$



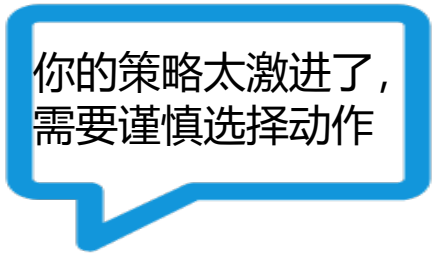
Atari 2600游戏

Double-DQN

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$

+

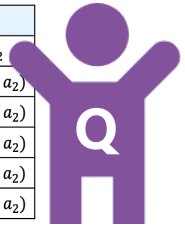




价值 **动作**

=

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$





星际争霸II

■ 基于策略的方法

策略梯度方法

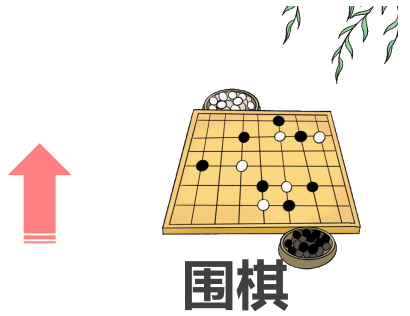


策略选择动作



梯度上升

P（动作）



围棋

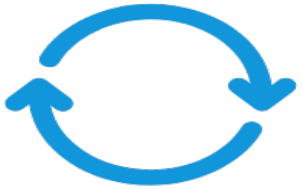
演员-评论家算法





Actor

选择动作

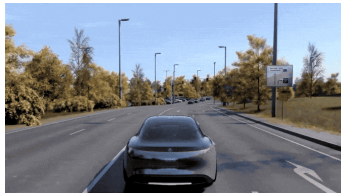


价值评估



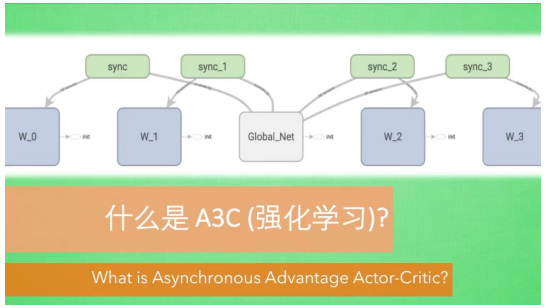
Critic

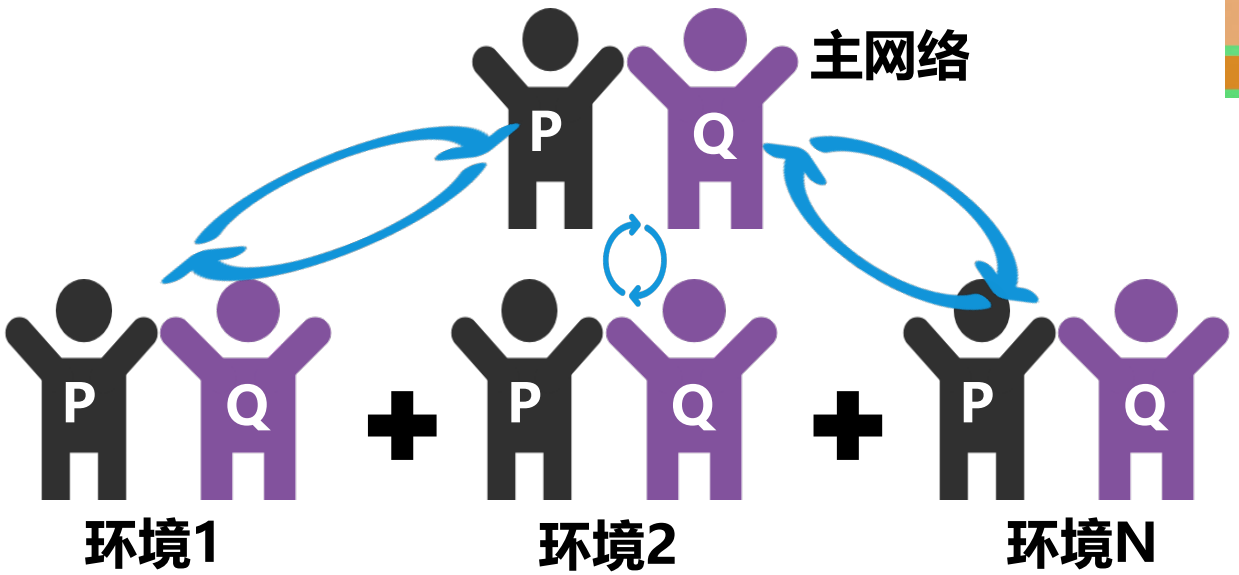
用 Critic 的反馈来优化 Actor 的策略



自动驾驶

■ 基于策略的方法　A3C方法

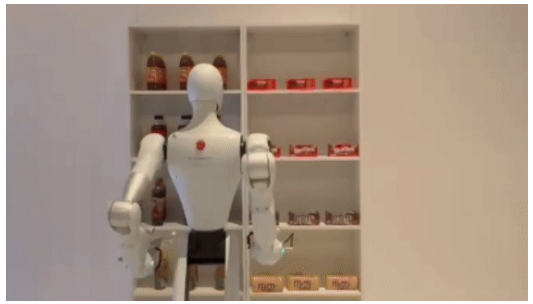


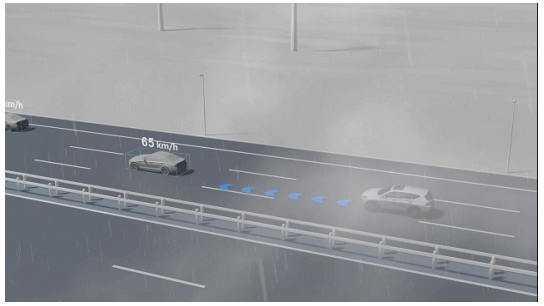


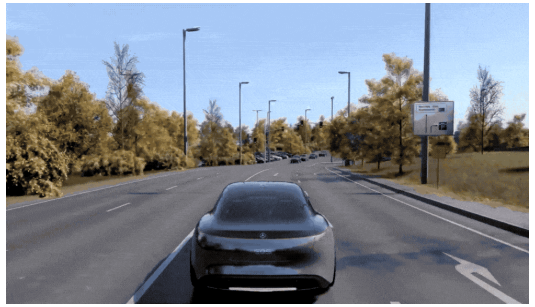
多个 Actor 独立与环境交互并异步更新全局网络

深度强化学习应用

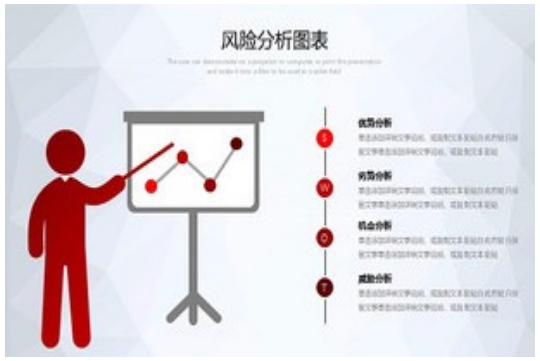


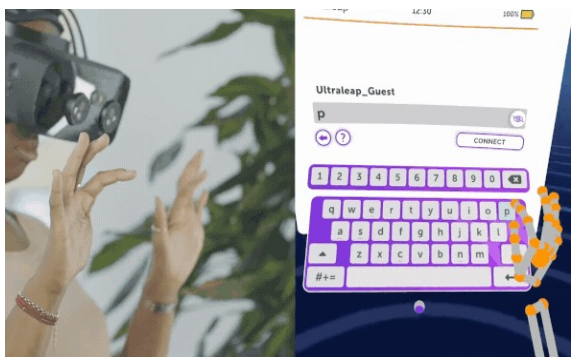




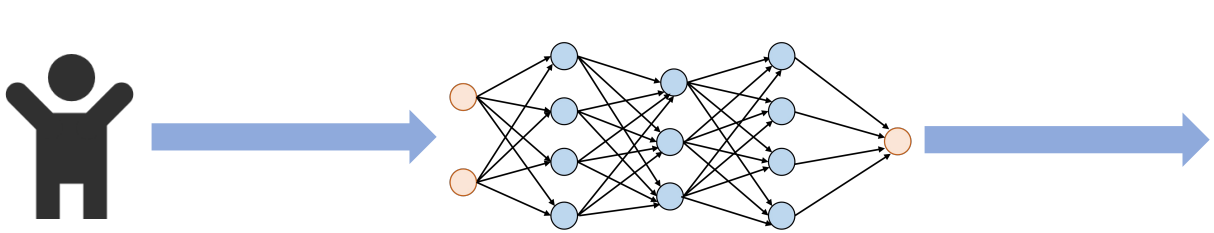












智能体　　神经网络　　决策输出

知识点4：智能机器人与强化学习



01 AlphaGo的启示

02 机器人的“学习革命”

AlphaGo的启示



《机器人总动员》



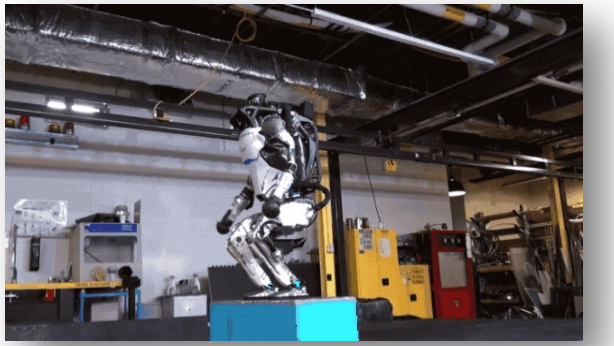
《超能查派》



这些机器人是如何学会行动的呢？

虚拟 VS 现实

强化学习！



波士顿动力机器人Atlas



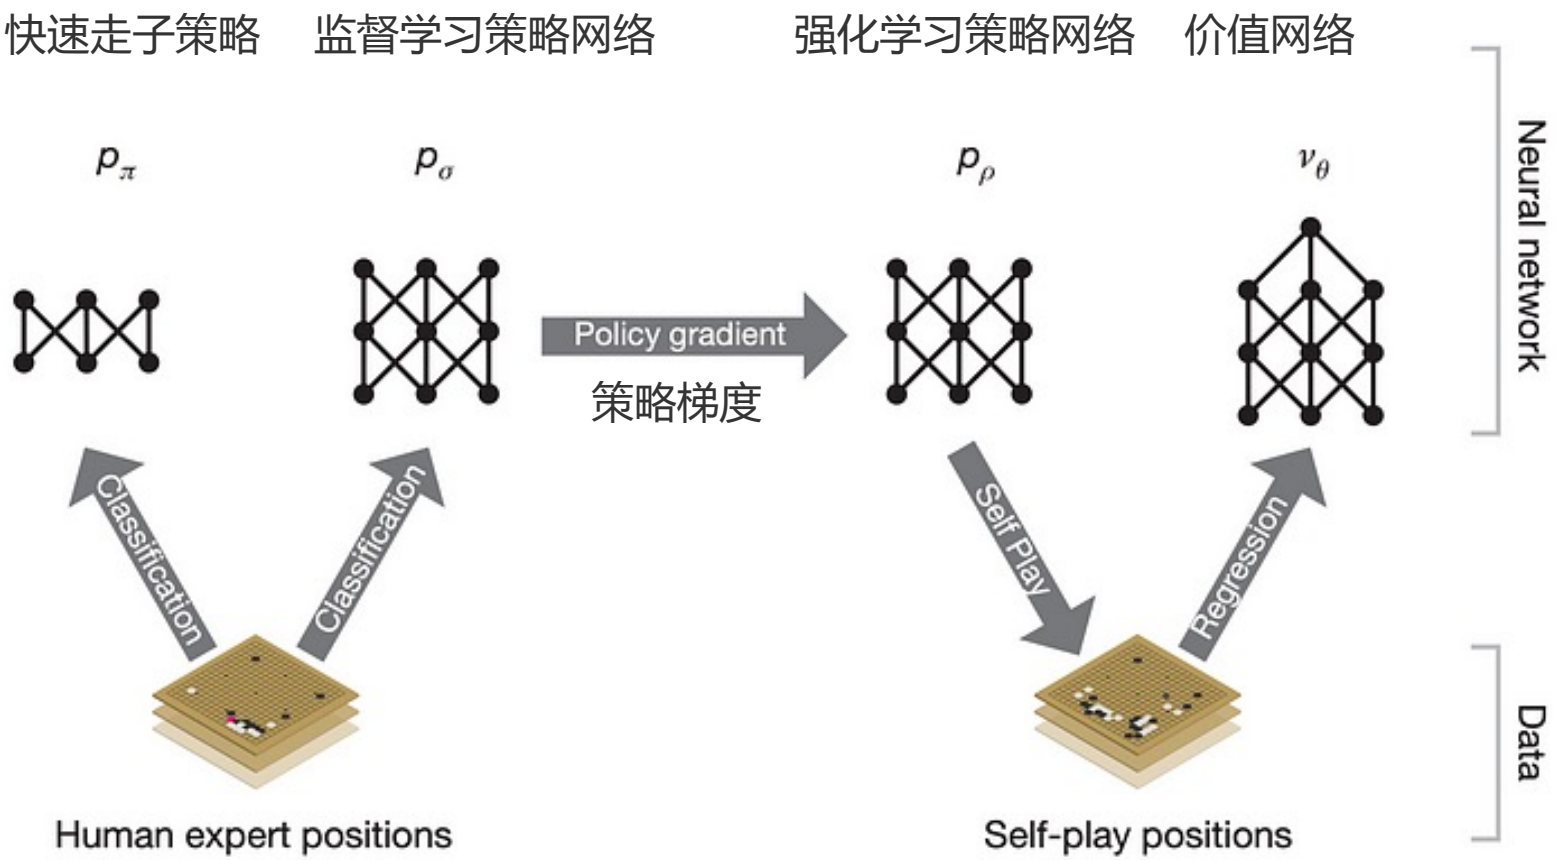
AlphaGo大战李世石

围棋有10^{170}种可能性，AlphaGo如何“算”出最优解?

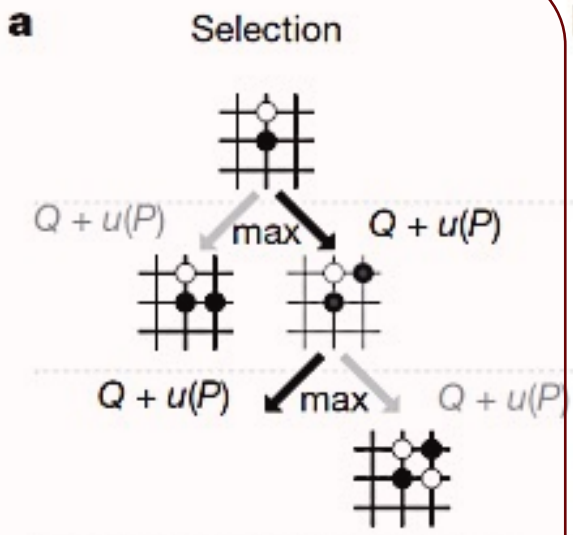
强化学习

蒙特卡洛树搜索

制胜法宝

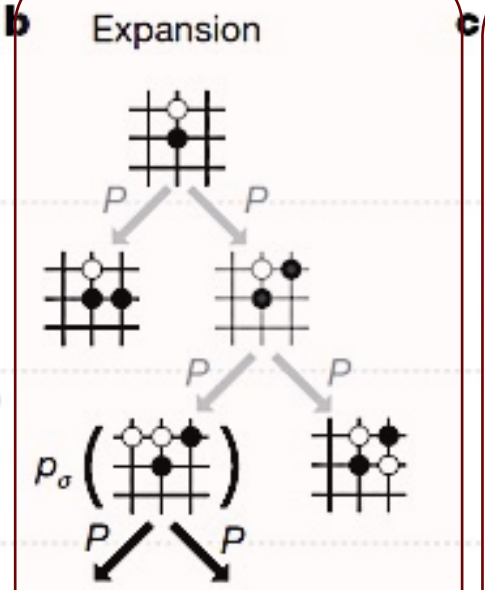


AlphaGo的启示



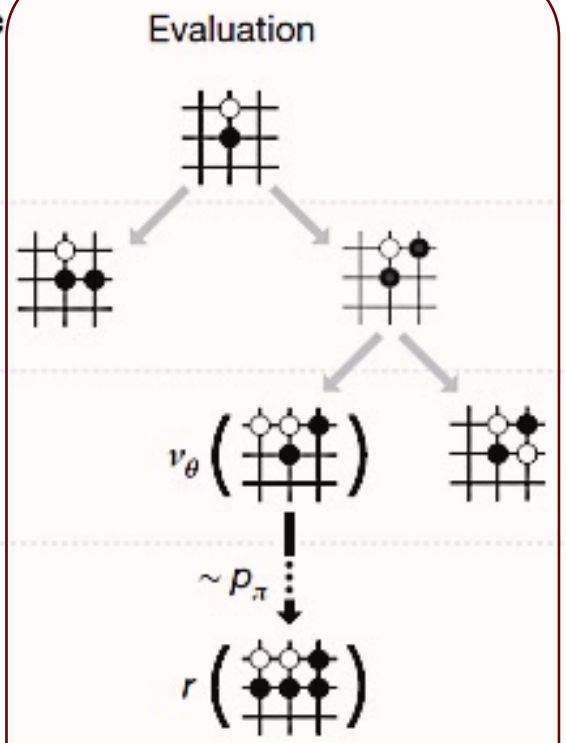
选　择

从根节点开始，选择最有潜力的子节点。根节点为当前棋盘状态。



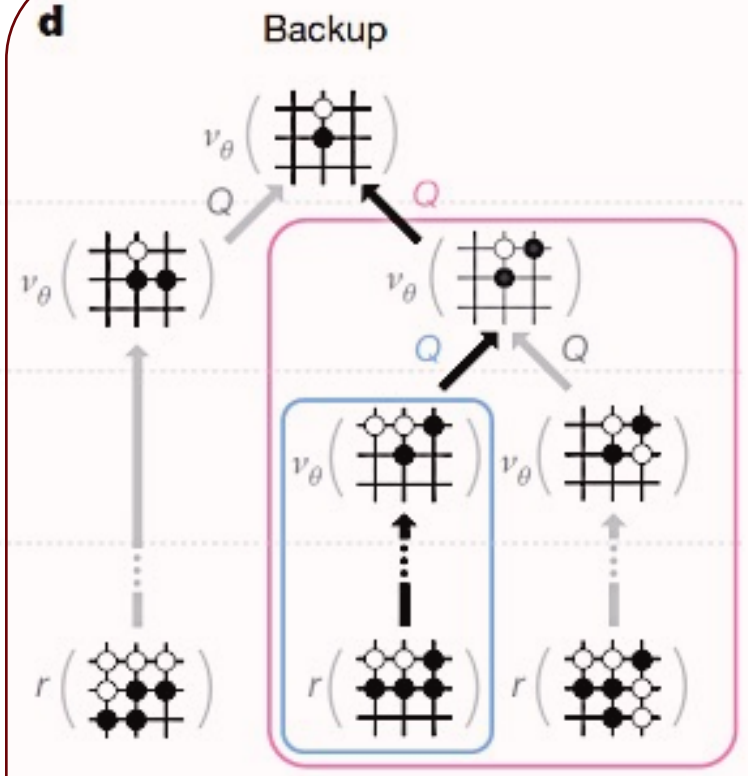
扩　展

如果叶节点不是终局状态，使用策略网络生成候选动作，并扩展搜索树。



评　估

使用价值网络评估叶节点的胜率。

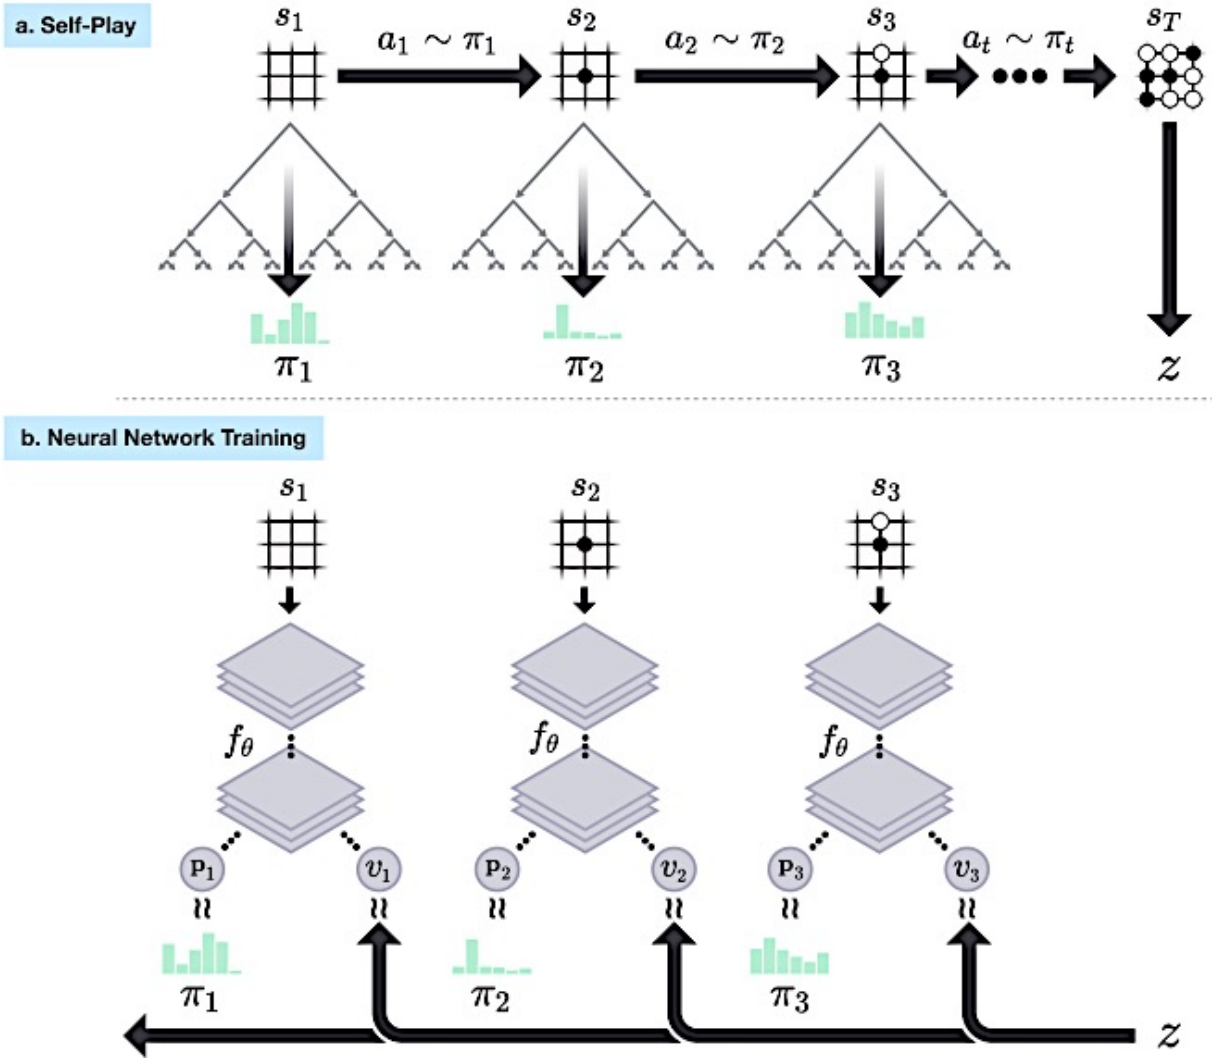


回　溯

将评估结果反向传播，更新搜索树中所有节点的统计信息（如访问次数、胜率）。

AlphaGo的启示

AlphaGo Zero完全抛弃人类棋谱，100:0 完胜AlphaGo

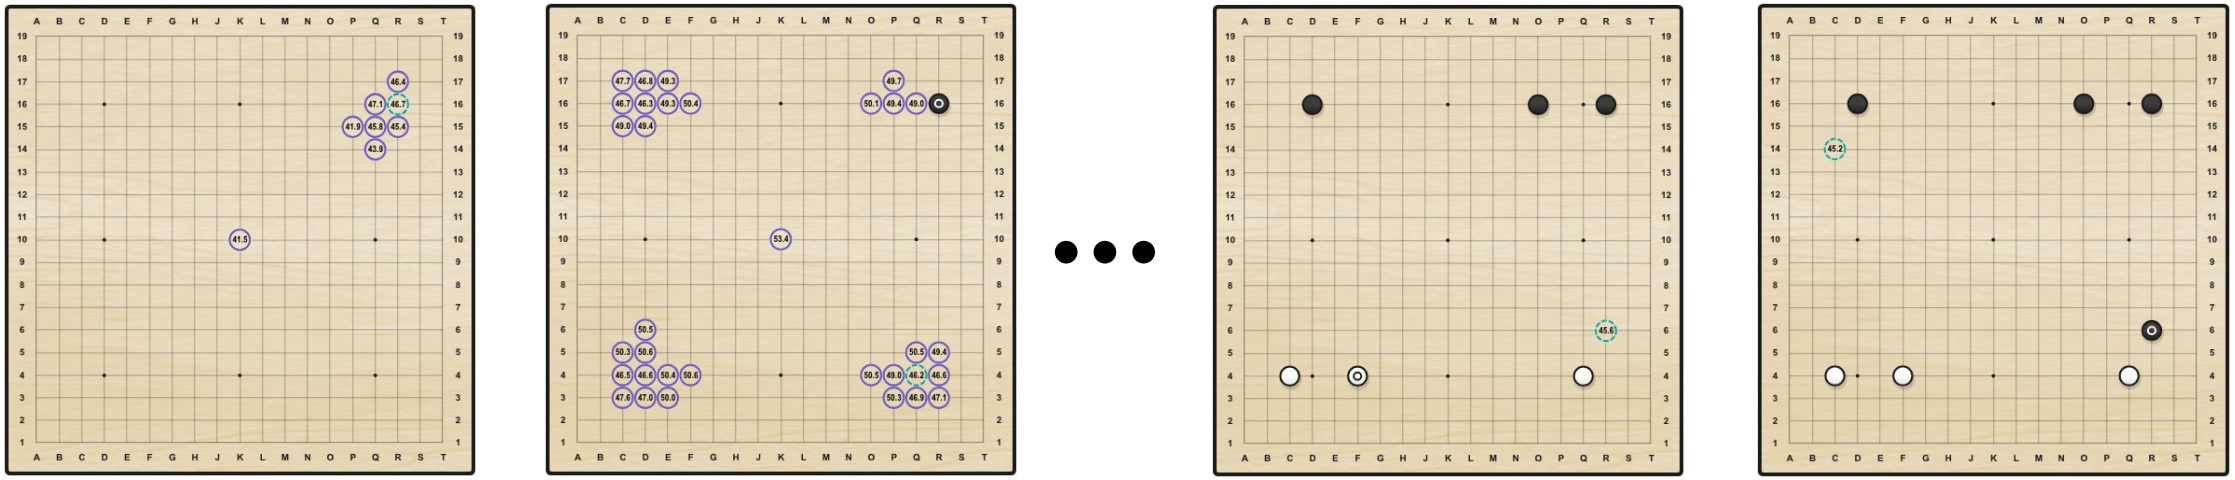


- **无人类数据**：完全从零开始学习，不依赖任何人类棋谱。通过自我对弈和蒙特卡洛树搜索生成高质量的训练数据，提升学习效率。
- **单一网络**：使用一个统一的神经网络同时预测策略和值函数，简化了模型结构。
- **残差网络**：深度残差网络提升模型表达能力。



AlphaGo的启示

AlphaGo围棋教学上线，人类围棋进入AI时代

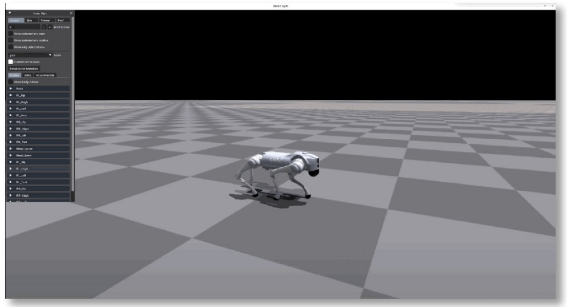


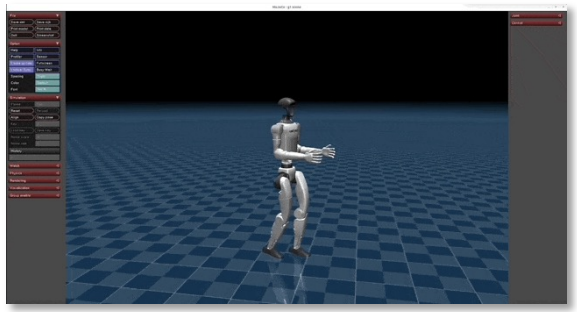
AlphaGo的成功带来哪些启示呢?

- ✓ 机器可以**从零开始**超越人类千年积累的经验。
- ✓ 解决了传统AI依赖标注数据的瓶颈，开创了**无监督强化学习**的新范式。
- ✓ 实现了**虚拟与现实的动态交互**，通过无监督学习与环境交互实现通用智能。

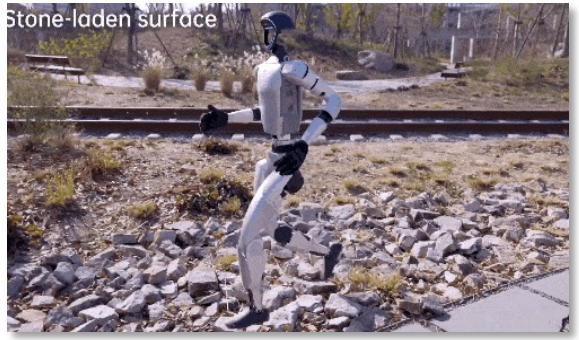
机器人的“学习革命”

■ 机器人训练场（行走篇）：如何让机器人适应未知地形?













在虚拟环境中模拟机器人行走

仿真训练：数千次虚拟跌倒 → 学习平衡策略

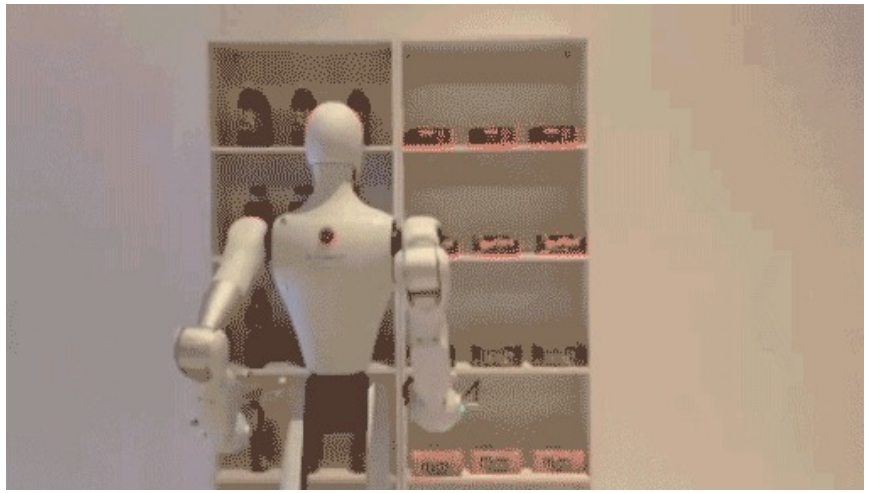
奖励函数：

- **基础奖励**：保持平衡 + 前进速度
- **“好奇心”奖励**：鼓励探索新地形

Sim2Real（仿真到真实的迁移）

域自适应、域随机化，随机化虚拟环境参数（摩擦系数、地形高度）提升泛化性

■ 机器人训练场（抓取篇）：抓取物体





稀疏奖励：仅当成功抓取时给予奖励

自监督预训练：从随机抓取中学习物理特性

离散动作：抓取/松开、移动方向

连续动作：夹持器开合力度、6自由度位姿调整

增加内在奖励，鼓励探索新状态（如触碰未知物体表面）

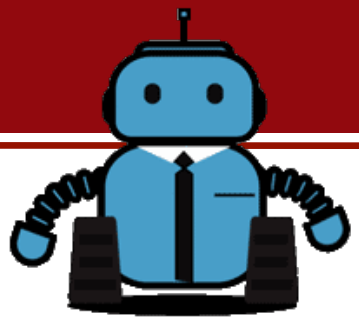


仿真中随机化物体质量、摩擦系数、光照条件，提升泛化性

持续生成新物理参数，防止过拟合

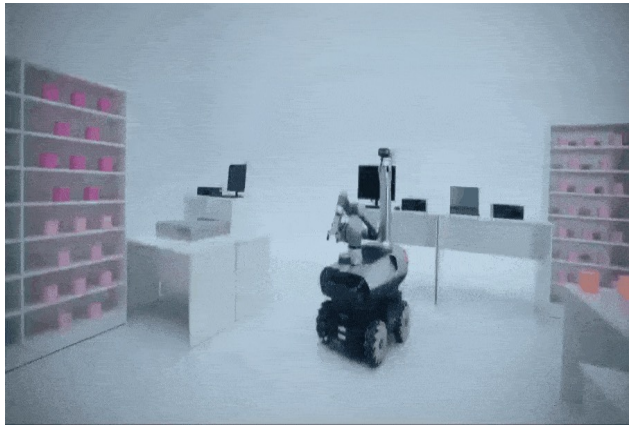
层级强化学习：高层规划旋转步骤，底层控制手指微调

机器人的“学习革命”

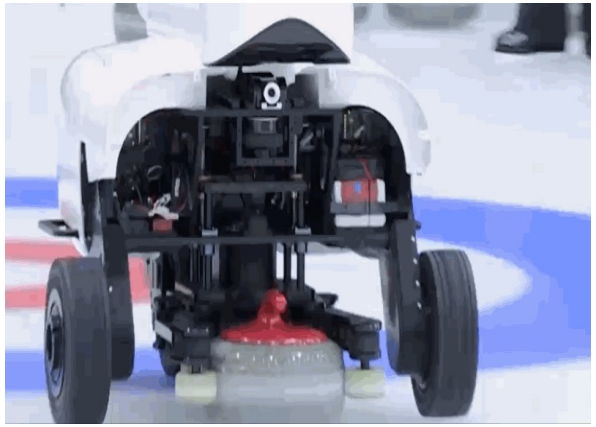


■ 未来趋势



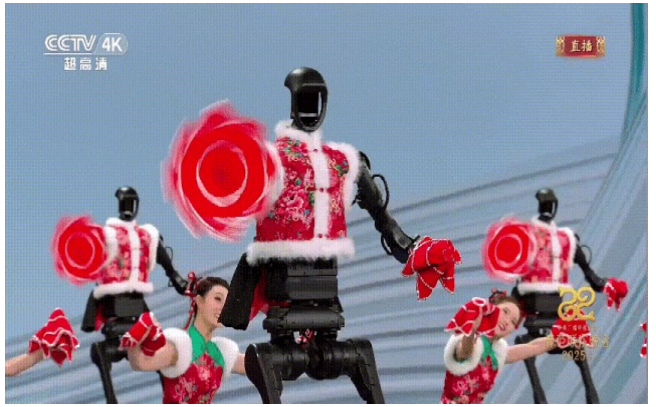


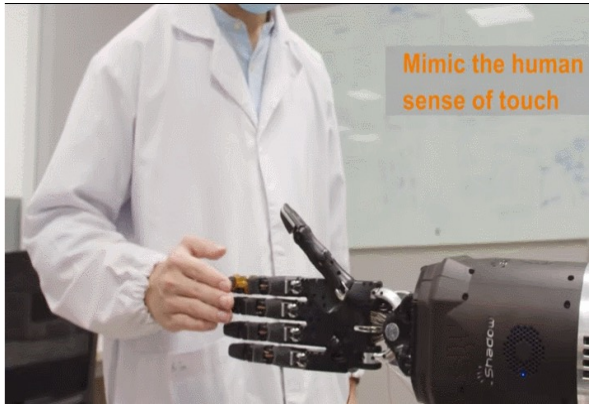












✓ 精细操作　✓ 群体智能　✓ 可变结构　✓ 人机交互　✓ 脑机接口

山东大学
SHANDONG UNIVERSITY

《人工智能通识》AI For Everyone

强化学习

学无止境 气有浩然

教育部-华为“智能基座”课程