



北京交通大学《深度学习》课件
教育部产学合作协同育人项目资助

第一讲 絮论

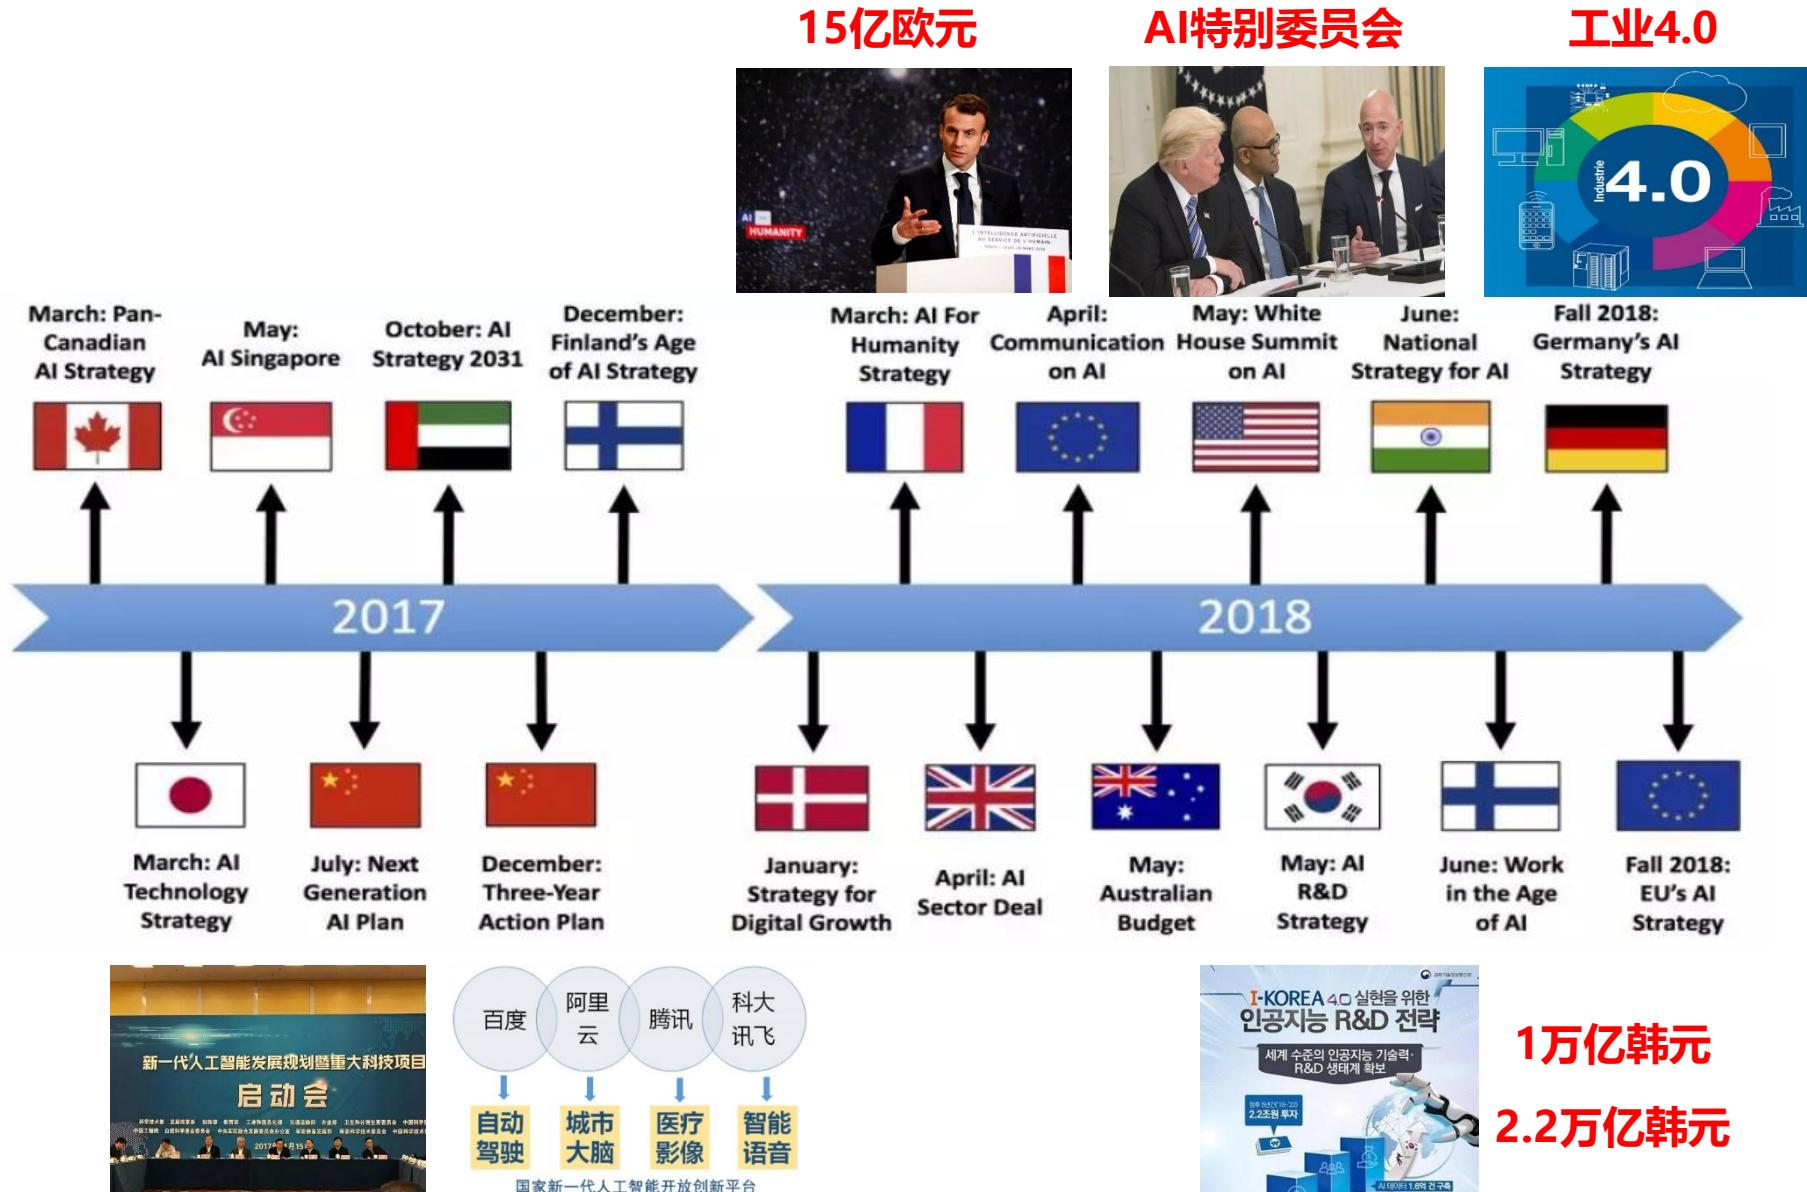
主讲教师：丛润民



1. 人工智能和机器学习概述

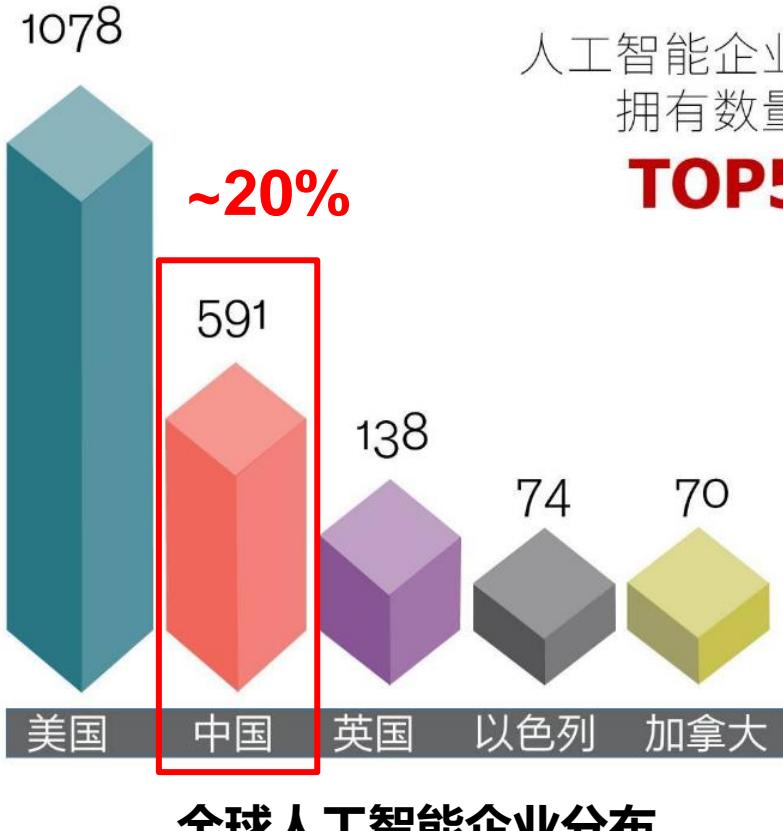


人工智能军备竞赛

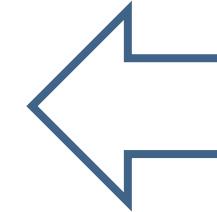




人工智能人才缺口



人工智能企业
拥有数量
TOP5



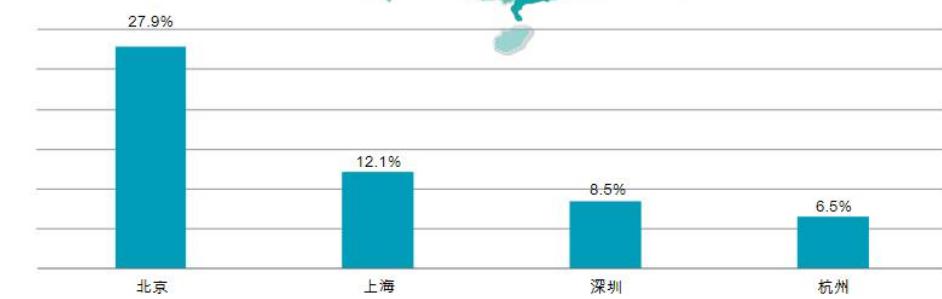
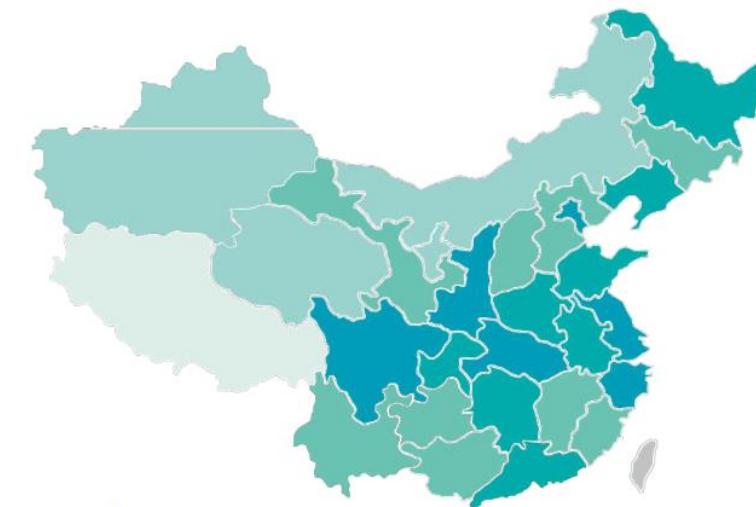
具有人工智能研究方向的高校
(总数: 367, 每年输出人才: 2万)

资料来源: 《2017全球人工智能人才白皮书》



人工智能人才缺口

	特点	科研院校	政府或科研机构与院校实验室	企业实验室
北京	<ul style="list-style-type: none"> • 科研技术实力最为雄厚 	占据全国50%以上： <ul style="list-style-type: none"> • 清华大学 • 北京大学 • 北京航空航天大学 • 中科院自动化所 	超过10个： <ul style="list-style-type: none"> • 模式识别国家重点实验室 • 智能技术与系统国家重点实验室 • 深度学习技术及应用国家工程实验室 • 清华大学人工智能研究院 • 北京大学法律与人工智能实验室 	<ul style="list-style-type: none"> • 360 • 百度 • 小米 • 美团 • 京东 • 创新工场 • 今日头条 • 联想 • 优必选
上海	<ul style="list-style-type: none"> • 主要依靠高校，企业研究院/实验室虽低于北京，但奠定了一定的学术基础 	众多高校资源： <ul style="list-style-type: none"> • 上海交通大学 • 复旦大学 • 上海同济大学 	<ul style="list-style-type: none"> • 上海交大-Versa脑科学与人工智能联合实验室 • 中科院自动研究所与松鼠AI联合成立平行AI智适应联合实验室 	<ul style="list-style-type: none"> • 上汽集团 • 飞利浦 • 商汤科技 • 腾讯 • 乂学教育-松鼠AI • 微软
深圳	<ul style="list-style-type: none"> • 主要依靠企业 	<ul style="list-style-type: none"> • 深圳大学 • 深圳南方科技大学 	主要为政府主导： <ul style="list-style-type: none"> • 深圳智能机器人研究院、 • 深圳人工智能与大数据研究院 	<ul style="list-style-type: none"> • 腾讯 • 华为 • 中兴
杭州	<ul style="list-style-type: none"> • 与北上深仍有一定差距 	<ul style="list-style-type: none"> • 浙江大学 		<ul style="list-style-type: none"> • 阿里巴巴 • 网易 • 吉利汽车



资料来源：公开资料，德勤研究

资料来源：《2019全球人工智能人才白皮书》



人工智能高等教育

2017.07

国务院关于印发新一代人工智能发展规划的通知

国发〔2017〕35号

各省、自治区、直辖市人民政府，国务院各部委、各直属机构：

现将《新一代人工智能发展规划》印发给你们，请认真贯彻执行。

加快培养人工智能高端人才

- 完善人工智能教育体系，加强人才储备和梯队建设，形成我国人工智能高地

2018.04

教育部文件

教技〔2018〕3号

教育部关于印发《高等学校人工智能 创新行动计划》的通知

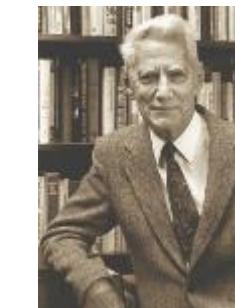
- 推动人工智能一级学科建设
- 到2020年建设100个“人工智能+X”复合特色专业、建立50家人工智能学院研究院



北京交通大学：增设人工智能四年制本科专业和人工智能技术两年制专业硕士专业，成立人工智能研究院等；



什么是人工智能



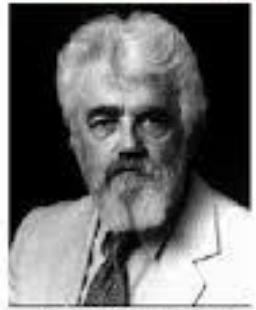
1956年美国达特茅斯会议：“人工智能”概念诞生

人工智能(Artificial Intelligence)

使一部机器像人一样进行**感知、认知、决策、执行**的人工程序或系统



人工智能的起源



- 1958年麦卡锡发明了表处理语言LISP。LISP可以方便地处理符号，很快成为人工智能程序设计的主要语言，至今仍被使用。

John McCarthy

约翰·麦卡锡



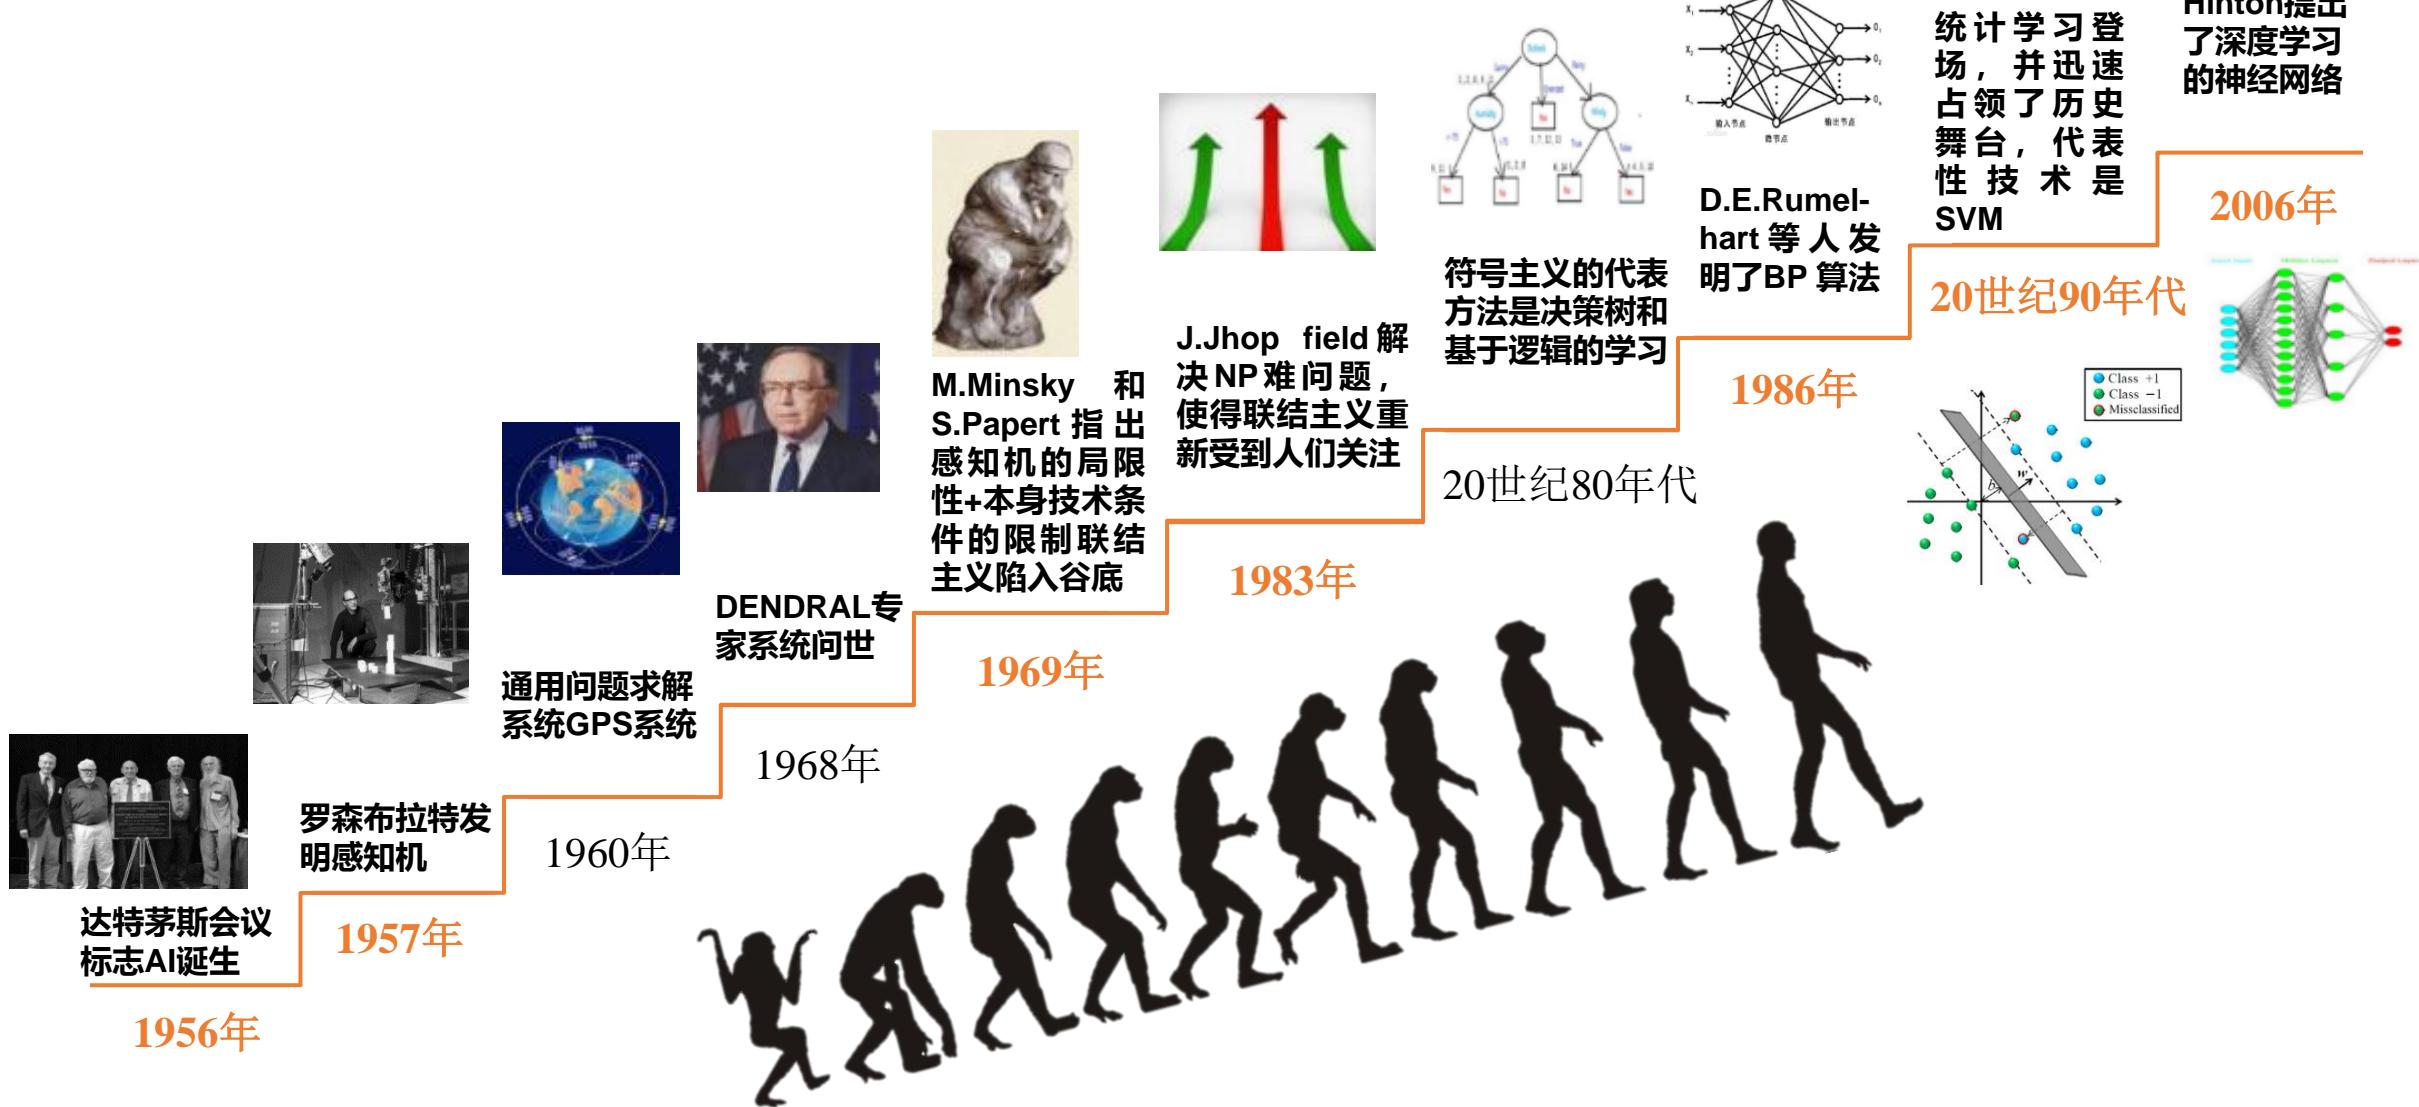
机器智能，阿兰·图灵，1948



摩尔 麦卡锡 明斯基 赛弗里奇 所罗门诺夫
(1956-2006)



人工智能发展标志性事件





人工智能发展阶段

萌芽期

1943年，人工神经网络和数学模型建立，**人工神经网络研究时代开启**；1950年，计算机与人工智能之父图灵发表《机器能思考吗？》，提出“图灵测试”；



启动期

1956年，达特茅斯会议召开，标志着**人工智能的诞生**；期间，国际学术界人工智能研究潮流兴起，罗素《数学原理》被算法全部证明，学术交流频繁；



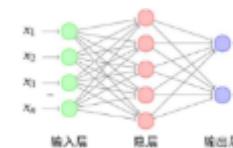
消沉期

1969年，作为主要流派的**联结主义与符合主义进入消沉**，四大预言遥遥无期，在计算能力的限制下，国家及公众信心持续减弱；



突破期

1975年，**BP算法**开始研究，第五代计算机开始研制，专家系统的研究和应用艰难前行，半导体技术发展，计算机成本和计算能力逐步提高，**人工智能逐渐开始突破**；



发展期

1986年，**BP网络**实现，神经网络得到广泛认知，基于人工神经网络的算法研究突飞猛进；**计算机硬件**能力快速提升；互联网构建，**分布式网络**降低了人工智能的计算成本；



高速发展期

2006年，深度学习被提出，人工智能**算法产生突破性发展**；
2010年，移动互联网发展，人工智能**应用场景开始增多**；
2012年，深度学习算法在语言和视觉识别上实现突破，同年，融资规模开始快速增长，人工智能**商业化高速发展**；



人工智能的三个层面

第一
层面



第二
层面



第三
层面



计算智能

能存能算

感知智能

能听会说、能看会认

认知智能

能理解、会思考



人工智能第一个层面-计算智能



计算智能 能存储会计算

计算机具有**快速计算**和**记忆存储**能力：

1996年首次对决中，国际象棋大师卡斯帕罗夫以4:2的战绩击败IBM深蓝。但在1997年，他输给了卷土重来的“深蓝”（Deeper Blue）

(1) “深蓝”重量达1.4吨，有32个节点，每个节点有8块专门为进行国际象棋对弈设计的处理器，平均运算速度为每秒200万步。

(2) 深蓝算法的核心是基于**暴力穷举**：生成所有可能的走法，然后执行尽可能深的搜索，并不断对局面进行评估，尝试找出最佳走法。



人工智能第二个层面-感知智能



感知智能 能听会说
能看会认



类似于人的视觉、听觉、触觉等感知能力



人工智能第三个层面-认知智能



逻辑推理



知识理解



决策思考



认知智能能理解、思考、决策

概念、意识、观念都是认知智能的表现



人工智能+生活/行业



AI+生活



AI+行业

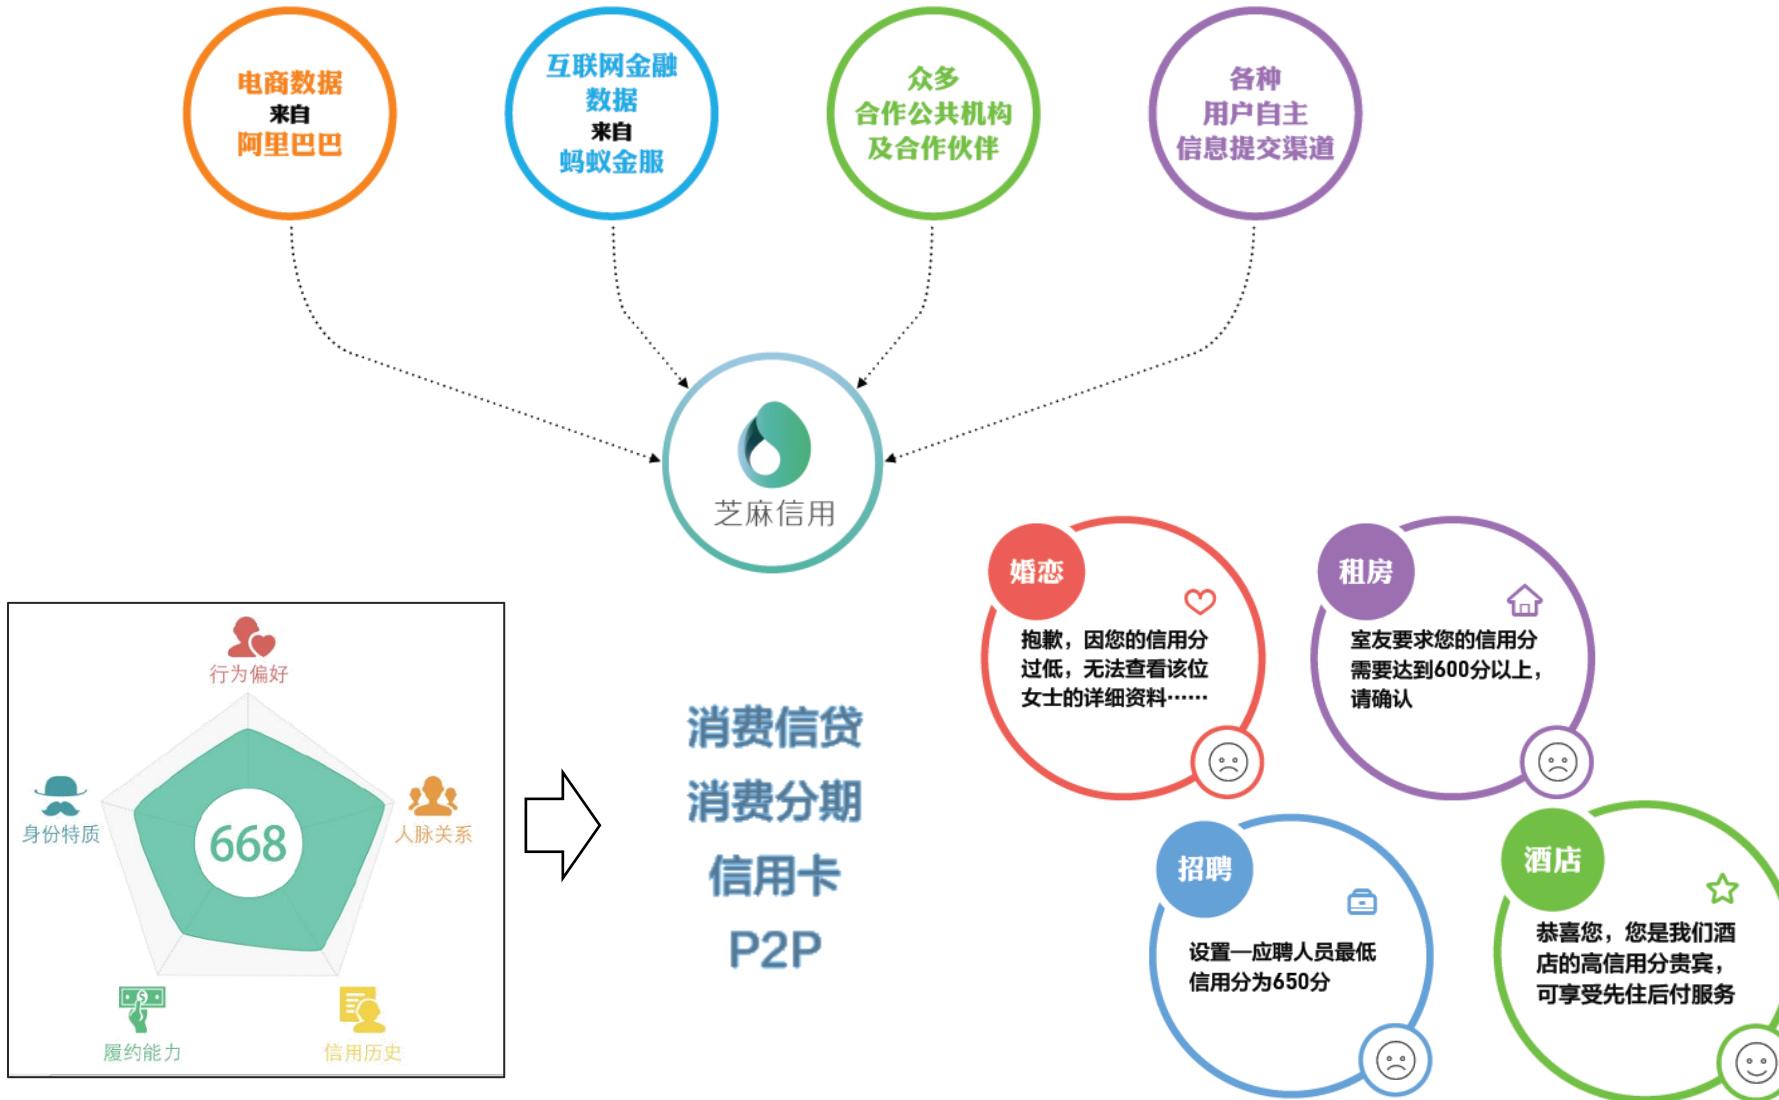


人工智能+金融





人工智能+金融：大数据征信





人工智能+法律

欧盟《一般数据保护条例》规定：自2018年5月25日起要求所有算法解释其输出原理，保证数据隐私和算法公平性



1 人工智能法律、伦理

建立人工智能法律法规、
伦理规范和政策体系



3 人工智能+法学培养模式

- 法律人懂人工智能、会用人工智能
- 不仅传授知识本身，更强调创新、实践能力和判断力的塑造

教育部文件

教技[2018]3号

教育部关于印发《高等学校人工智能
创新行动计划》的通知

2 智慧法庭

促进人工智能在证据收集、案例分析、法律文件阅读与
分析中的应用，实现审判体系和审判能力智能化

法律人工智能科技



服务法院的智能系统
庭审语音，生成判决书
案件结果预测



服务律师的智能系统
智能客服，筛选客户
查找类案，辩护路径推荐



服务当事人智能系统
自动生成起诉书
自助咨询服务，寻找律师



人工智能+法律

AI应用 程度 参与主体	信息化 (IT/互联网思维)	智能化 (人工智能思维)
当事人		法律咨询 律师推荐 文书处理
律所/律师	信息管理	智能客服 文书检索 案情预测 文书处理
法院/法官	互联网法院 信息管理	智能客服 文书检索 案情辅助审判 文书处理

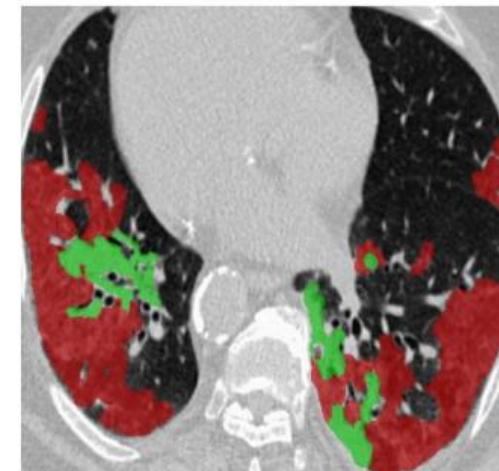


人工智能+医疗



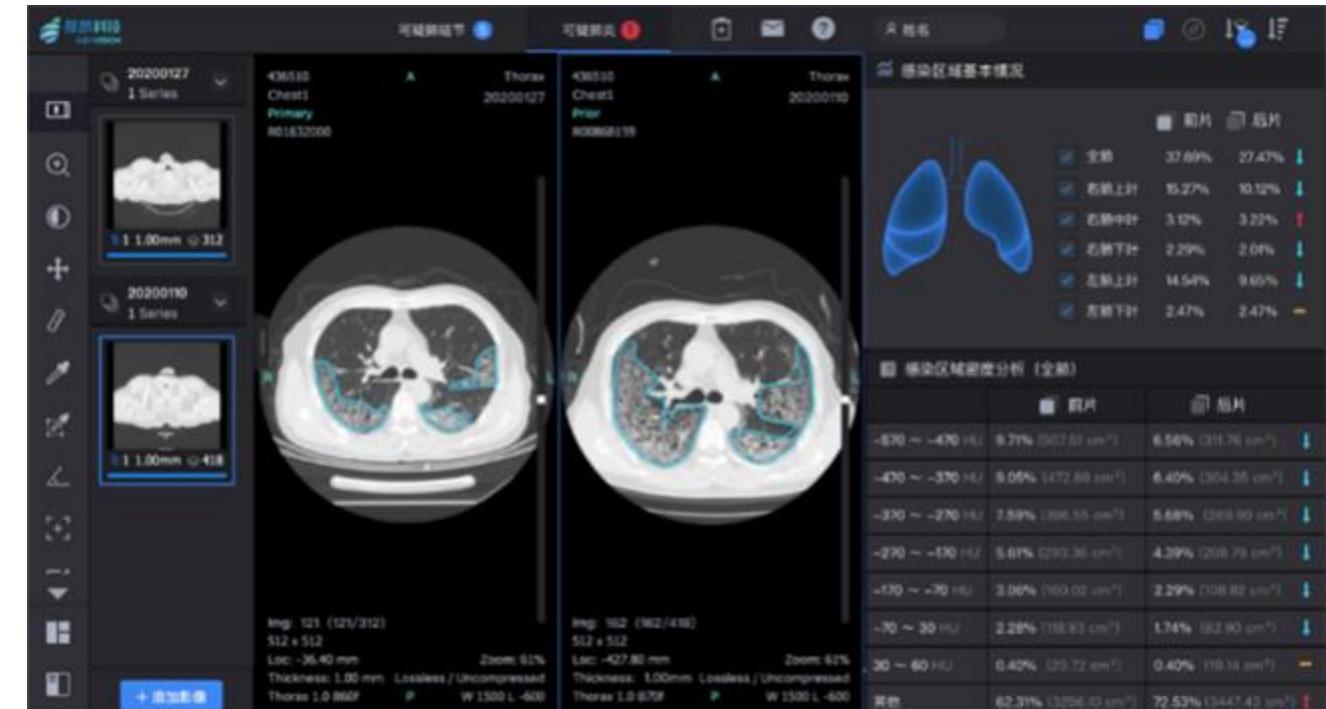


COVID-19肺部感染图像分割与筛查



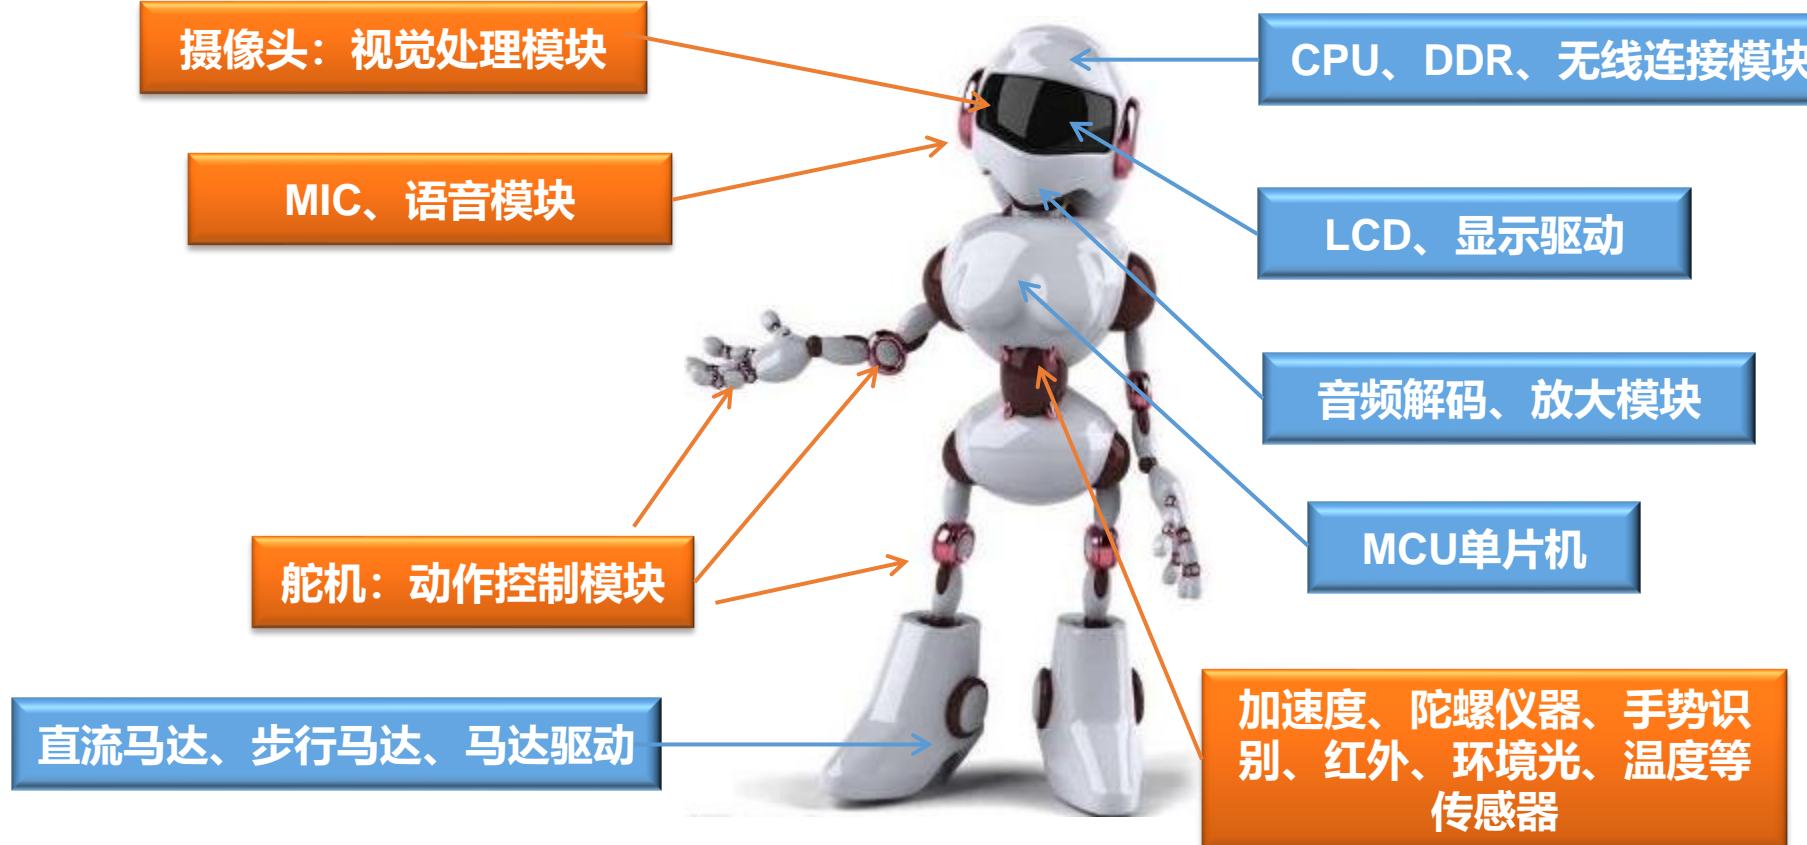
初期：毛玻璃现象（红色）

后期：肺实变（绿色）



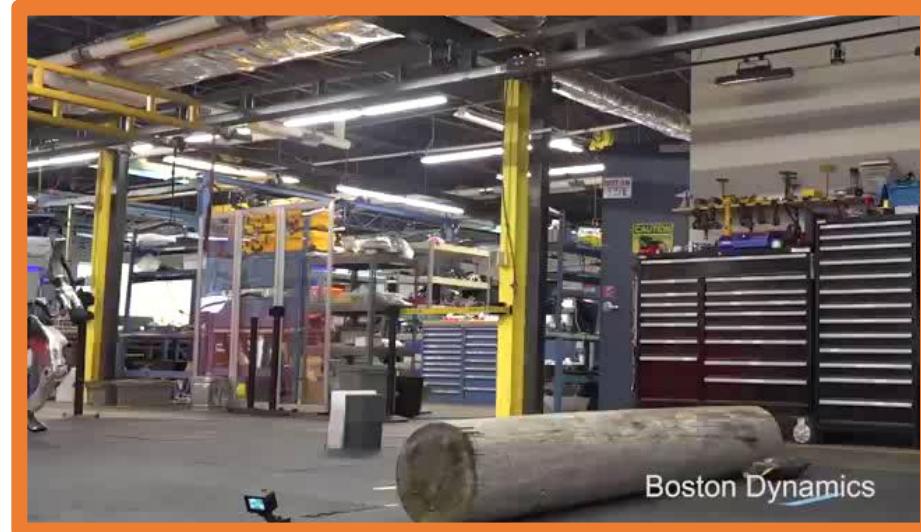


人工智能+机器人





人工智能+机器人



扫地机器人



拣货机器人



医疗机器人



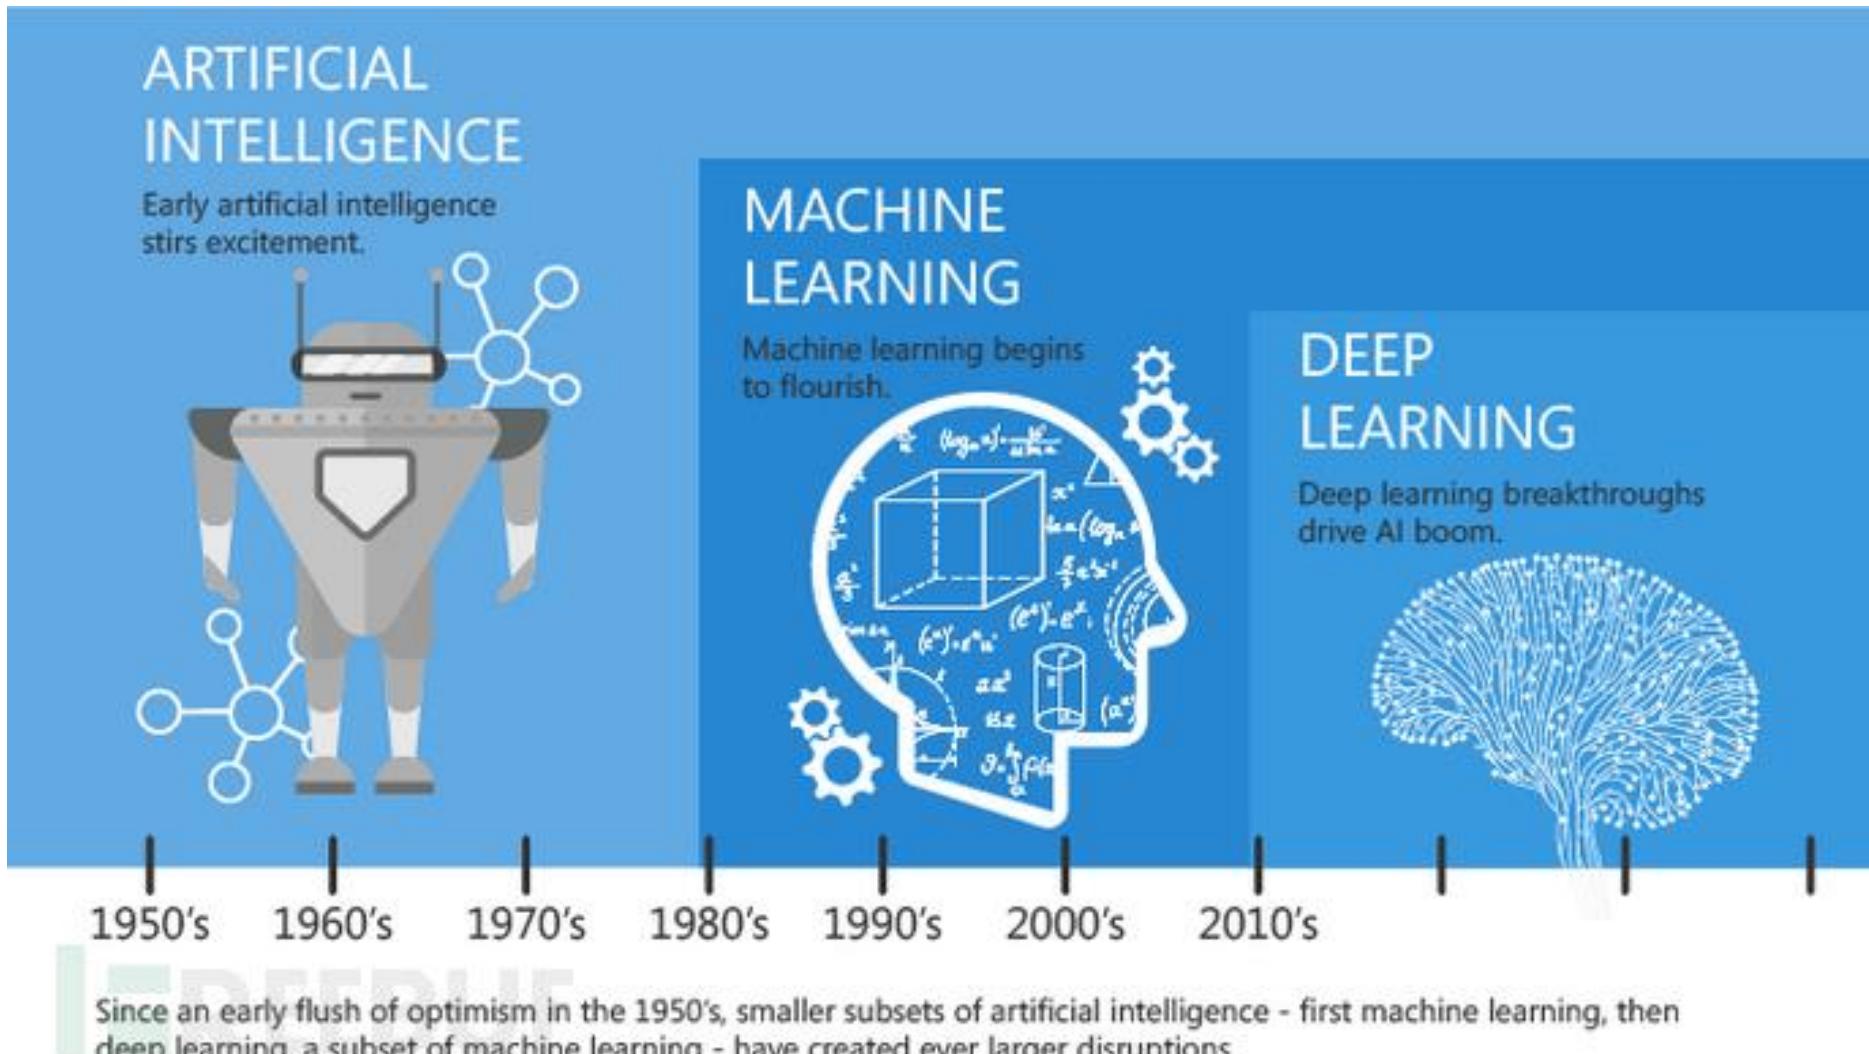
教育机器人



服务机器人

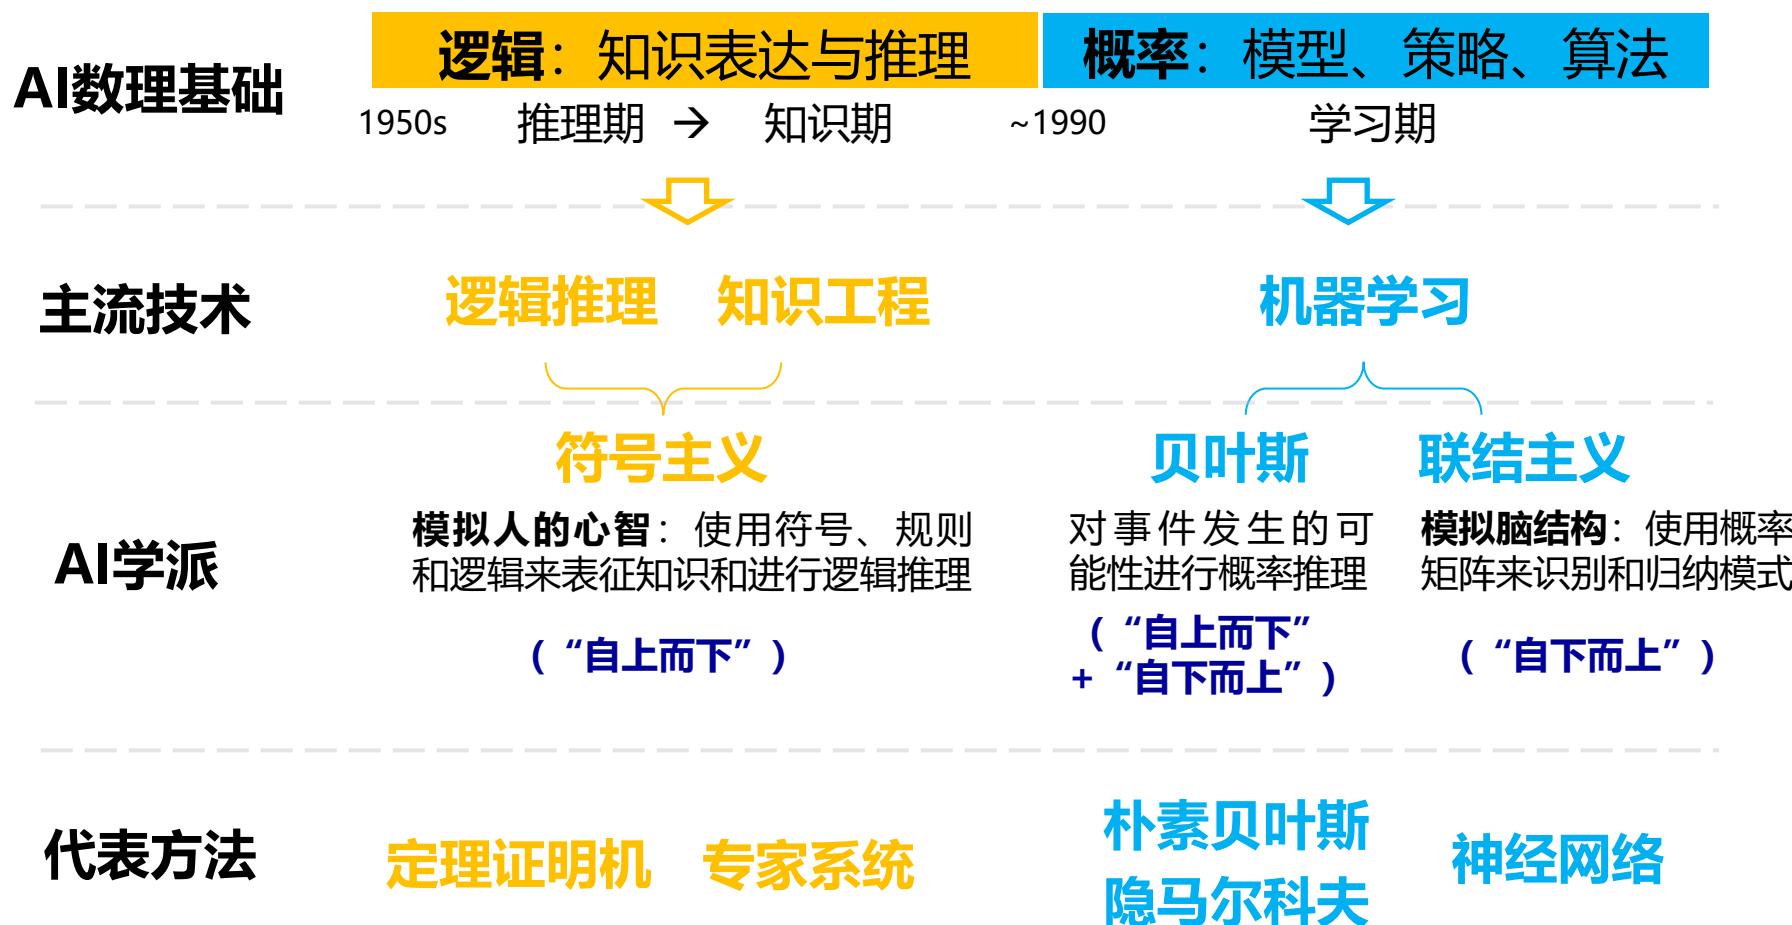


人工智能>机器学习>深度学习





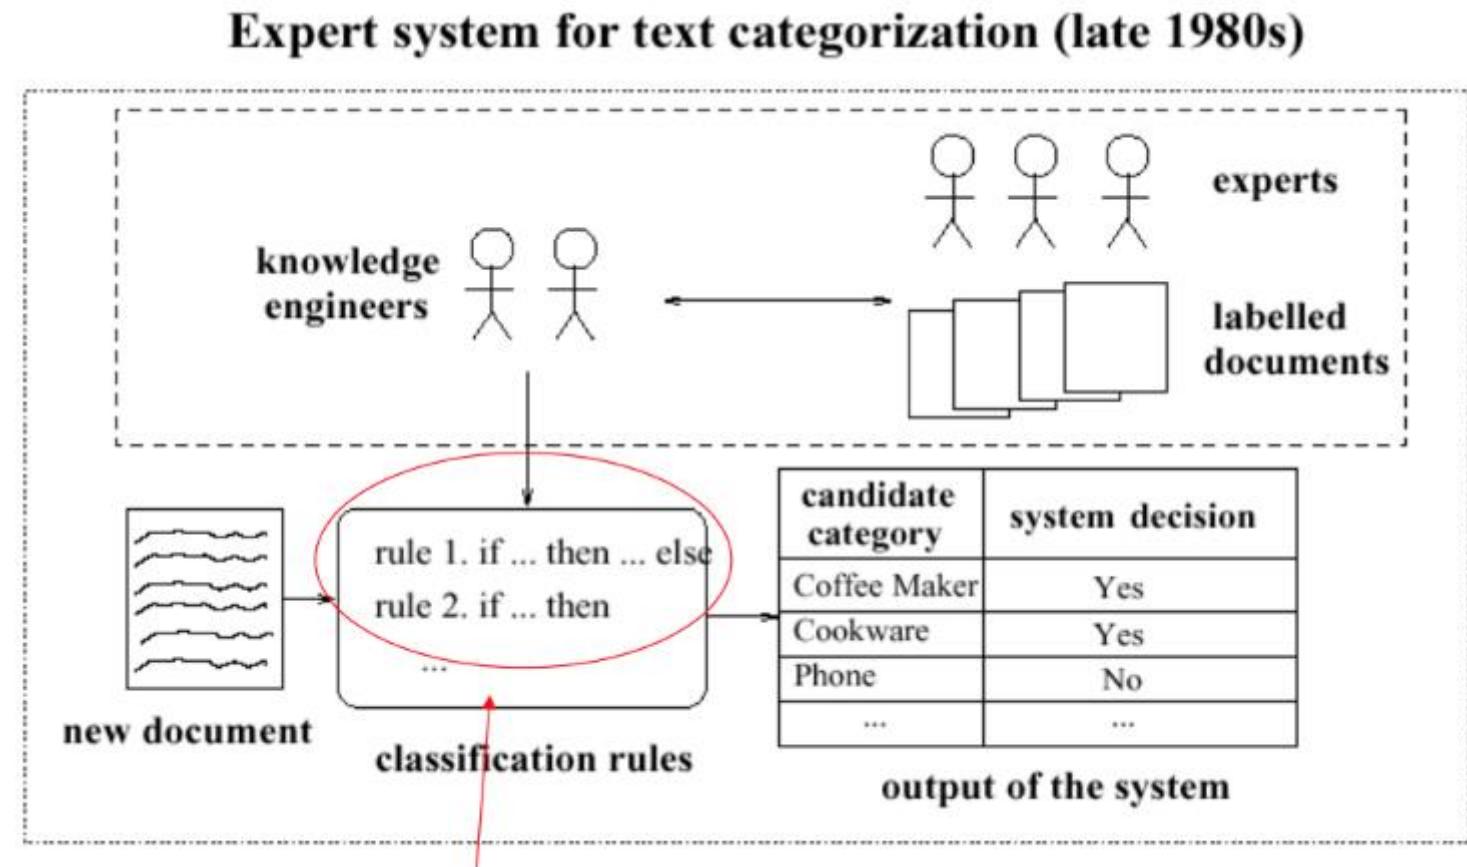
逻辑演绎 vs 归纳总结





知识工程/专家系统

根据专家定义的知识和经验，进行推理和判断，从而模拟人类专家的决策过程来解决问题。

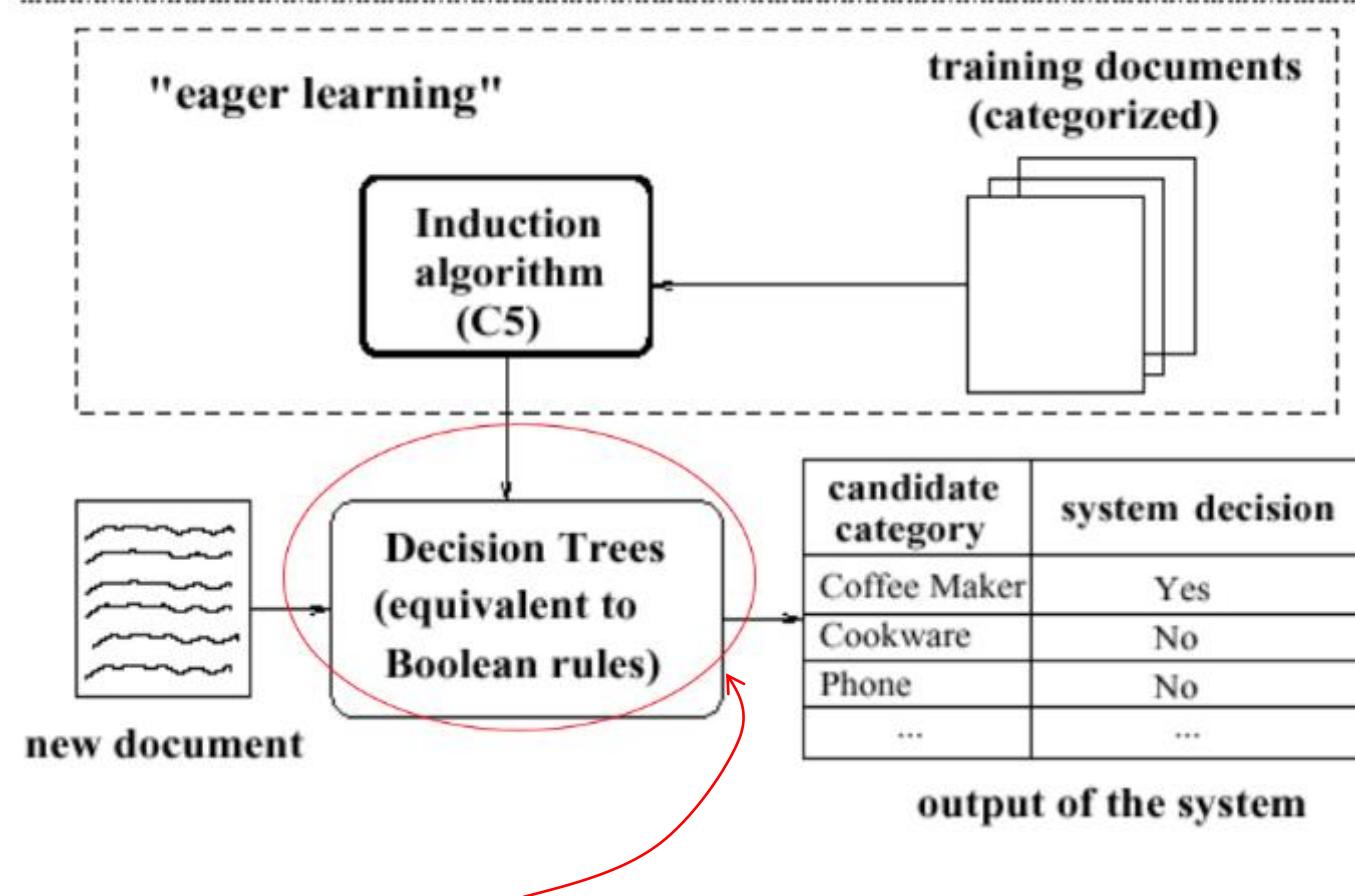


人工定义规则



机器学习

DTree induction for text categorization (since 1994)

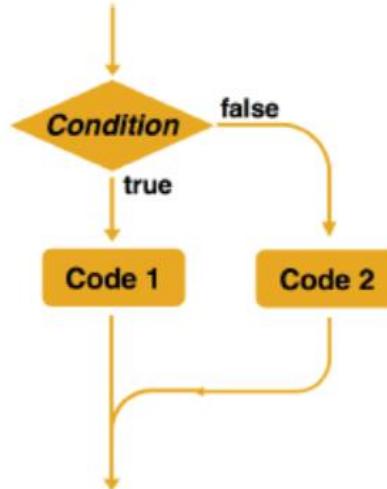


机器自动训练

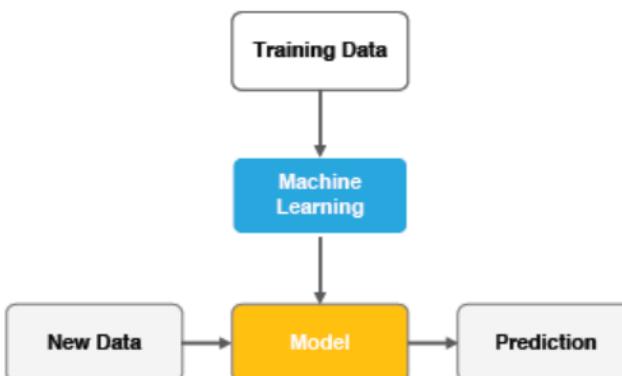


知识工程 vs 机器学习

Rule-based approach



Machine learning



■ 知识工程

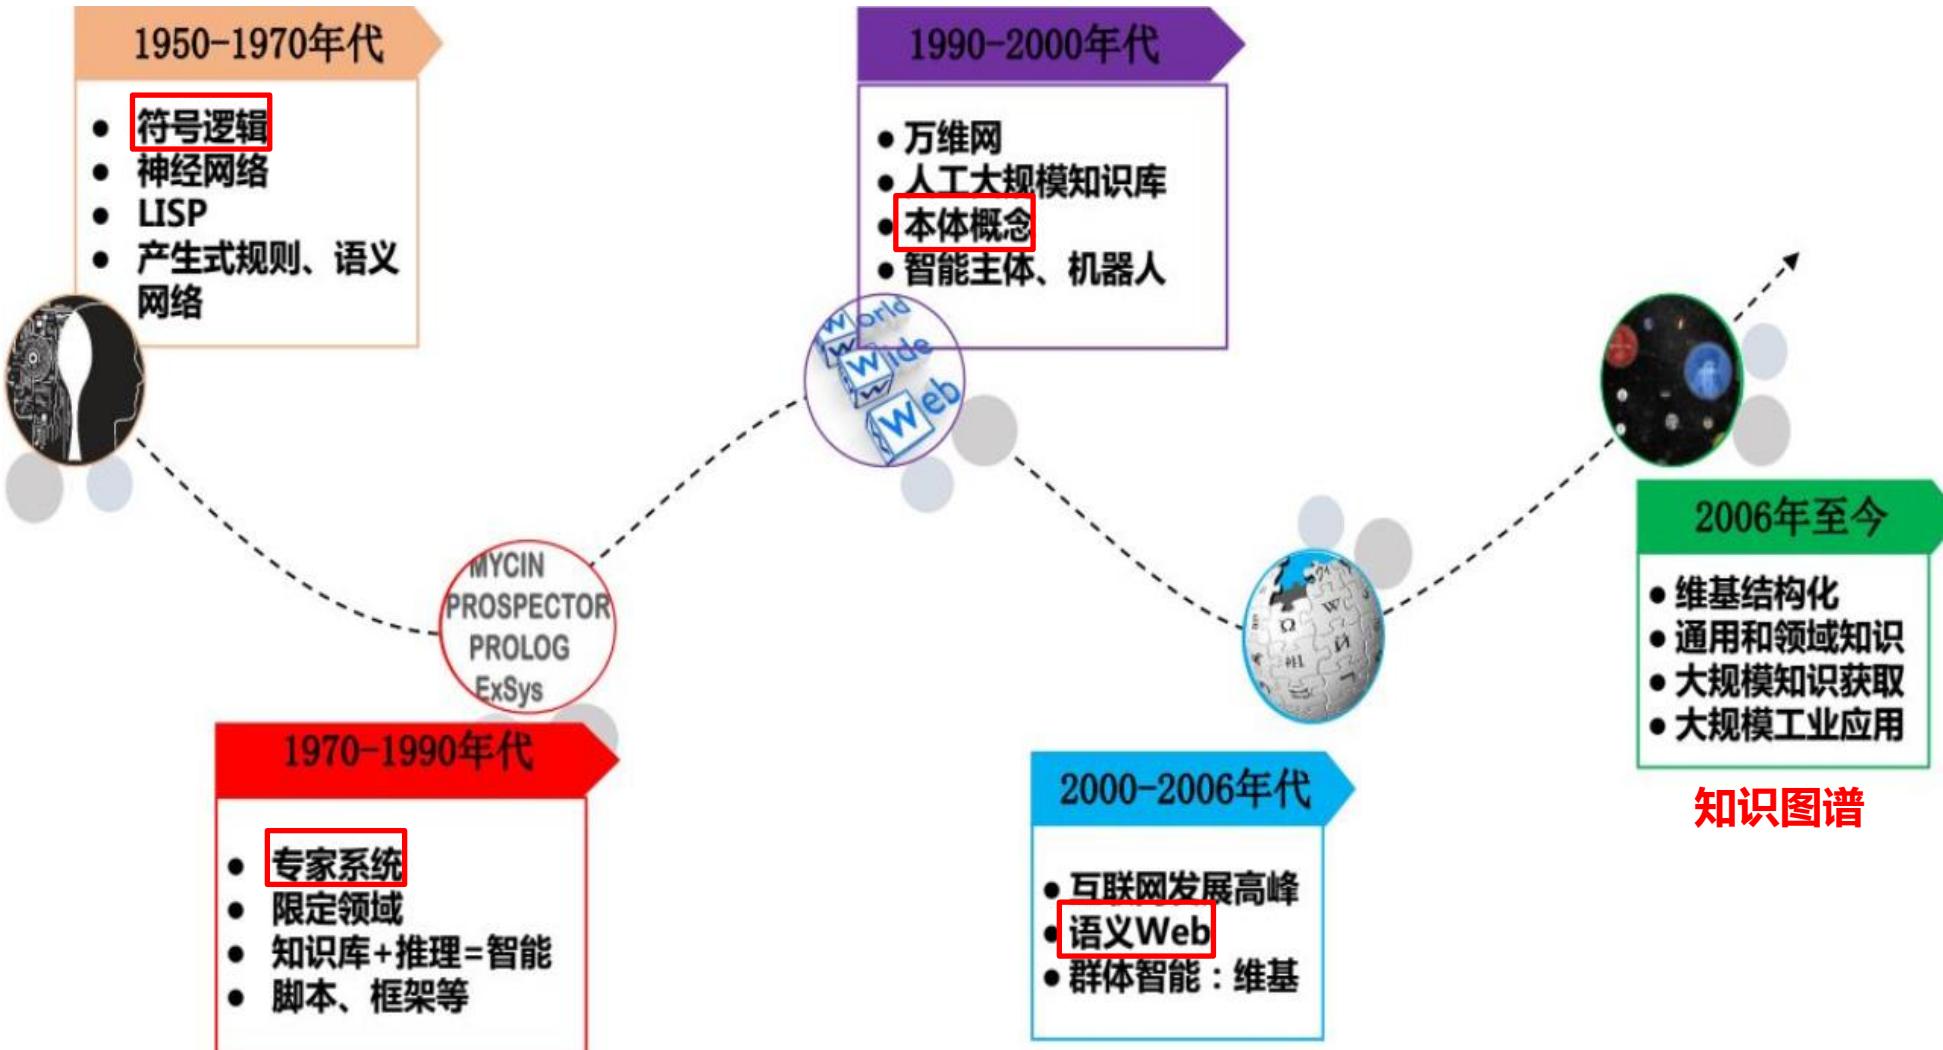
- 基于手工设计规则建立专家系统 (~80年代末期)
- 结果容易解释
- 系统构建费时费力
- 依赖专家主观经验，难以保证一致性和准确性

■ 机器学习

- 基于数据**自动学习** (90年代中期~)
- 减少人工繁杂工作，但结果可能不易解释
- 提高信息处理的**效率**，且准确率较高
- 来源于真实数据，减少人工规则主观性，可信度高



知识工程的发展 & 融合





机器学习的应用技术领域

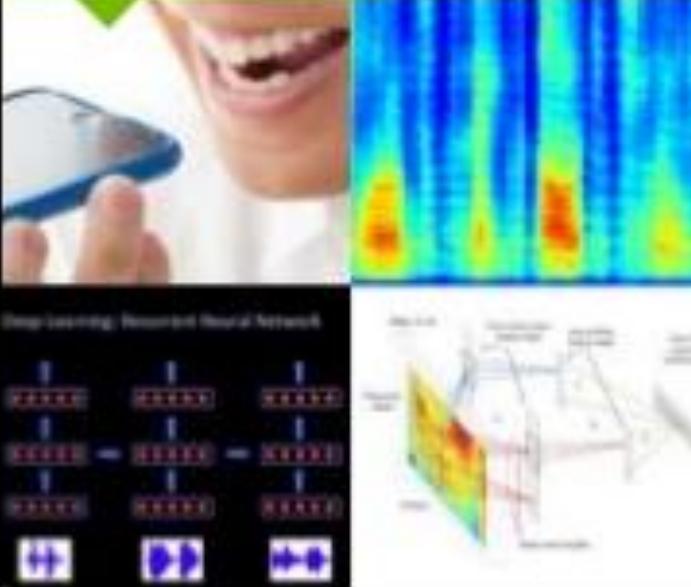
 
Image Classification Object Detection

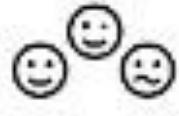
COMPUTER VISION



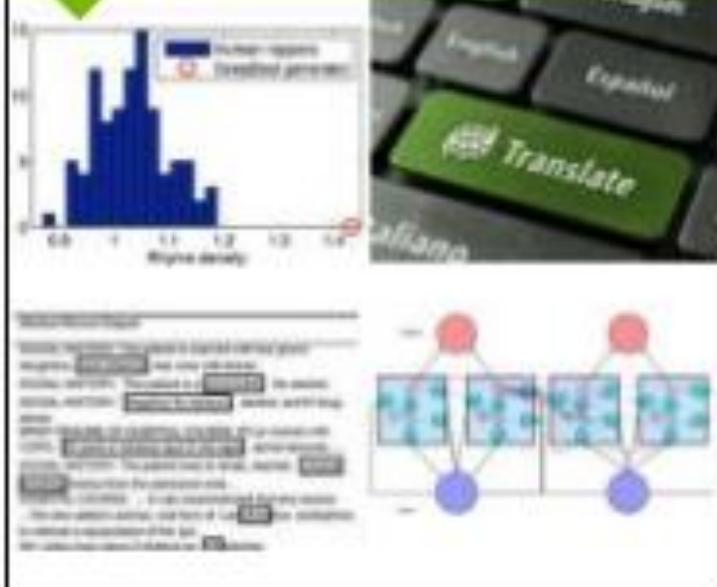
 
Voice Recognition Language Translation

SPEECH & AUDIO



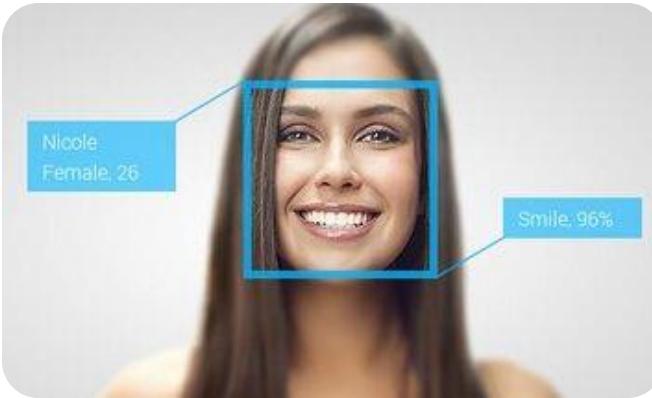
 
Recommendation Engines Sentiment Analysis

NATURAL LANGUAGE PROCESSING

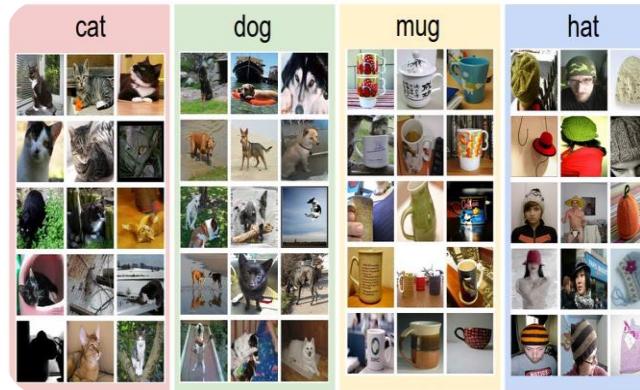




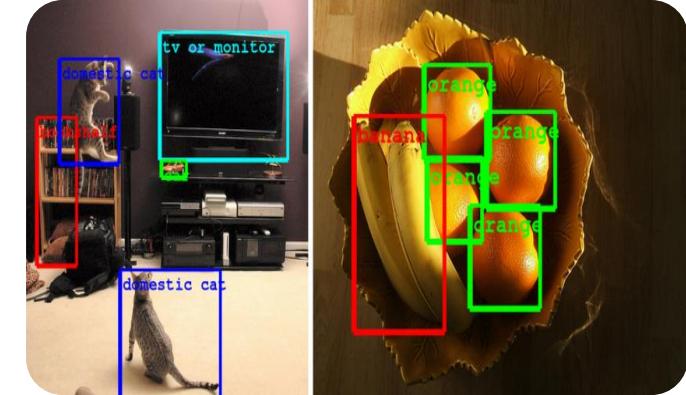
计算机视觉



人脸识别



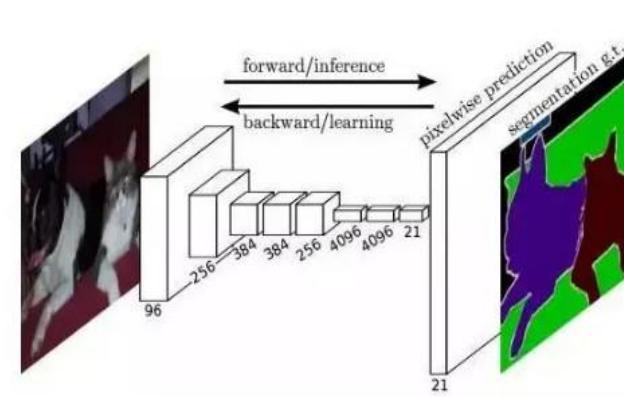
图像分类



目标检测



图像搜索



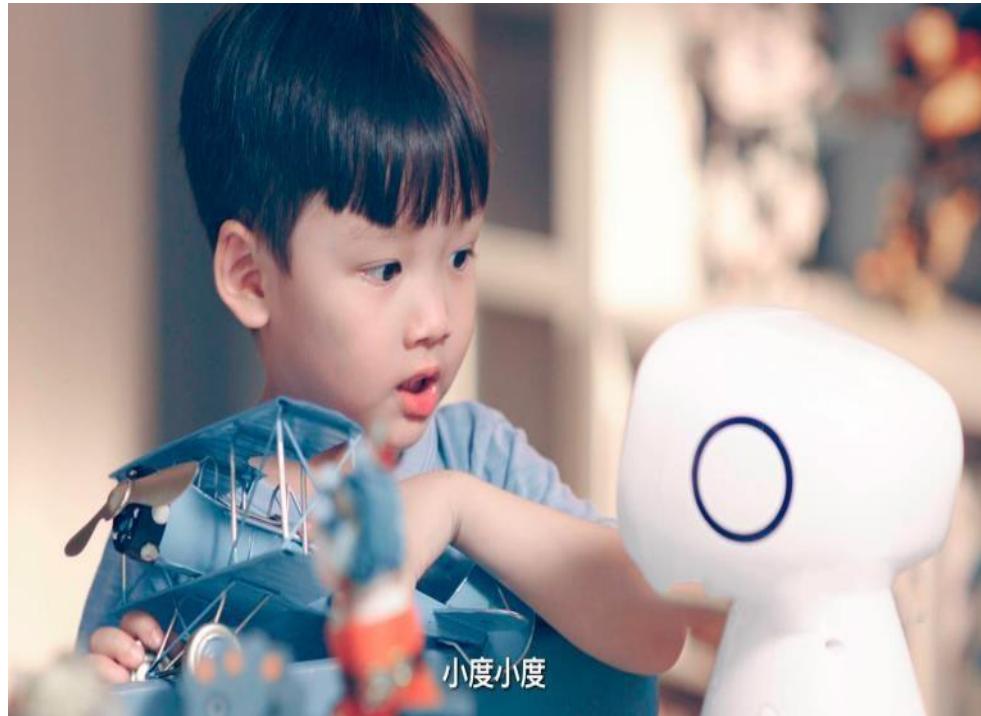
图像分割



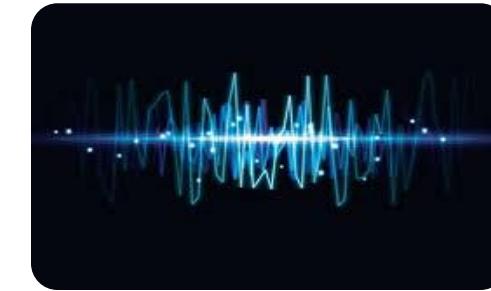
视频监控



语音技术



语音识别



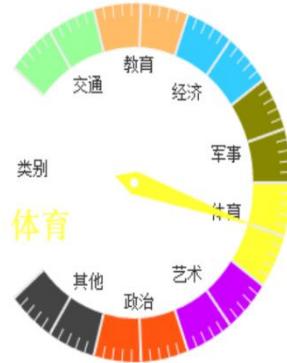
语音合成



声纹识别



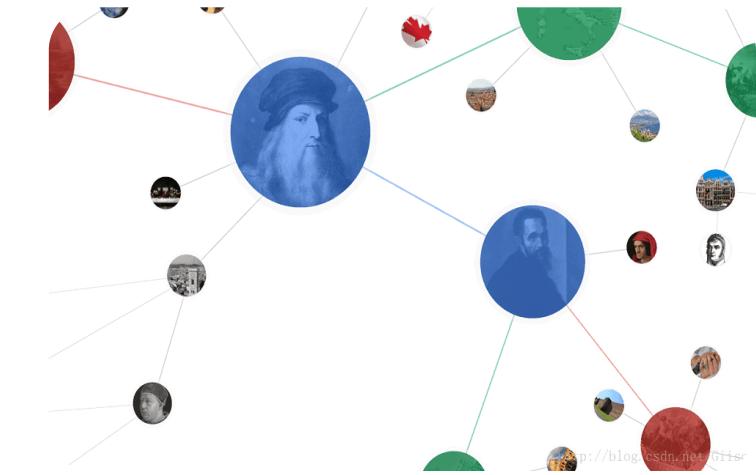
自然语言处理



文本分类



机器翻译



知识图谱



自动问答



信息检索

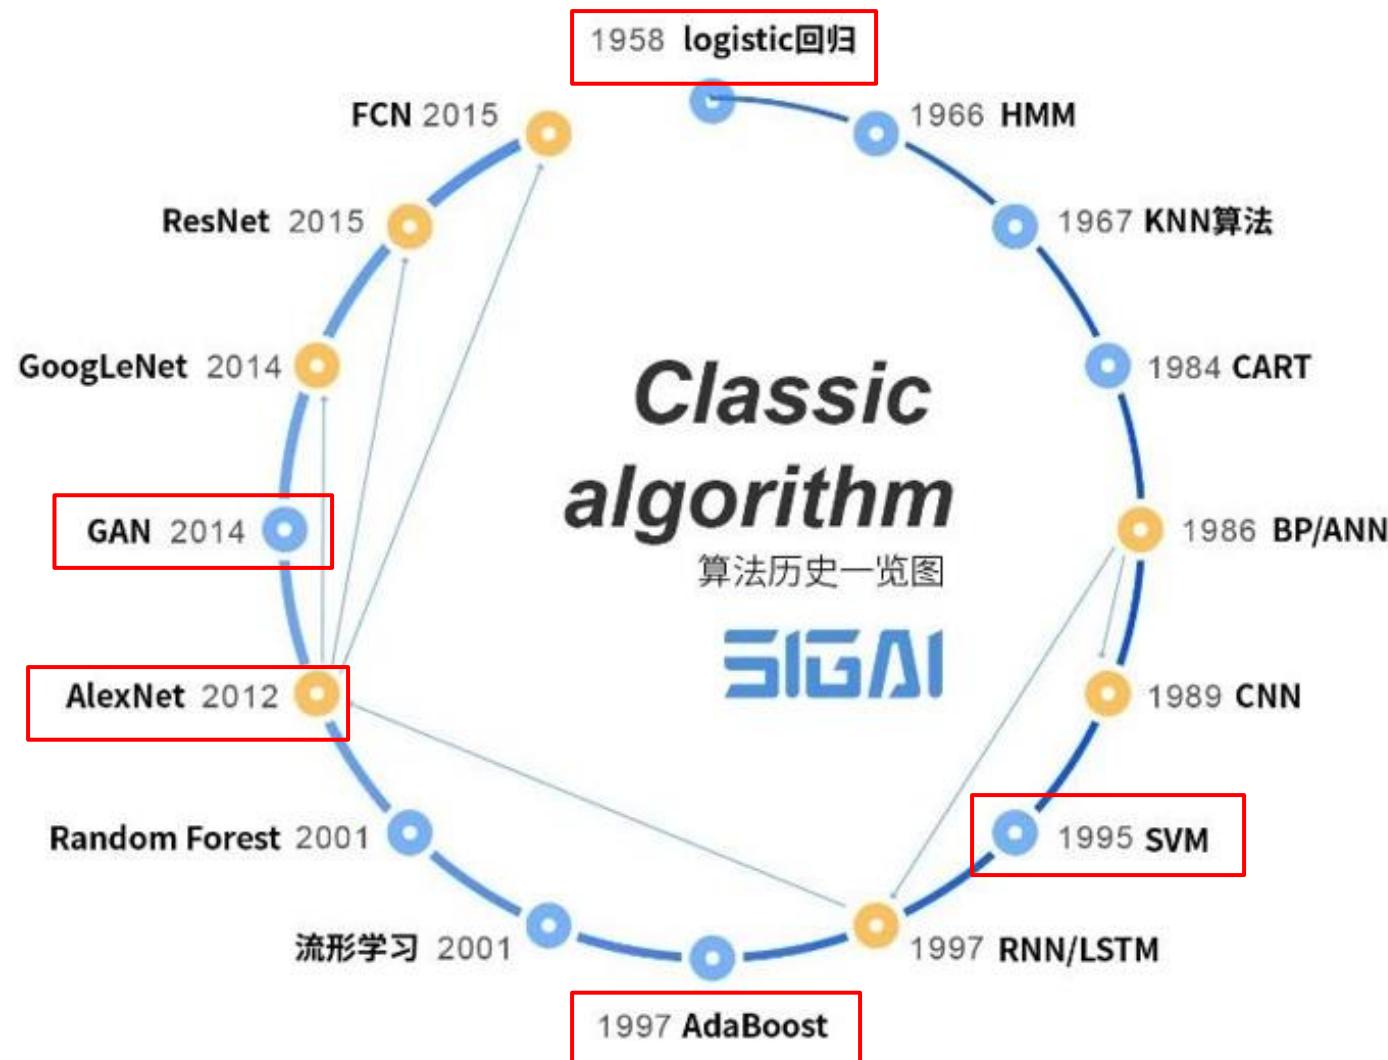


文本生成

2. 神经网络和深度学习概述

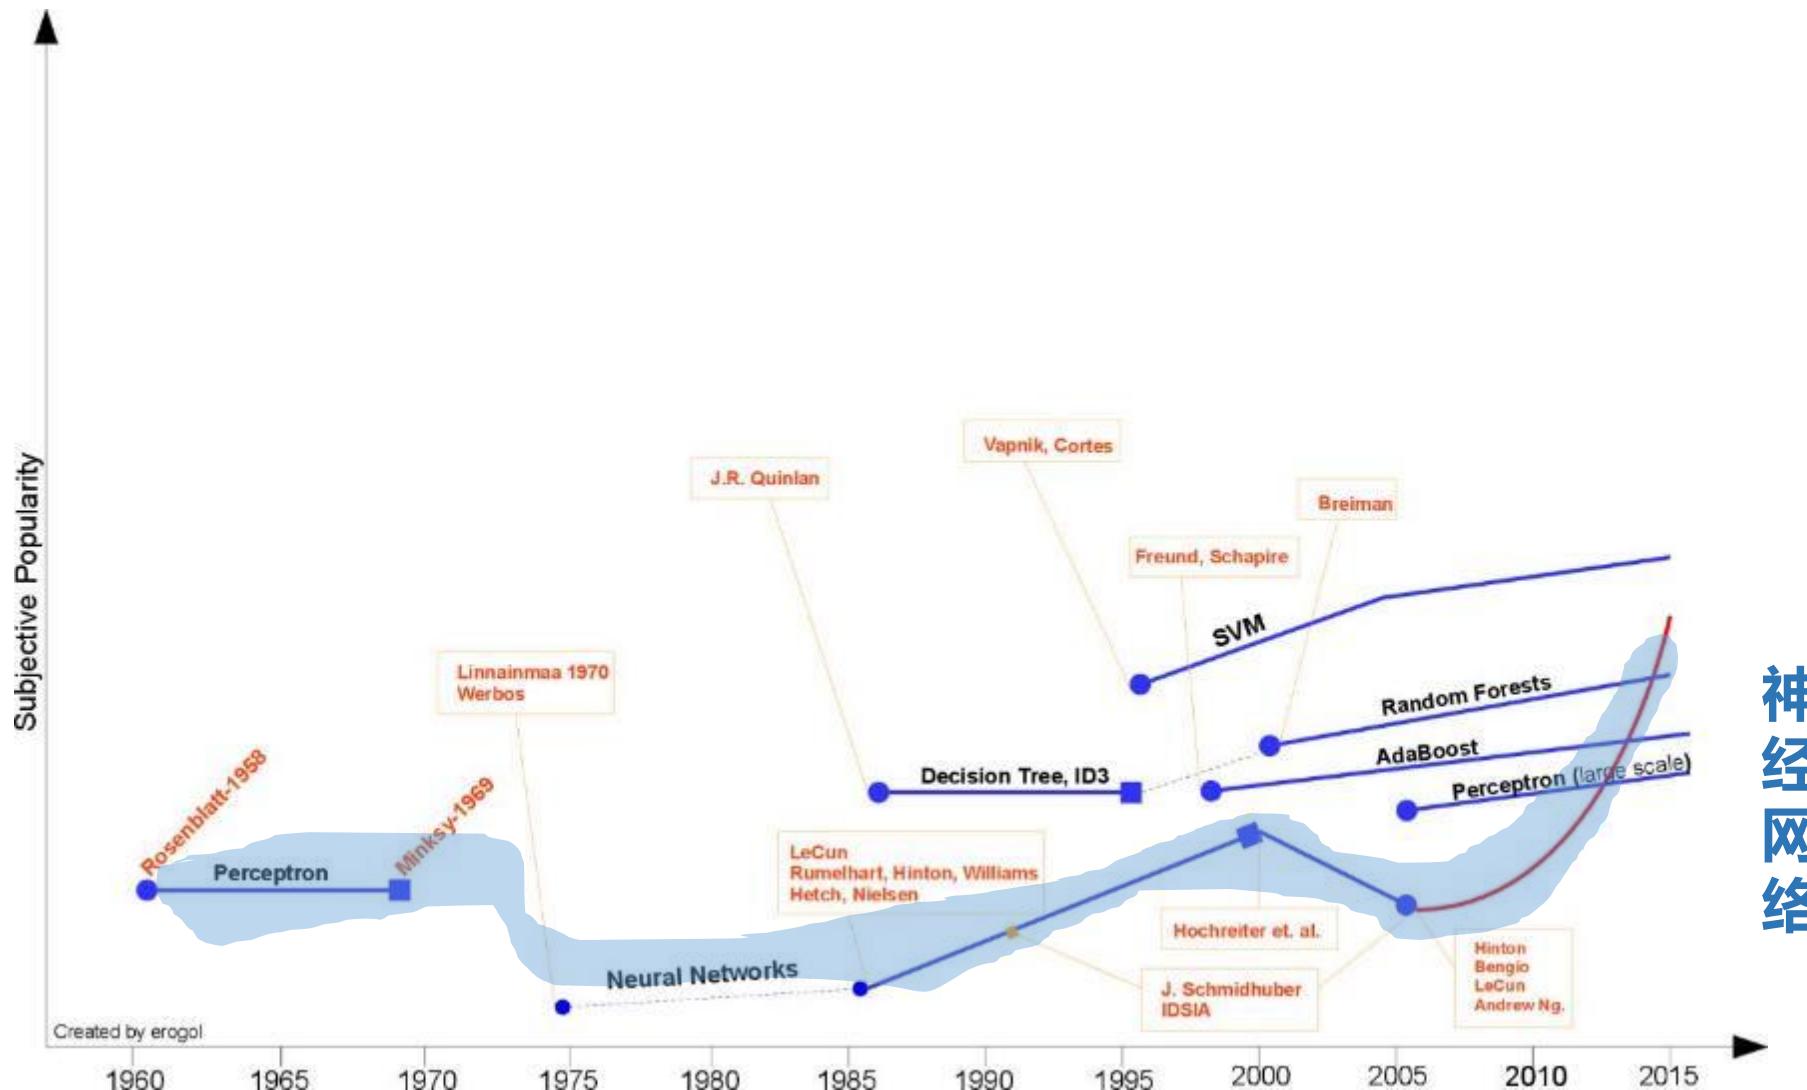


流行机器学习模型的演变





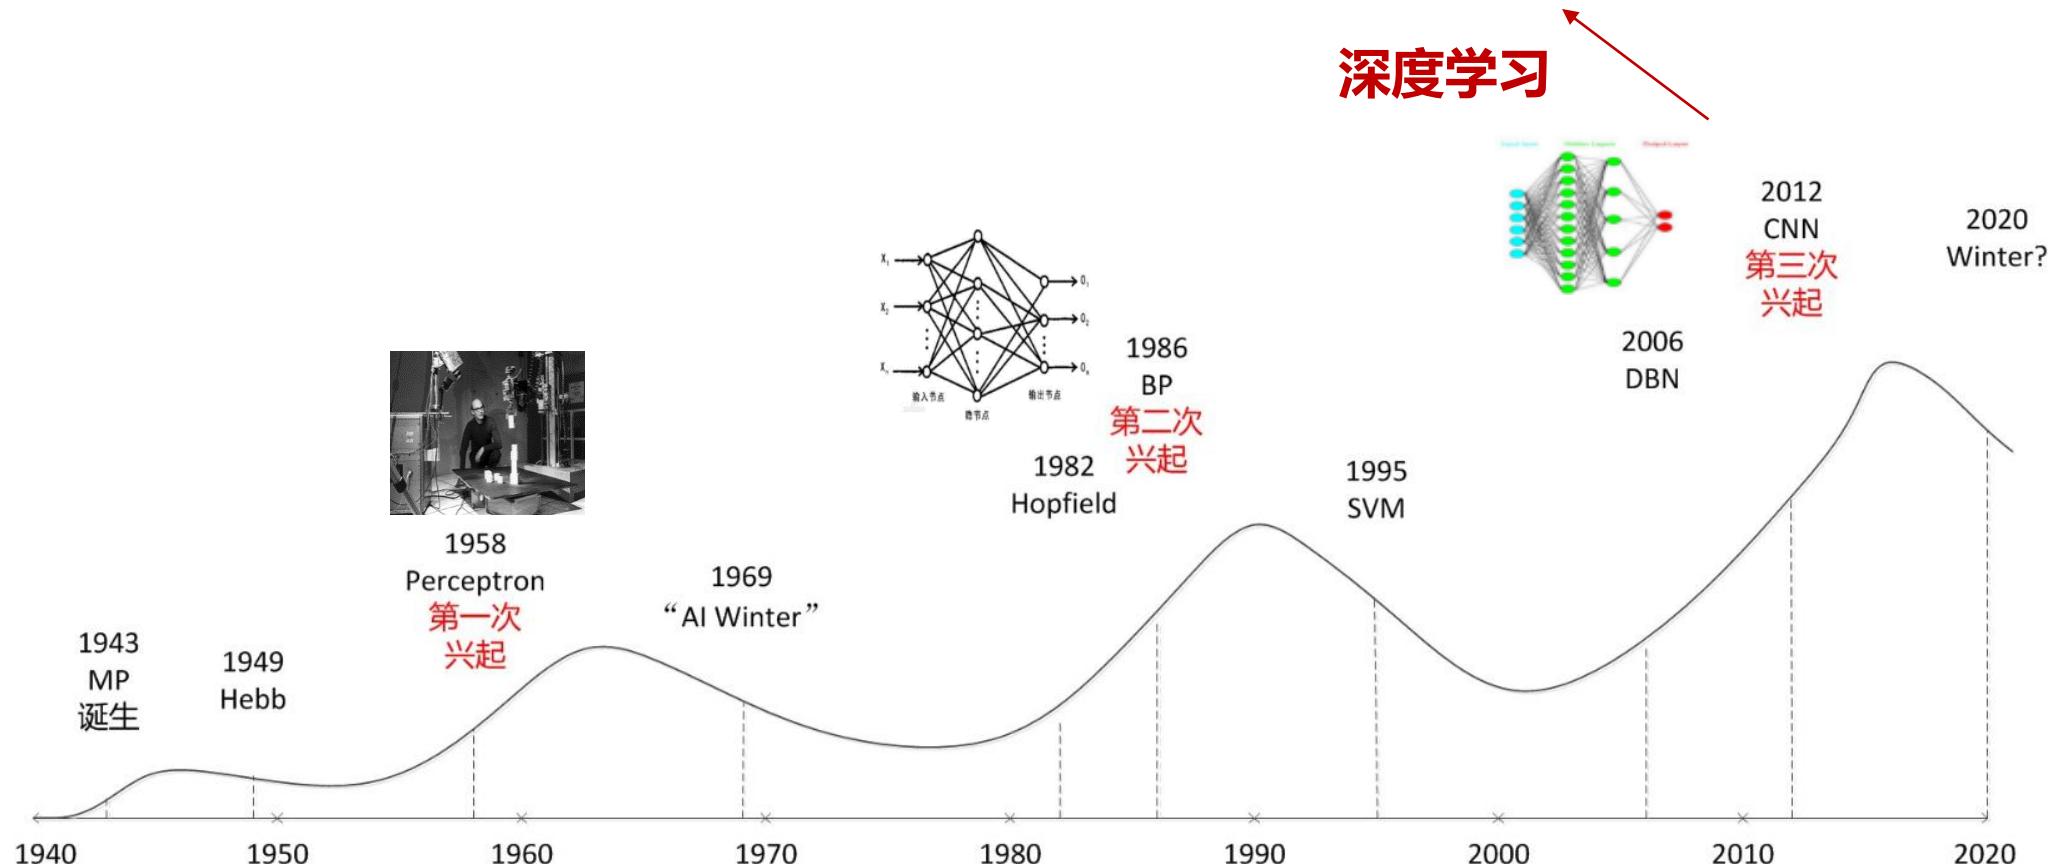
流行机器学习模型的演变





神经网络(人工智能)的三起两落

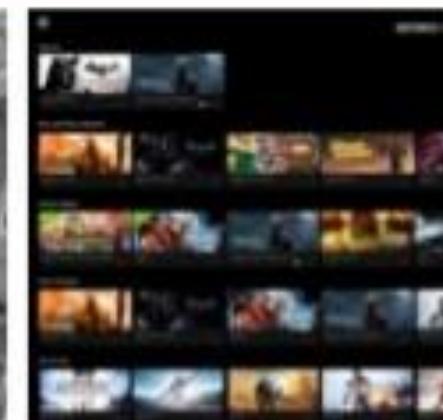
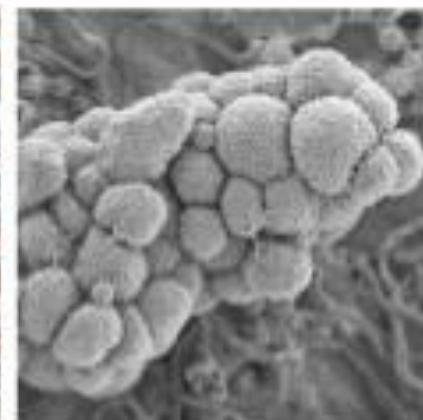
[学术] 2006年，逐层预训练算法被提出；
[工业] 2012年，深度学习算法在视觉识别竞赛ImageNet上实现突破；
[普及] 2016年，AlphaGo战胜李世石。





深度学习无所不在

DEEP LEARNING EVERYWHERE



INTERNET & CLOUD

- Image Classification
- Speech Recognition
- Language Translation
- Language Processing
- Sentiment Analysis
- Recommendation

MEDICINE & BIOLOGY

- Cancer Cell Detection
- Diabetic Grading
- Drug Discovery

MEDIA & ENTERTAINMENT

- Video Captioning
- Video Search
- Real Time Translation

SECURITY & DEFENSE

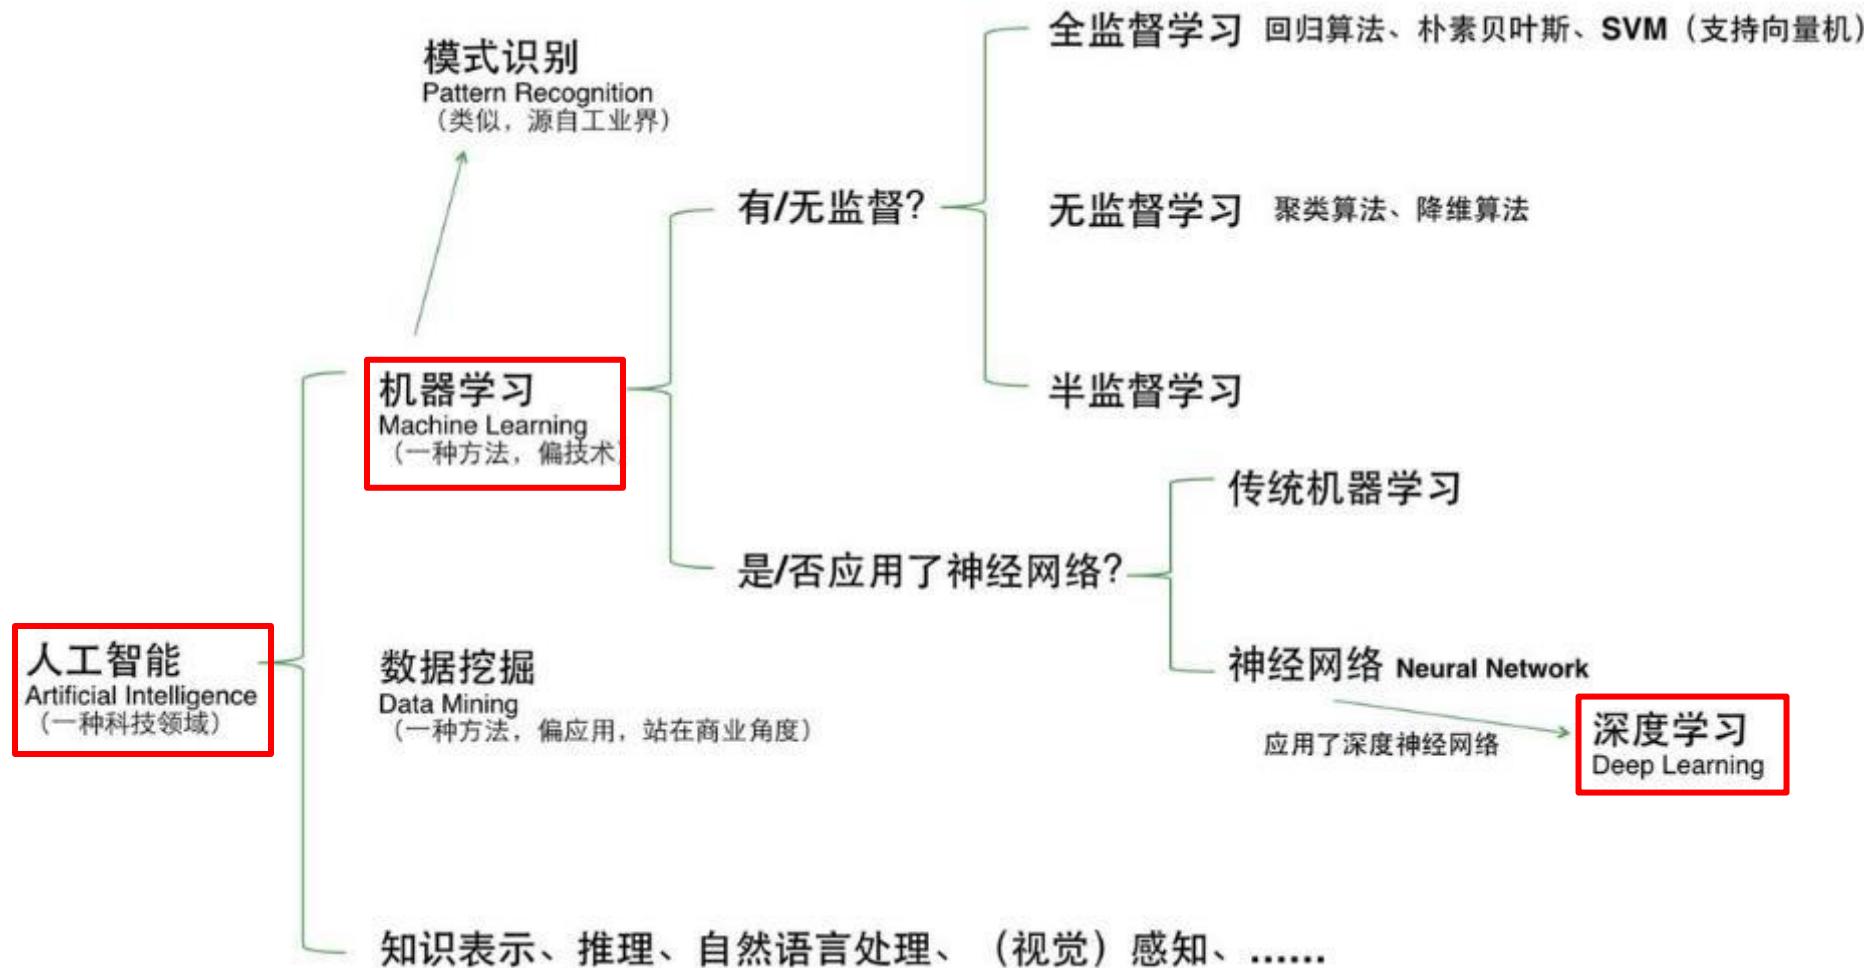
- Face Detection
- Video Surveillance
- Satellite Imagery

AUTONOMOUS MACHINES

- Pedestrian Detection
- Lane Tracking
- Recognize Traffic Sign



人工智能>机器学习>深度学习

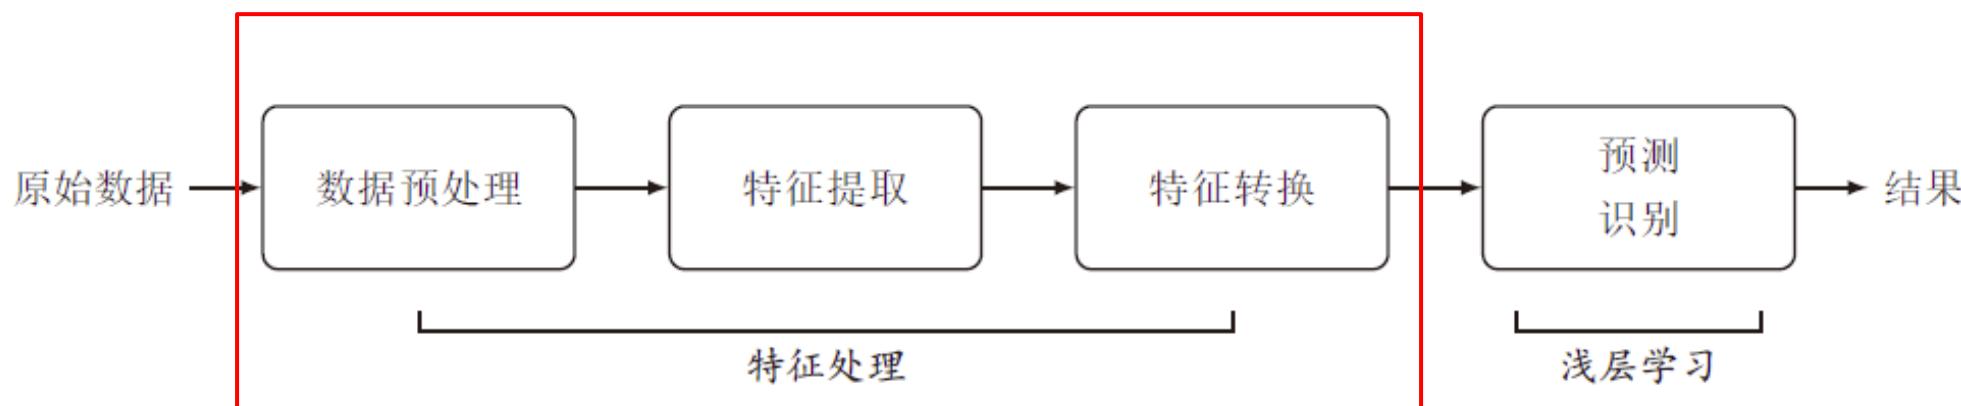




传统机器学习：人工设计特征

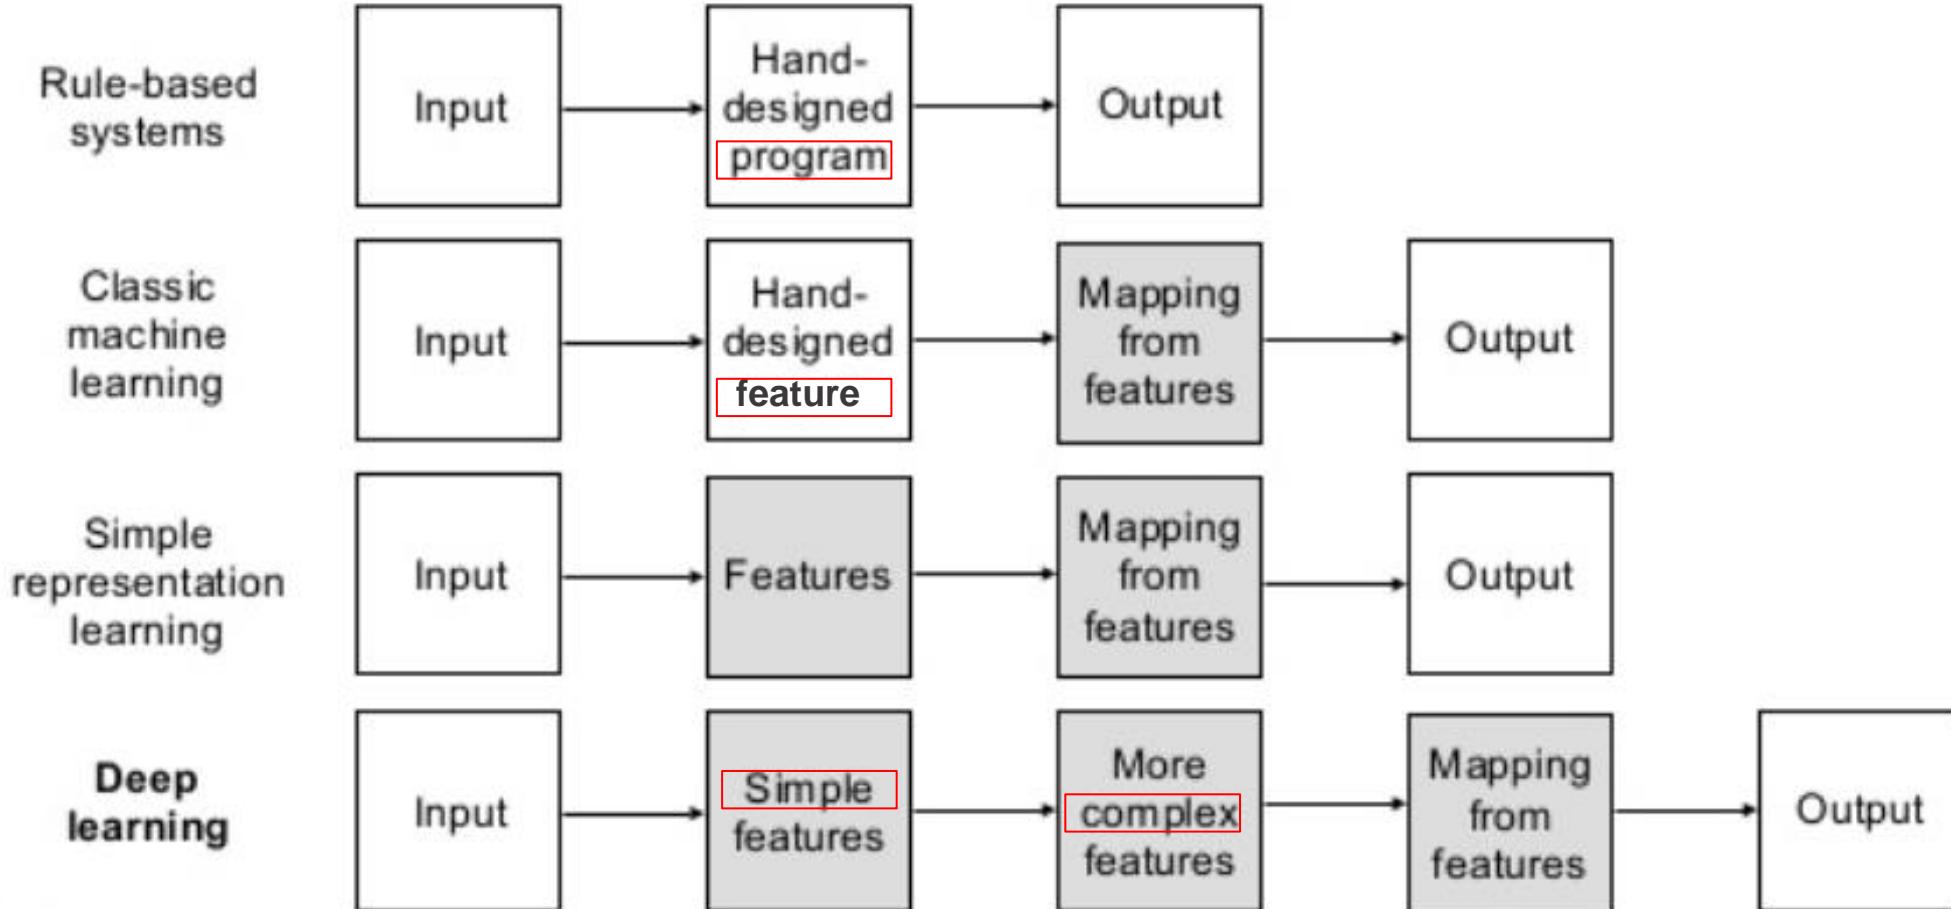
■ 实际应用中，特征往往比分类器更重要

- 预处理：经过数据预处理，如去除噪声等；如在文本分类中，去除停用词等。
- 特征提取：从原始数据中提取有效特征，如在图像分类中，提取边缘、尺度不变特征变换特征等。
- 特征转换：对特征进行一定的加工，比如降维和升维。降维包括
 - ✓ 特征抽取 (Feature Extraction) : PCA、LDA
 - ✓ 特征选择 (Feature Selection) : 互信息、TF-IDF





传统机器学习 VS 深度学习





传统机器学习 VS 深度学习

从巡逻机器人的狗屎检测需求说起...





传统机器学习 VS 深度学习

前深度学习时代，我们这么做...

- 步骤1：花几天时间收集并标注几百张便便图
- 步骤2：花几个月观察便便图
■ 形状，颜色，纹理等一些特征
- 步骤3

需要多久？1年甚至更久
行人检测用了10年...
人脸检测用了20年...



专家知识驱动
的特征设计



专家选择的
分类器



传统机器学习 VS 深度学习

深度学习时代，我们这么做...

- 步骤1：花几个星期时间收集并标注(框出狗)数万张便便图
- 步骤2：花1个星期，挑几个深度模型，调参数
- 步骤3：交给机器优化深度模型，调参数

需要多久？2个月



专家选择
深度模型



机器优化
深度模型



传统机器学习 VS 深度学习

后深度学习时代，我们怎么做？

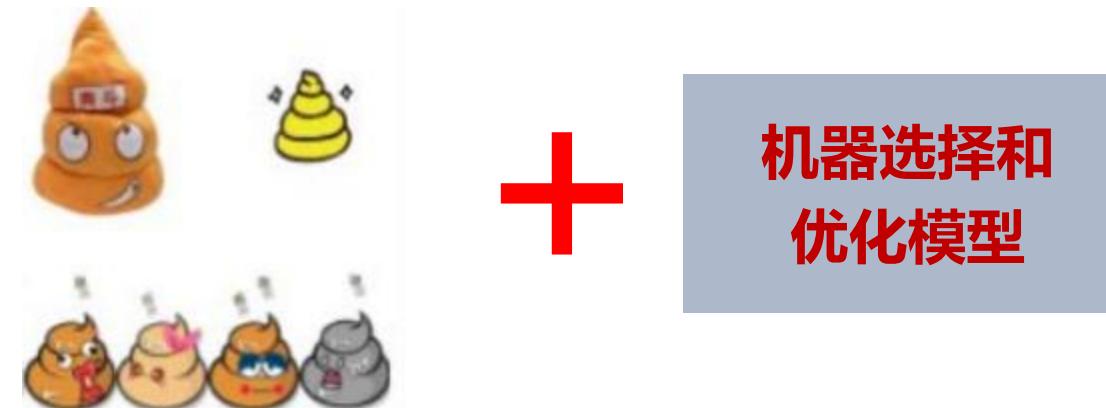




传统机器学习 VS 深度学习

后深度学习时代，我们期待这么做...

- 步骤1：花几分钟时间收集并标注几张便便图
- 步骤2：交给机器绞尽脑汁完成任务





从下棋说起

■ 游戏对弈机器：从国际象棋到AlphaGo



1769年匈牙利作家兼发明家Wolfgang von Kempelen建造了机器人The Turk，能够跟国际象棋高手对弈，但最终谜底揭开，机器人之所以会下棋是因为箱子里藏着一个人。



《2001太空漫游》(2001: A Space Odyssey)是1968年上映的，由斯坦利·库布里克执导，根据科幻小说家亚瑟·克拉克小说改编的科幻电影。片中一个情节是机器人HAL与人Frank下国际象棋，人类在机器面前甘拜下风



HAL→IBM

TIME

1997年在IBM的深蓝战胜国际象棋世界冠军Kasparov后，时代杂志提出了一项新的挑战：让计算机与人类下围棋吧，它获胜的机会很小。“**计算机要在围棋上战胜人类，还要再过一百年，甚至更长的时间**”时代杂志的文章中这些写道。



从下棋说起

■ 20 年，不用100年



Deep Blue依靠运算能力搜索最佳走棋，而AlphaGo更像人类，通过自学来提高棋力。

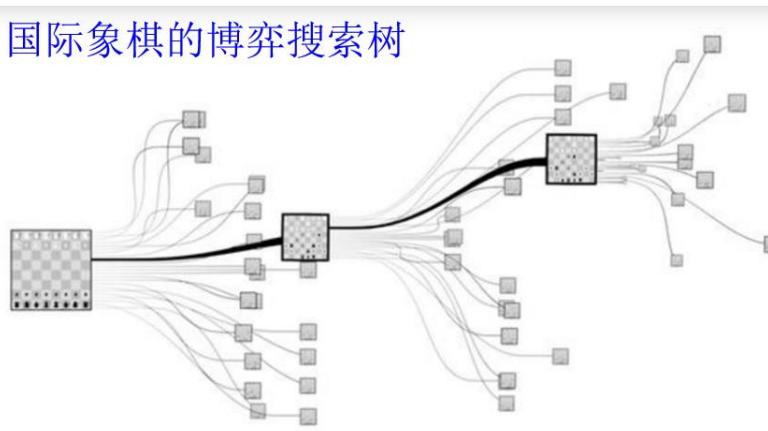
AlphaGo Shock：AlphaGo冲击波在韩国，投资30亿美元的5年计划，研究人工智能。



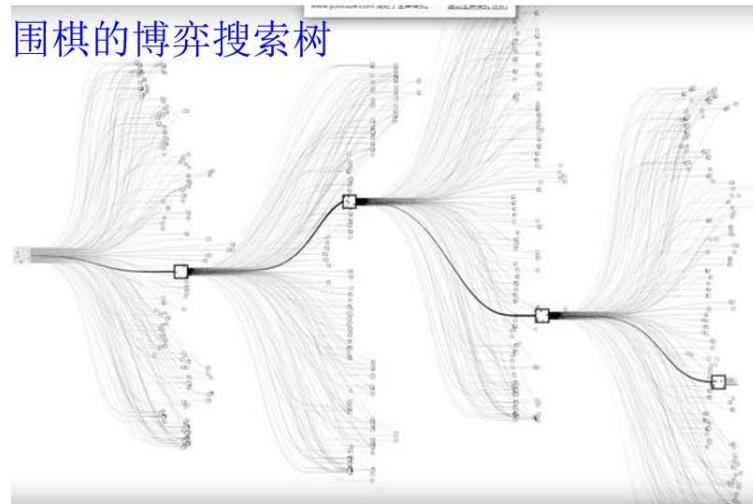
从下棋说起

■ Deeper Blue vs. AlphaGo

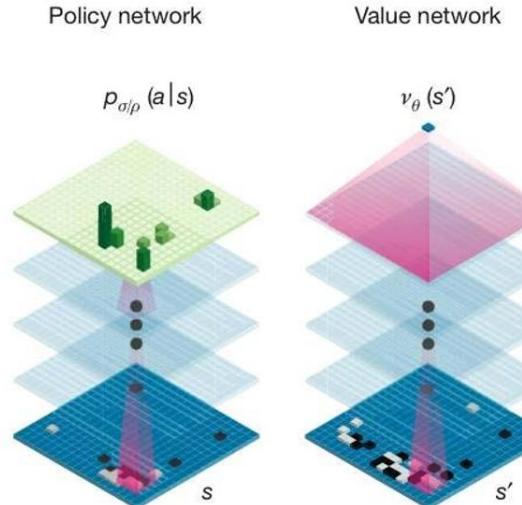
国际象棋的博弈搜索树



围棋的博弈搜索树



两个网络：
走子网络
评估网络



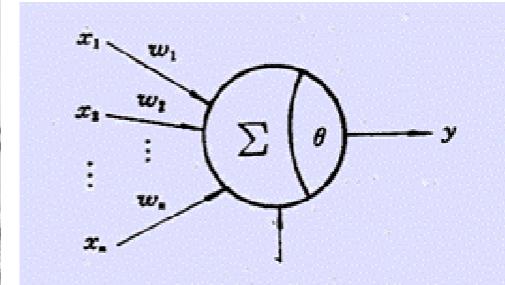
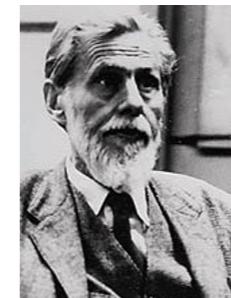
Hinton 在访谈中说：我们会得到非常好的证据，最终学术界会改变观点。也许那些和你争论的科学家永远不会回心转意，但是年轻一代会，这就是在深度学习领域正在发生的事。传统的人工智能领域的老家伙们还是不信，但是年轻一代的研究生们都看到了事情在朝什么方向发展。



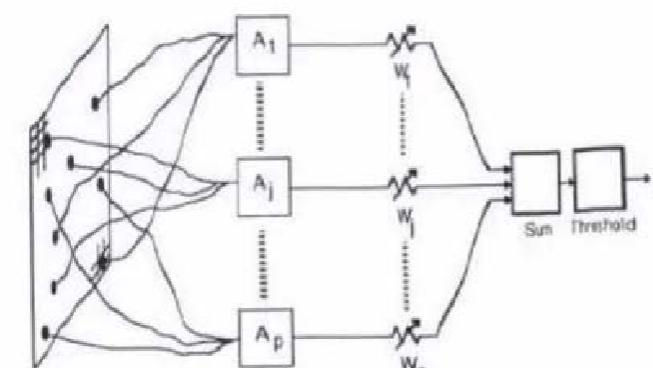
一切的开始：感知器

■ Rosenblatt & Perceptron

- 计算模型：1943年最初由Warren McCulloch 和Walter Pitts 提出
- 感知器 (Perceptron)：康奈尔大学 Frank Rosenblatt 1957年提出
- Perceptron是第一个具有自组织自学习能力的数学模型
- Rosenblatt 乐观预测：感知器最终可以 “学习, 做决定, 翻译语言”
- 感知器技术六十年代一度走红，美国海军曾出资支持，期望它 “以后可以自己走, 说话, 看, 读, 自我复制, 甚至拥有自我意识”



Perceptron (1957)

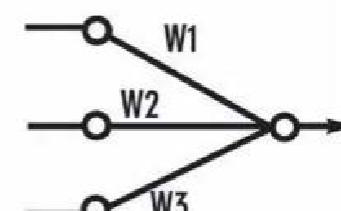


Frank Rosenblatt
(1928-1971)

Original Perceptron

(From Perceptrons by M. L Minsky and S. Papert, 1969, Cambridge, MA: MIT Press. Copyright 1969 by MIT Press.)

Simplified model:

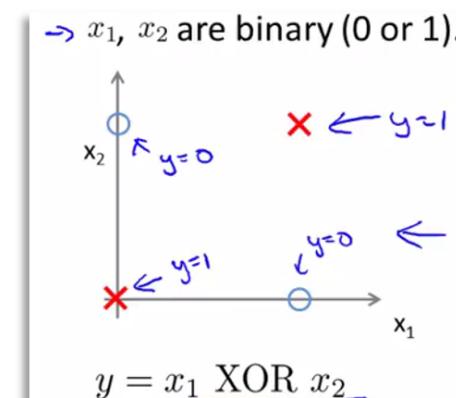




一切的开始：感知器

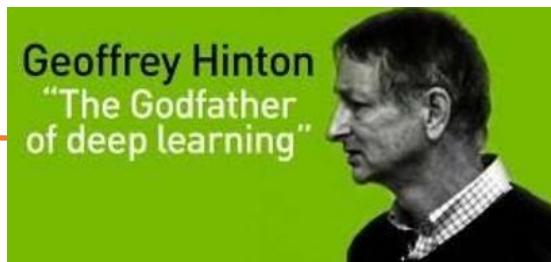
■ Rosenblatt vs. Minsky

- Rosenblatt 和 Minsky是间隔一级的高中校友。但是六十年代，两个人在感知器的问题上展开了长时间的激辩：[R](#)认为感应器将无所不能，M则认为它应用有限
- 1969 年, Marvin Minsky 和 Seymour Papert 出版了新书: "感知器: 计算几何简介". 书中论证了感知器模型的两个关键问题:
 - 第一, 单层的神经网络无法解决不可线性划分的问题, 典型例子[如异或门](#)
 - 第二, 更致命的问题是, 当时的电脑完全有能力完成神经网络模型所需要的[超大的计算量](#)
- 此后的十几年, 以神经网络为基础的人工智能研究进入[低潮](#), 相关项目长期无法得到政府经费支持, 这段时间被称为[业界的核冬天](#)
- Rosenblatt 自己则没有见证日后神经网络研究的复兴。1971年他[43岁生日](#)时, 不幸在海上开船时因为事故而丧生





传统神经网络



■ Geoffrey Hinton & NNs

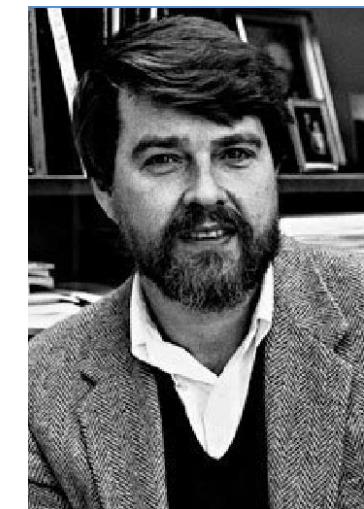
- 1970年, 当神经网络研究的**第一个寒冬**降临时, 在英国的爱丁堡大学, 一位23岁的年轻人 **Geoffrey Hinton**, 刚刚获得心理学的学士学位.
- Hinton 六十年代还是中学生时就对**脑科学着迷**。当时一个同学给他介绍关于大脑记忆的理论是: 大脑对于事物和概念的记忆, 不是存储在某个单一的地点, 而是像全息照片一样, 分布式地存在于一个巨大的神经元的网络里.
- **分布式表征** (Distributed Representation)和传统的**局部表征** (Localized Rep.) 相比
 - **存储效率高很多** : 线性增加的神经元数目, 可以表达指数级增加的大量不同概念
 - **鲁棒性好** : 即使局部出现硬件故障, 信息的表达不会受到根本性的破坏
- 这个理念让 Hinton **顿悟**, 使他40多年来一直在**神经网络**研究的领域里坚持
 - 本科毕业后, Hinton 选择继续在爱丁堡大学读研, 把人工智能作为自己的博士研究方向
 - 1978 年, Hinton在爱丁堡获得博士学位后, 来到美国继续他的研究工作



传统神经网络

■ Rumelhart & BP Algorithm

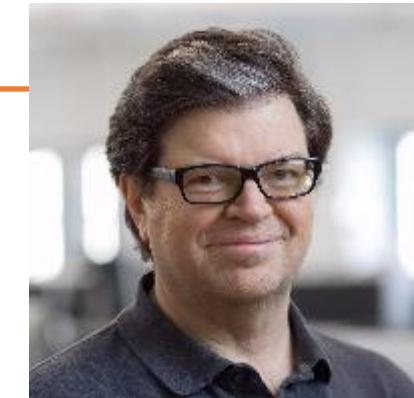
- 神经网络被 Minsky 诟病的问题：巨大的计算量; XOR问题
- 传统的感知器用所谓“**梯度下降**”的算法纠错时, 耗费的计算量和神经元数目的平方成正比. 当神经元数目增多, 庞大的计算量是当时的硬件无法胜任的
- 1986年7月, Hinton 和 *David Rumelhart* 合作在Nature杂志上发表论文 : Learning Representations by Back-propagating Errors, 第一次系统简洁地阐述**BP算法**及其应用
 - 反向传播算法把纠错的运算量下降到只和神经元数目本身成正比
 - BP算法通过在神经网络里增加一个所谓**隐层** (hidden layer), 解决了**XOR难题**
 - 使用了**BP算法**的神经网络在做如形状识别之类的简单工作时, 效率比感知器大大提高 , 八十年代末计算机的运行速度, 也比二十年前高了几个数量级
- 神经网络及其应用的研究**开始复苏** !





传统神经网络

■ Yann Lecun & CNN



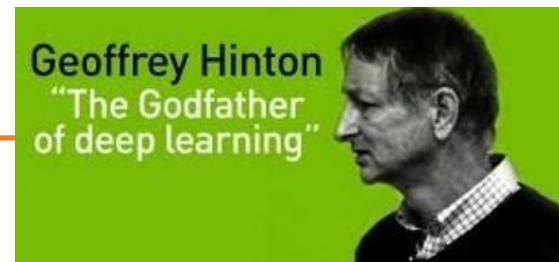
- Yann Lecun于1960年出生于巴黎
- 1987年在法国获得博士学位后,他曾追随 Hinton 教授到多伦多大学做了一年博士后的工作,随后搬到新泽西州的 Bell Lab 继续研究工作
- 在 Bell Lab , Lecun1989年发表了论文,“[反向传播算法在手写邮政编码上的应用](#)”. 他用美国邮政系统提供的近万个手写数字的样本来训练神经网络系统, 训练好的系统在独立的测试样本中, 错误率只有[5%](#)
- Lecun进一步运用一种叫做“[卷积神经网络](#)”(Convolutional Neural Networks) 的技术, 开发出商业软件, 用于读取银行支票上的手写数字, 这个支票识别系统在九十年代末占据了美国接近20%的市场
- 此时就在Bell Lab, Yann Lecun临近办公室的一个同事[Vladimir Vapnik](#)的工作, 又把神经网络的研究带入[第二个寒冬](#) !



深度学习发展

■ Hinton & Deep Learning

- 2003年, Geoffrey Hinton, 还在多伦多大学, 在神经网络的领域苦苦坚守
- 2003年在温哥华大都会酒店, 以Hinton 为首的十五名来自各地的不同专业的科学家, 和加拿大先进研究院 (Canadian Institute of Advanced Research, CIFAR) 的基金管理负责人 Melvin Silverman 交谈
 - Silverman 问大家, 为什么 CIFAR 要支持他们的研究项目
 - 计算神经科学研究者, Sebastian Sung (现为普林斯顿大学教授) 回答道 : “喔, 因为我们有点古怪. 如果CIFAR 要跳出自己的舒适区, 寻找一个高风险, 极具探索性的团体, 就应当资助我们了!”
 - 最终 CIFAR 同意从2004年开始资助这个团体十年, 总额一千万加元. CIFAR 成为当时世界上唯一支持神经网络研究的机构
- Hinton 拿到资金支持不久, 做的第一件事, 就是把“神经网络”改名换姓为 “深度学习”
- 此后, Hinton 的同事不时会听到他突然在办公室大叫 : "我知道人脑是如何工作的了!".

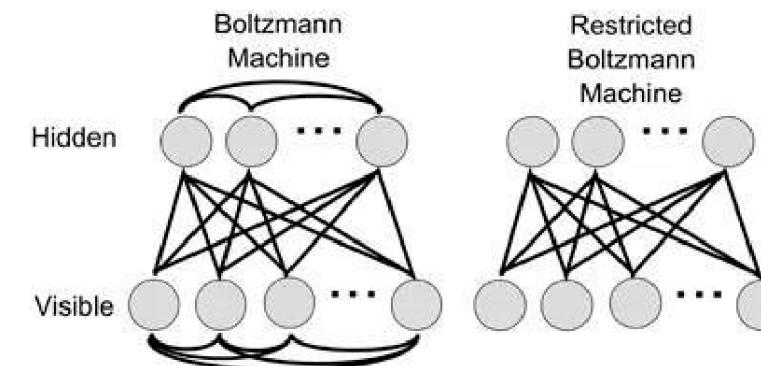




深度学习发展

■ DBN & RBM

- 2006年Hinton 和合作者发表论文：[A Fast Algorithm for Deep Belief Nets](#)
- 算法上借用了统计力学中“[玻尔兹曼分布](#)”概念：一个微粒在某个状态的几率, 和那个状态的能量的指数成反比, 和它的温度的倒数之指数成反比。使用所谓的“[限制玻尔兹曼机](#)”(RBM)来学习
 - RBM 相当于一个两层网络, 同一层神经元之间[不可连接](#)(所以叫“限制”), 可以对神经网络实现“[unsupervised training](#)”。深度置信网络[DBN](#)就是几层 RBM 叠加在一起
 - RBM 可以从输入数据进行预先训练, 自己发现重要的特征, 对神经网络连接的权重进行有效的初始化. 被称作：特征提取器 ([Feature Extractor](#))或自动编码器 ([Autoencoder](#))
 - Hinton 指出：深度学习的突破除了[计算蛮力](#)的大幅度提高以外, 聪明有效地对网络[链接权重的初始化](#)也是一个重要原因
 - 经过六万个MNIST 数据库的图像训练后, 对于一万个测试图像的识别错误率最低降到了只有 [1.25%](#)





深度学习发展

■ Andrew Y. Ng & GPU

- 2007年之前, 用GPU编程缺乏一个简单的软件接口, 编程繁琐, Debug困难
2007年 Nvidia 推出 CUDA 的GPU 软件接口后才真正改善
- 2009年6月, 斯坦福大学的 Rajat Raina 和吴恩达合作发表论文 : Large-scale Deep Unsupervised Learning using Graphic Processors (ICML09) ; 论文采用DBNs模型和稀疏编码(Sparse Coding), 模型参数达到一亿 (与Hinton模型参数的对比见下表)
- 论文结果显示 : 使用GPU运行速度和用传统双核CPU相比, 最快时要快近70倍. 在一个四层, 一亿个参数的深信度网络上使用GPU把程序运行时间从几周降到一天

Published source	Application	Params
Hinton et al., 2006	Digit images	1.6mn
Hinton & Salakhutdinov	Face images	3.8mn
Salakhutdinov & Hinton	Sem. hashing	2.6mn
Ranzato & Szummer	Text	3mn
Our model		100mn

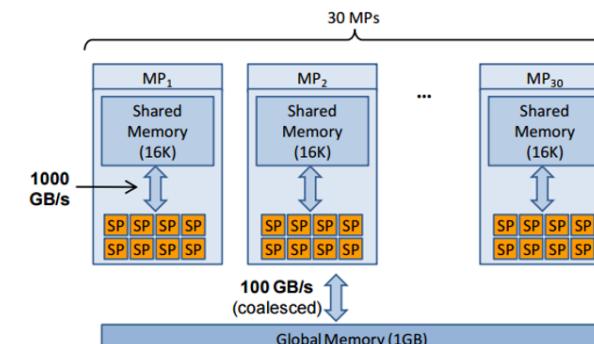


Figure 1. Simplified schematic for the Nvidia GeForce GTX 280 graphics card, with 240 total cores (30 multi-processors with 8 stream processors each).





深度学习发展

■ Jen-Hsun Huang & GPU

- 黄仁勋, 1963年出生于台湾
- 1993年从斯坦福大学硕士毕业后不久创立了 Nvidia
- Nvidia 起家时做的是图像处理的芯片, 主要面对电脑游戏市场. 1999 年Nvidia推销自己的 Geforce 256 芯片时, 发明了 GPU (Graphics Processing Unit)这个名词
- GPU 的主要任务, 是要在最短时间内显示上百万、千万甚至更多的像素. 这在电脑游戏中是最核心的需求. 这个计算工作的核心特点, 是要同时**并行处理海量的数据**
- 传统的 CPU 芯片架构, 关注点不在并行处理, 一次只能同时做一两个加减法运算. 而 GPU 在最底层的算术逻辑单元 (ALU, Arithmetic Logic Unit), 是基于所谓的 Single Instruction Multiple Data (单指令多数据流)的架构, **擅长对于大批量数据并行处理**
- 一个 GPU, 往往包含**几百个 ALU**, 并行计算能力极高. 所以尽管 GPU 内核的**时钟速度**往往比 CPU的还要慢, 但对**大规模并行处理**的计算工作, 速度比 CPU 快许多
- 神经网络的计算工作, 本质上就是大量的矩阵计算的操作, 因此特别适合于**使用 GPU**





■ Big Data: ImageNet

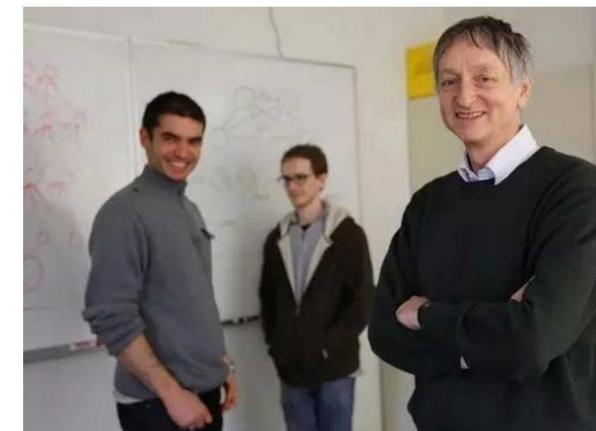
- 2009年,一群在普林斯顿大学计算机系的华人学者(第一作者为 Jia Deng)发表了论文：[ImageNet: A large scale hierarchical image database](#), 宣布建立了第一个超大型图像数据库供计算机视觉研究者使用
- 数据库建立之初,包含了320万个图像. 它的目的,是要把英文里的8万个名词,每个词收集5百到1千个高清图片,存放到数据库里. 最终达到5千万以上的图像
- 2010年,以 ImageNet 为基础的大型图像识别竞赛, [ImageNet Large Scale Visual Recognition Challenge 2010](#) (ILSVRC2010) 第一次举办
- 竞赛最初的规则：以数据库内120万个图像为[训练](#)样本. 这些图像从属于1千多个不同的类别,都被手工标记。经过训练的程序,再用于5万个测试图像评估分类准确率





■ Image Classification : ILSVRC竞赛

- Top Five Category : 计算机会对图像的分类, 答出最有可能的头五个类别, 如果正确答案都不在里面即为错误
- 2010年冠军 : NEC 和伊利诺伊大学香槟分校的联合团队, 用支持向量机 (SVM) 的技术, 识别分类的错误率为 28%
- 2011年冠军 : 用 Fisher Vector 的计算方法 (类似SVM), 将错误率降到了 25.7%
- 2012年冠军 : Hinton 和两个研究生 Alex Krizhevsky, Illya Sutskever , 利用CNN+Dropout 算法 + RELU激励函数, 用了 两个 Nvidia 的 GTX 580 CPU (内存 3GB, 计算速度 1.6 TFLOPS), 花了接近六天时间, 错误率只有 15.3%
- 2012年10月13日, 当竞赛结果公布后, 学术界沸腾了
这是神经网络二十多年来, 第一次在图像识别领域,
毫无疑义的, 大幅度挫败了别的技术
- 这也许是人工智能技术突破的一个转折点





深度学习发展

■ Yoshua Bengio & RELU

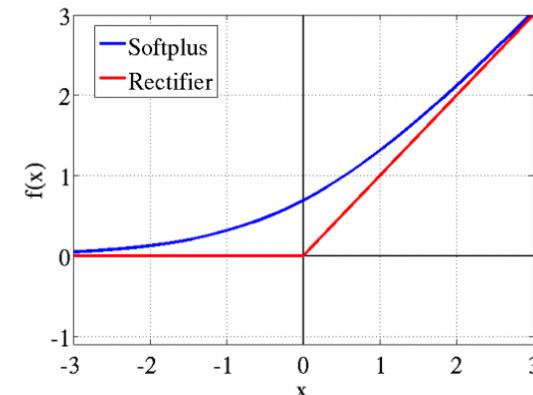
- 2011 年, 加拿大的蒙特利尔大学学者 Xavier Glorot 和 Yoshua Bengio 发表论文 : Deep Sparse Rectifier Neural Networks

- 论文的算法中使用一种称为“修正线性单元”(Rectified Linear Unit, RELU) 的激励函数. 对于特定的输入, 统计上有一半神经元是没有反应, 保持沉默



- 和使用别的激励函数的模型相比, RELU 不仅识别错误率普遍更低, 而且其有效性, 对于神经网络是否进行“预先训练”过并不敏感

- 传统的激励函数, 计算时要用指数或者三角函数, 计算量要比简单的RELU至少高两个数量级
- RELU的导数是常数, 非零即一, 不存在传统激励函数在反向传播计算中的“梯度消失问题”
- 由于统计上约一半的神经元在计算过程中输出为零, 使用 RELU 的模型计算效率更高, 而且自然而然的形成了所谓“稀疏表征”(sparse representation), 用少量的神经元可以高效, 灵活, 稳健地表达抽象复杂的概念





深度学习发展

ACM（国际计算机学会）宣布，有“深度学习三巨头”之称的 Yoshua Bengio、Yann LeCun、Geoffrey Hinton 共同获得了 2018 年的图灵奖。

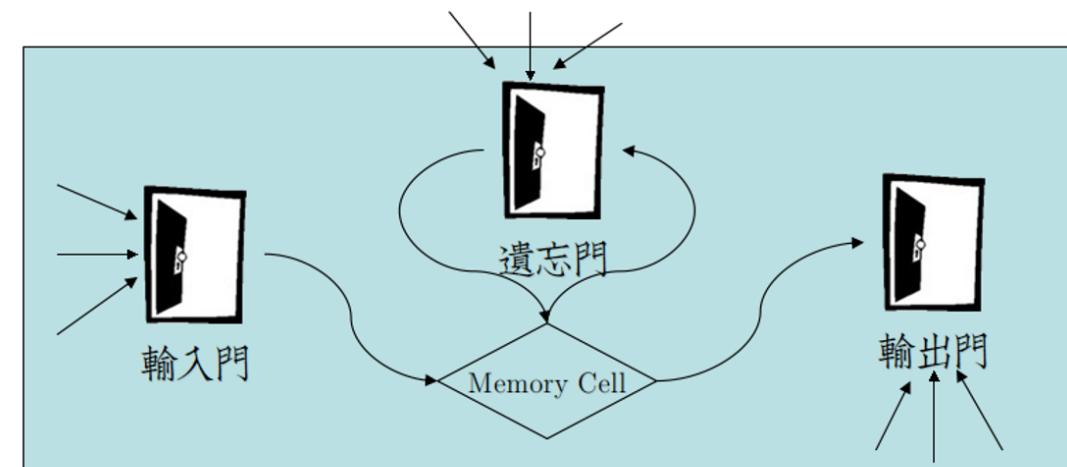
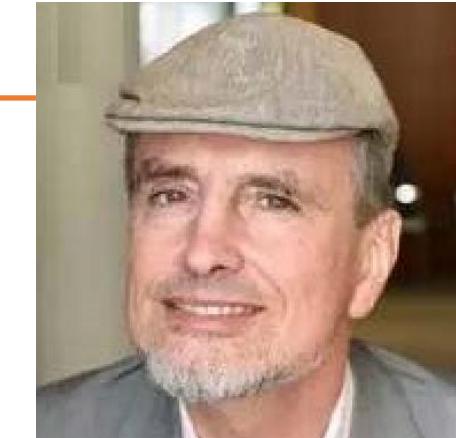




深度学习发展

■ Schmidhuber & LSTM

- 1997年瑞士 Lugano 大学的 Schmidhuber 和他的学生 Sepp Hochreiter 合作, 提出了长短期记忆 (LSTM, Long Short-Term Memory) 的计算模型
- LSTM : 背后要解决的问题, 是如何将有效信息, 在多层循环神经网络传递之后, 仍能输送到需要的地方去
- LSTM 模块, 是通过内在参数的设定 (如图, input gate, output gate, forget gate), 决定某个输入信息在很久以后是否还值得记住, 何时取出使用, 何时废弃不用

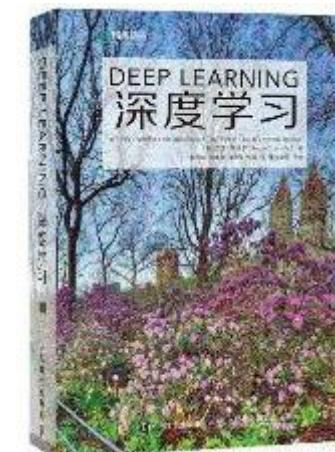
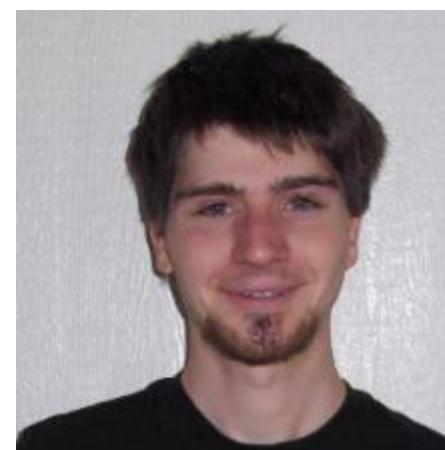




生成对抗网络

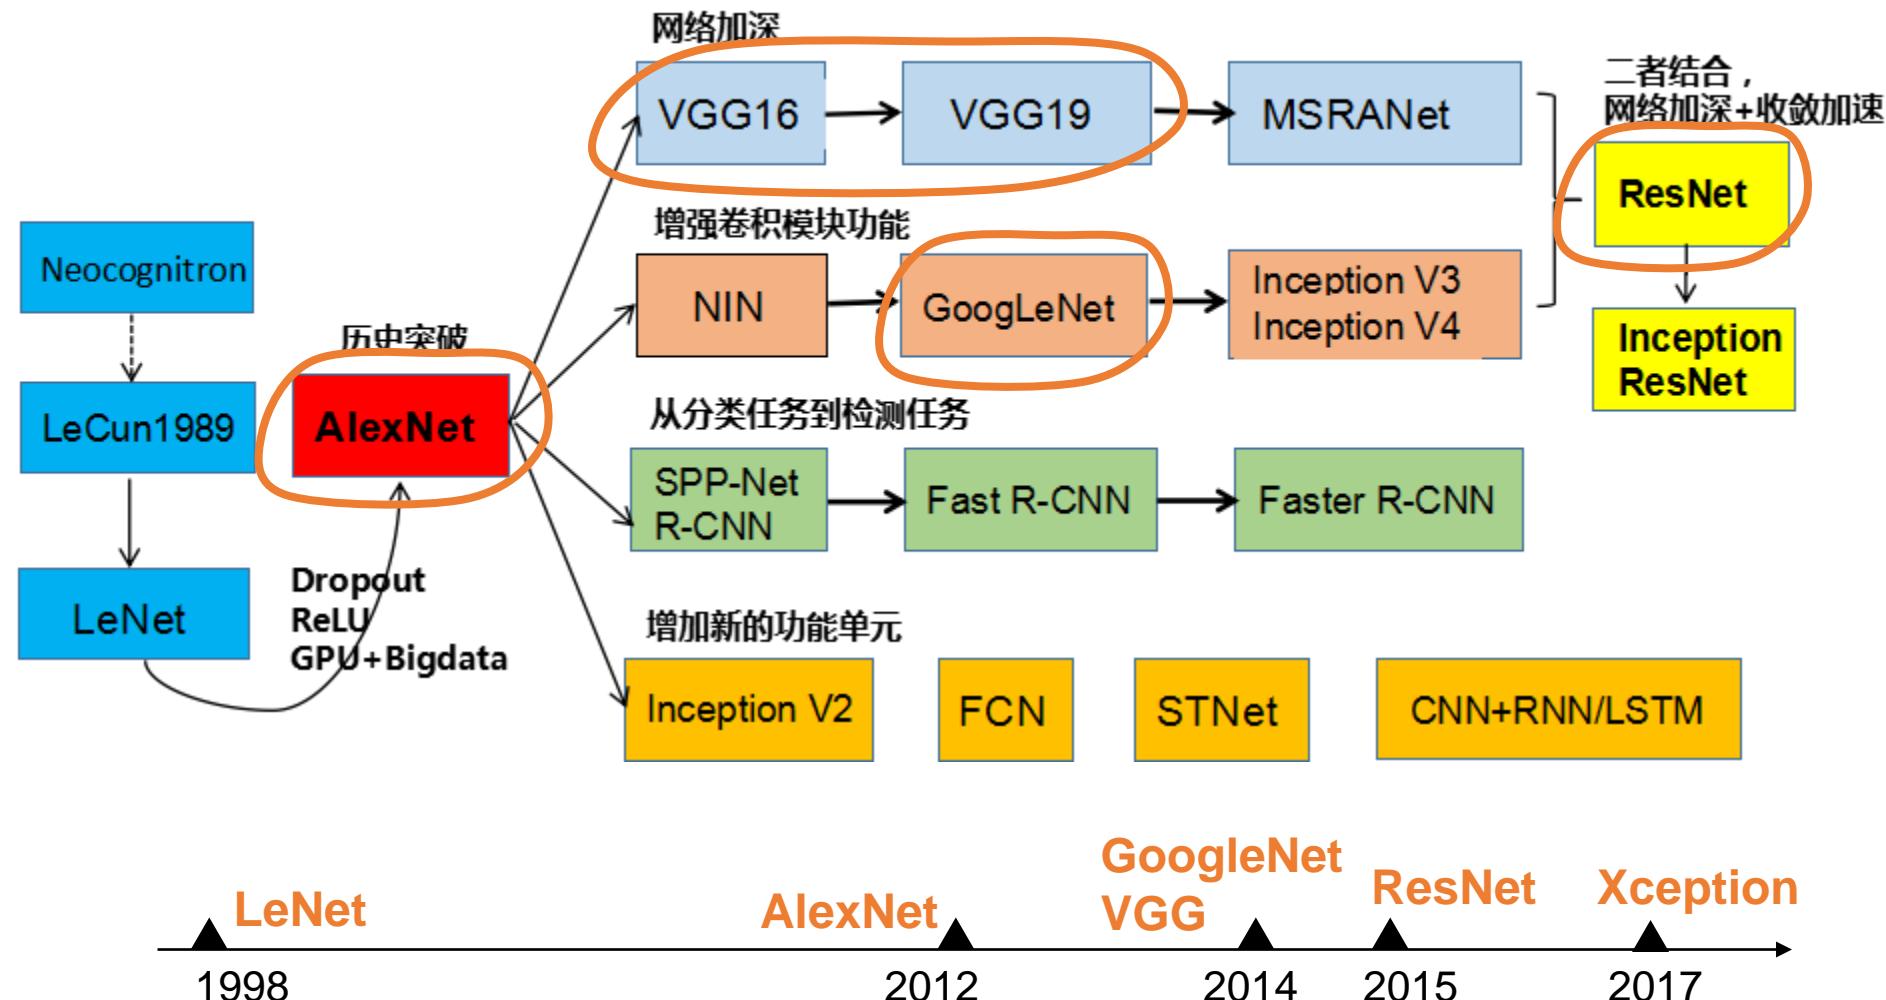
Generative Adversarial Networks (GANs)

Ian Goodfellow, OpenAI Research Scientist
NIPS 2016 tutorial
Barcelona, 2016-12-4



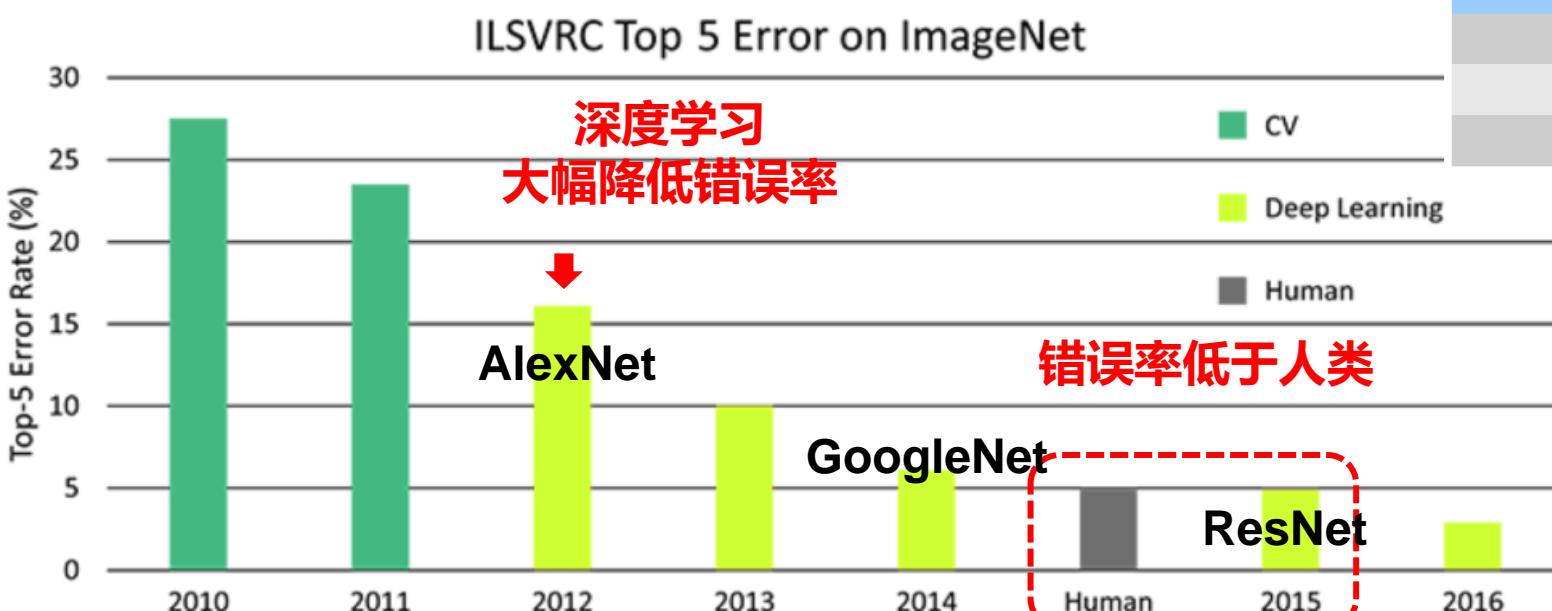


神经网络结构的发展





ImageNet的进击



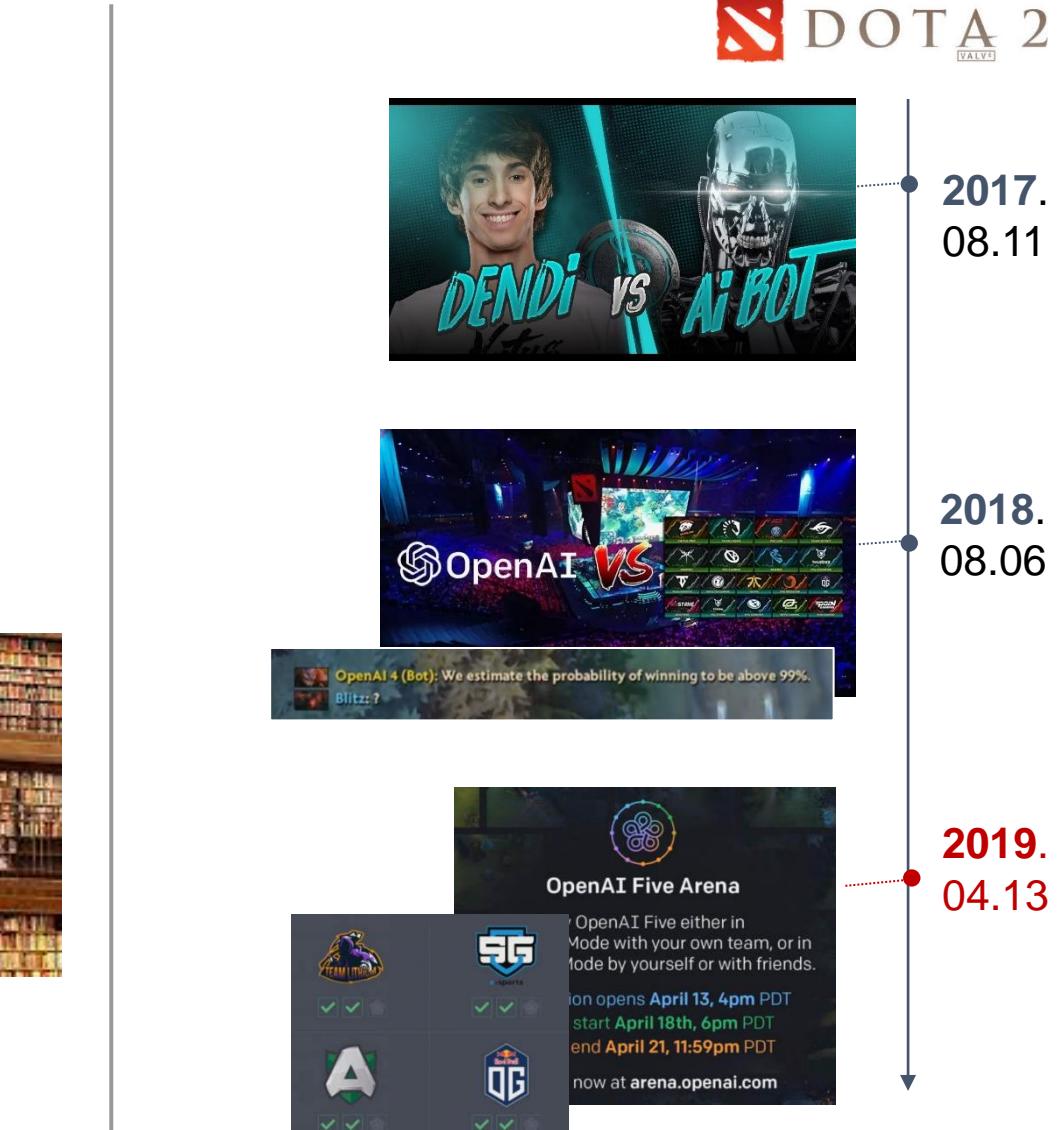
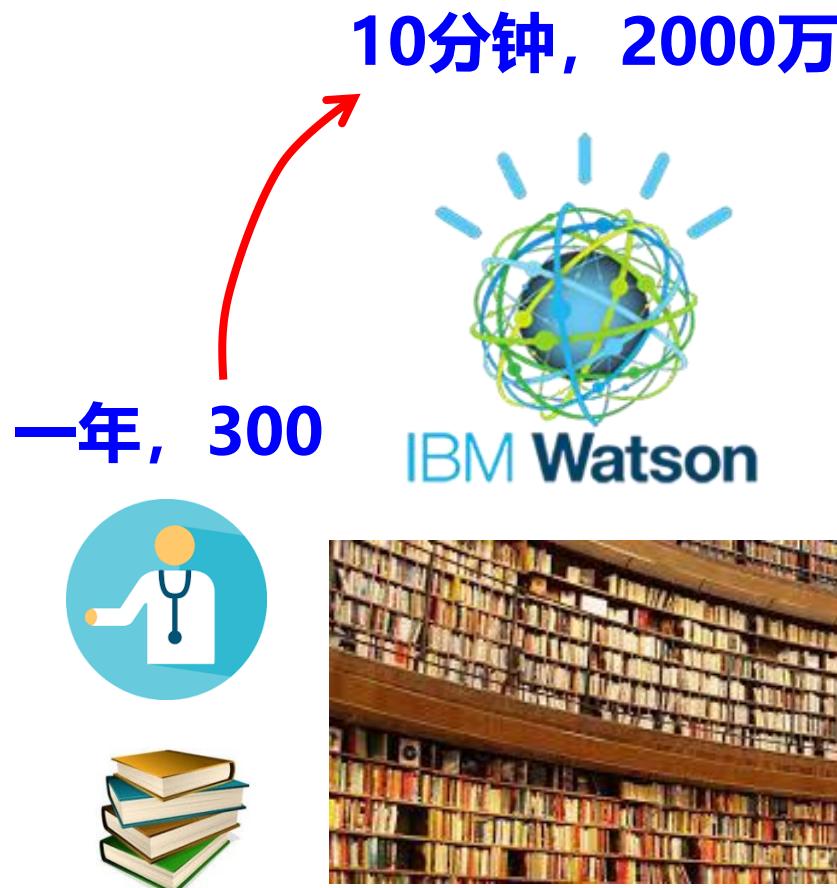
source: <https://www.dsiac.org/resources/journals/dsiac/winter-2017-volume-4-number-1/real-time-situ-intelligent-video-analytics>

2012 Teams	%error	2013 Teams	%error	2014 Teams	%error
Supervision (Toronto)	15.3	Clarifai (NYU spinoff)	11.7	GoogLeNet	6.6
ISI (Tokyo)	26.1	NUS (singapore)	12.9	VGG (Oxford)	7.3
VGG (Oxford)	26.9	Zeiler-Fergus (NYU)	13.5	MSRA	8.0
XRCE/INRIA	27.0	A. Howard	13.5	A. Howard	8.1
UvA (Amsterdam)	29.6	OverFeat (NYU)	14.1	DeeperVision	9.5
INRIA/LEAR	33.4	UvA (Amsterdam)	14.2	NUS-BST	9.7
		Adobe	15.2	TTIC-ECP	10.2
		VGG (Oxford)	15.2	XYZ	11.2
		VGG (Oxford)	23.0	UvA	12.1





深度学习-学霸？游戏王？





深度学习的“琴棋书画”

